蛙鸣

第 68 期

1981.06–2026.07

喜聽蛙鳴

科大學風濤

蛙鳴顯精神

前輩栽好樹

更有後來人

單增 辛丑 八月

院长寄语

《蛙鸣》承载着科大数院的同学们探索数学、分享知识、创造新天地的满腔热情和无限期待。一声声纯粹而质朴的“蛙鸣”，其形虽小，其声也宏。值此《蛙鸣》创刊40周年之际，希望同学们以此为新的起点，携手奋进，将科大数学的精神薪火相传，在数学世界里继续追寻纯粹崇高的理想，求实求真，勇于创新，奏响科大数学人的最强音！

马志明

2021年6月4日

卷首语

2026 年，注定是数学史上不平凡的一年。

单位距离问题、雅可比猜想……越来越多曾经横亘在人类面前的数学难题，开始有了 AI 的身影。曾经只存在于想象中的图景，正以远超预期的速度成为现实。当机器开始证明定理、提出猜想，甚至尝试走向数学的未知之境，我们也不得不重新追问：

AI 时代的数学，将走向何方？而身处其中的我们，又该如何学习数学、理解数学，乃至重新认识自己与数学的关系？

时代的答案尚未写就。或许，今日许多笃定的判断，数年之后都会显得稚嫩；我们熟悉的学习方式、研究方式，甚至对“数学家”这一身份的理解，也可能悄然改变。

但变化之中，总有一些东西值得珍重。工具会变，问题会变，通往答案的道路也会变；而我们对数学的热爱，对未知的好奇，对求知与探索的渴望，却不应因此褪色。恰恰是在一个答案似乎越来越容易获得的时代，我们更需要学会提出真正的问题；在知识唾手可得的时候，更需要知道什么值得理解，什么值得追寻。于是，又一年盛夏，我们带着新一期《蛙鸣》，与大家见面了。

从 1981 到 2026，四十五载光阴流转。《蛙鸣》所记录的，从来不只是纸页上的文字，也是不同年代数学学子的所思、所问、所爱。时代一次次改变它的面貌，而一代又一代“蛙鸣人”，仍愿意俯身倾听校园里的声音，记录属于数学人的困惑、探索与热忱。

惟愿这份热忱，不因世界变化太快而仓促，不因工具日益强大而消减。愿我们仍肯为一个问题久久思索，为一个证明反复推敲，为偶然窥见的数学之美而欣喜；也愿我们有勇气拥抱新的时代，却不在潮流之中失去自己的判断。

愿新一期《蛙鸣》，仍能陪你在答案之外，多保留一些问题；在时代奔涌向前的时候，多听见几声属于自己的蛙鸣。

第 68 期《蛙鸣》编辑部

2026 年 7 月 6 日

《蛙鸣》复刊的回忆与感想

2013年秋季刚开学时，当时还是大一萌新的我在社团宣传讲座上第一次接触到《蛙鸣》。当时《蛙鸣》已停刊四年，11级计算数学方向的李航学长希望能将这本属于科大数院学子自己的数学期刊重新办起来，可惜由于人手不够以及宣传途径的有限，也没能延续下去。“蛙鸣”之名，本有“其形虽小，其声也宏”之意，可在那之后的相当长一段时间，“蛙鸣”逐渐销声匿迹。

我大四的时候，15级龚禹霖同学建了个QQ群（也就是后来的“山顶洞数学交流群”）讨论数学专业课的学习。记得那时大家总觉得“提前修若干门专业课”、“某门很难的课拿了A+”是非常高大上的事情。当越来越多同学加群后，我们才意识到后辈们其实很少有渠道了解到如何合理地规划数学学习路线。2019年底，在16级王翌宇同学的倡导下，由我组织山顶洞群友撰写了《USTC基础数学修课指南》，意在让大家在修课阶段少走弯路，更快掌握必要的基础知识。如今回看，这份指南中相当一部分内容当然还很不成熟；但在当时，它至少为许多对选课和学习路线感到茫然的后辈提供了一条可以尝试的路径。某种意义上，这也是“蛙鸣”精神的延续：学生之间自发地分享经验，也自发地把对数学的热情传递下去。后来我还得知这份指南当时在网上确实造成了一定的影响力：上学期我教的PDE班上一位学生跟我聊天时还提到“当年高一的时候看到这份修课指南，对科大心驰神往，于是就报考了科大数学专业”。

我读博士期间逐渐感受到“学习数学基础”和“做数学科研”的差别还是很大的。前者更多依赖课程、教材和系统训练，后者却往往需要在交流中获得问题意识，在阅读中理解动机，在不断试错中摸索出自己真正感兴趣的方向。再回想我自己在大三下学期转到基础数学方向，准备申请出国前的一个月不到毅然转向PDE领域，正是因为我做大研期间读前沿专著时逐渐对PDE、调和分析中的“硬分析”产生了浓厚的兴趣；又回想起大四那年在赵老师开设的两门PDE选讲课上，我学到了很多课内完全接触不到的研究方法，这些内容看似天马行空，然仔细研读后又发现其思想实则脱胎于一些非常基本的事实。我忽然意识到，如果我们在读书期间仅仅关注上课、考试和GPA，或者读研期间只关注眼前自己领域的一亩三分地，那很难成长为一名能立足的数学工作者。既然这样，那为什么不能让本科中高年级的同学更早接触到这些东西？为什么不能有一个平台，让大家在“拟合课本和往年考题”之外还能看到数学作为研究对象时更鲜活的一面？

转机出现在2020年底。当我与14级的罗宇杰（他也是我在JHU的博士同学和在NUS的博士后同事）聊起这些感想时，他也说到可以写一些关于自己研究方向介绍性的survey，我便想起了那沉寂已久的《蛙鸣》——光是当时的山顶洞群就有很多同学已经进入海内外名校深造读博，为什么我们不能借此机会复刊《蛙鸣》呢？我记得我在山顶洞群里说了一句“我们想‘复活’《蛙鸣》”，很快就得到了大家的积极回应。巧合的是，数院学生会18级的黄欣祺、陈恒宇等同学当时也在与王作勤老师和马杰老师筹划复刊《蛙鸣》。更巧合的是，2020年海外疫情肆虐，而我正好回国线上学习了一年。于是两边一拍即合，我直接前往科大与诸位老师同学们共同商量策划《蛙鸣》的复刊事宜，这也得到

了数院官方的大力支持。

复刊的第一期（总第64期）由我担任主编，几位17~20级数院的同学担任编委或是负责美工设计、排版和会议记录。最初我们通过数院学生会的公众号等渠道发布征稿启事，提供了投稿用的LaTeX模板，并同时面向全校学生招募审稿人。之后我们明确了编辑部处理稿件的流程以及审稿人撰写审稿意见的规范。接下来的几个月，30余位审稿人对主动投稿和编辑部约稿的20篇稿件进行了详细的审阅，同时负责美工设计和排版的同学利用自己的空余时间雕琢封面和插画的每一个细节。终于，在2021年初夏，阔野万里中的一声“蛙鸣”打破了尘封十二年的寂静：创刊四十周年之际，在科大数院老师、校友、同学们的支持和关心下，我们带着《蛙鸣》回来了！

第64期《蛙鸣》复刊之后的几年，第65 66、67期《蛙鸣》又相继问世。一代代科大数院人借此自由开放、原创独立的数学讨论平台，将科大数学的精神薪火相传。如果说第64期《蛙鸣》是长眠后的苏醒，那就愿它能点燃你我心中对数学的热情，唤起蛰伏于心中一声声纯粹质朴的蛙鸣，在未来延绵不绝，生生不息。

我有幸于2025年5月回到科大数院工作。和同学们接触时，我常感叹今天学生所能获得的学习资源已经远超我们当年；许多同学的学习能力、信息检索能力和自学速度也令人印象深刻。尤其在AI迅速发展的背景下，了解新事物的门槛大幅降低，找到学习入口也比过去容易得多。与此同时，我也隐约感到如今的同学比过去更容易陷入一种“单打独斗”的状态，也更容易被升学就业、GPA焦虑和技术革新等浪潮裹挟，以至于对未来的发展感到迷茫。私以为，辅助工具可以帮助我们更快找到入口，却不能替代扎实的基础训练；AI可以帮助我们过滤信息和解答问题，却不能替代我们自己的主观判断。真正能支撑一个人走向高处的仍然是脚踏实地掌握核心知识、主动寻找交流对象、尽早接触真实问题的能力。

更重要的是，我希望科大同学们能有更强的“活人感”：上课、考试和GPA不是生活的全部，它们的“存在感”仅限于大学前三年；抛开桎梏，更早地成为一个“活人”而非“唯GPA论者”，去思考未来自己想成为一个怎样的人并付诸行动，去大胆地表述你的想法并与他人碰撞出思维的火花——这也正是“蛙鸣”最初的愿望之一。也许正是在这些看似微小的声音中，我们会重新发现数学的乐趣，重新发现生活的丰富多彩。

文/章俊彦

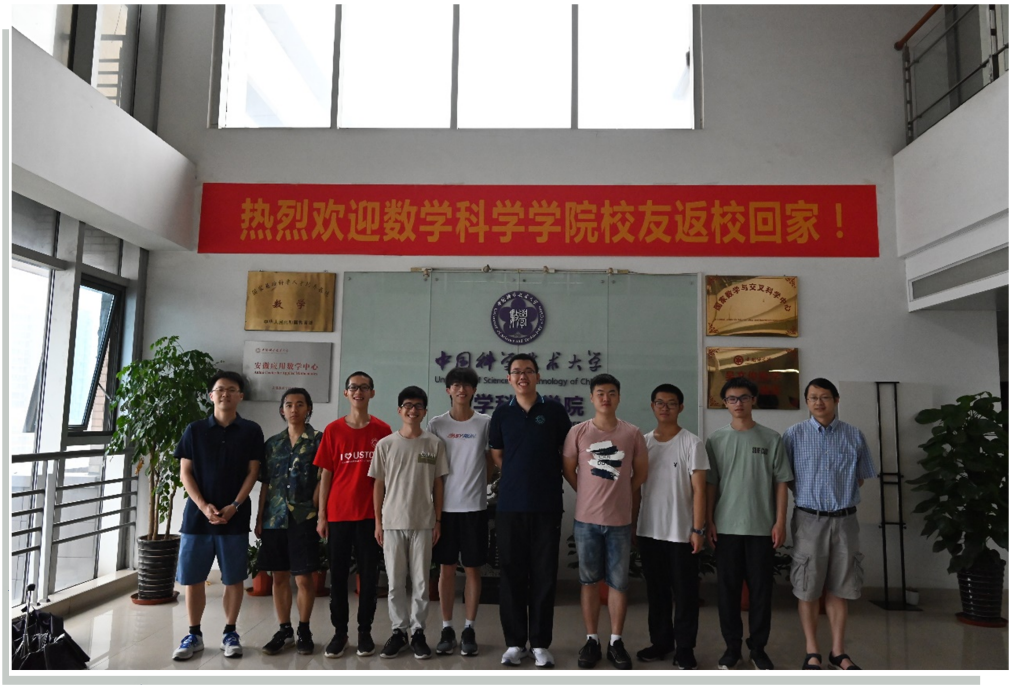

第六十四期《蛙鸣》编委会、指导老师合影。左起：马杰老师、王麒翔（18数院）、陈恒宇（18数院）、邵锋（17数院）、郑伟豪（18数院）、章俊彦（13数院）、黄欣祺（18数院）、姚一晨（18数院）、吴松宇（20数院）、王作勤老师。

第68期《蛙鸣》编辑部

（排名不分先后）

顾　问

章俊彦　朱葛瑄

主　编

郑登煜

编　委

李华滨　叶钉　冯玉山

柯力成　郭谦　林俊杰

罗腾宇　杨汶昊

设　计

郑婷月　翟思翔　ChatGPT

排　版

林俊杰　罗腾宇　骆一豪

考亚楠　杨中取　王依彦

林资荐　刘昭颖　马钰函

记　录

郑登煜

投稿 / 建议 / 勘误

mathsu01@ustc.edu.cn

扫描二维码获取更多信息

中国科大
数学科学学院学生会

联系我们
蜗壳的书院

目录

初阳

一道概率小题目：巧算面积期望

...俞袁朴　3

在线背包问题的最优竞争比与鲁棒性

...刘厚振　7

蛙声一片

双曲平面的一些几何性质

...舒屹扬　19

基于行列式乘子表示的 LMSD 收敛证明及加权 Ritz 推广

...杨书泰　33

降维的艺术：Krylov 子空间与 GMRES 方法

...张汇泽　51

AI 时代的数学研究——专访九重团队

...数学科学学院 郑登煜 谭皓天 68

Fitch Cheney's Five-Card Trick: Combinatorial Insights and Generalization

... Feipeng Liu 78

Research on the Erdős Matching Conjecture and Focal-free uniform hypergraphs

...叶钉 87

笔墨文篇

庐山小姑娘 ...史红霞 95

春色如茶 ...杨炳阳 97

致谢 ... 98

征稿启事 ... 99

初阳

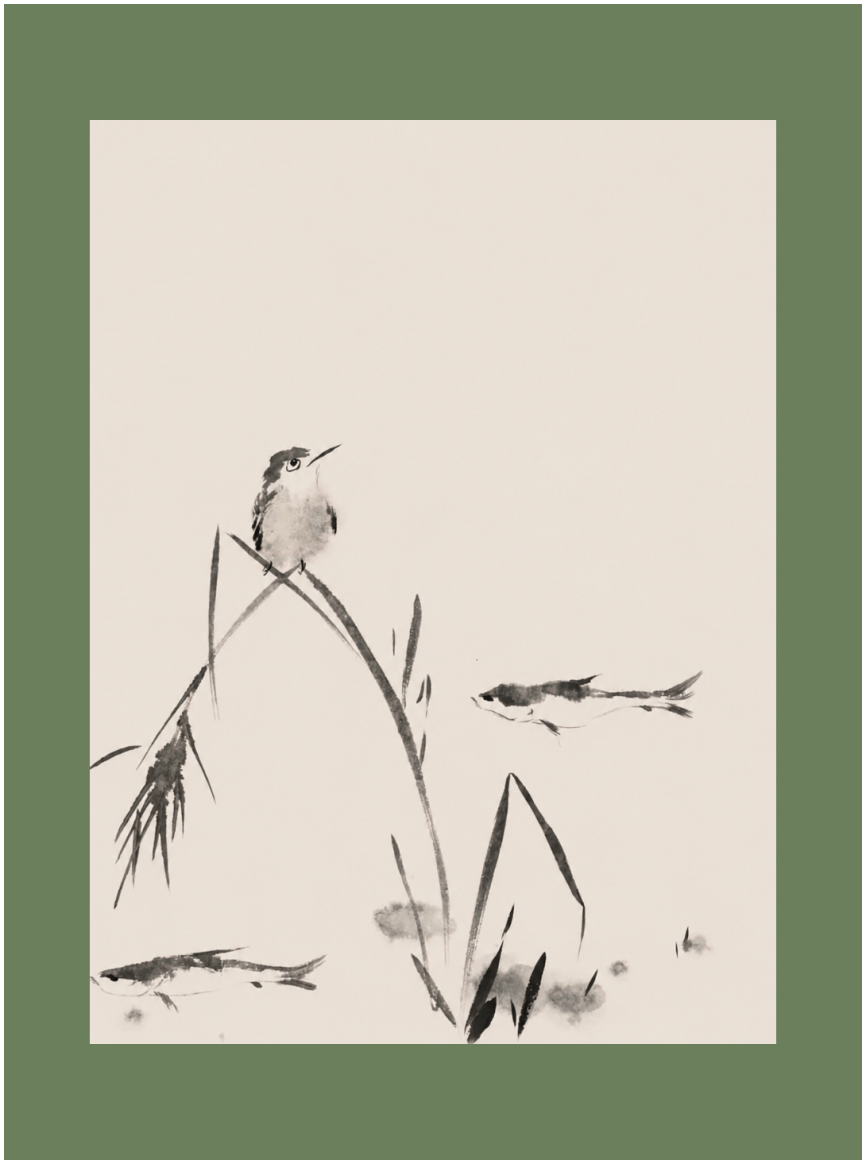

稻花香里说丰年，听取蛙声一片。

——《西江月·夜行黄沙道中》

一道概率小题目：巧算面积期望

俞袁朴

摘 要

本文针对单位圆内随机三点构成的三角形与圆和直线围成的区域的面积期望之比，提出了一种巧妙的概率求解方法。通过引入第四个随机点并利用几何概型的对称性与概率测度的不变性，将复杂的面积期望计算转化为四点凸包问题的分析。分析证明，三角形区域面积与外围区域面积之比的期望值为 1/3，且解决问题的思想方法可推广至外围区域为一般凸图形的情形。文章进一步指出，四点凸包为三角形的概率即 Sylvester 四点问题的经典结果，并进一步介绍了详细的数学史背景，体现了组合几何与概率方法的结合。

1 题目与解答

题目. 平面直角坐标系中，随机取 A, B, C 三点，三点坐标独立同分布，均服从单位圆内的均匀分布，则三点以概率 1 不共线. 设直线 AB、直线 BC 与圆三者围成的区域为 S_1，直线 BC、直线 AC 与圆三者围成的区域为 S_2，直线 AC、直线 AB 与圆三者围成的区域为 S_3，再设 $S = S_1 \cup S_2 \cup S_3$（如图，图中红色区域），三角形 ABC 区域记作 T（图中蓝色区域）. 求

$$\frac{\mathrm{E}|T|}{\mathrm{E}|S|}$$

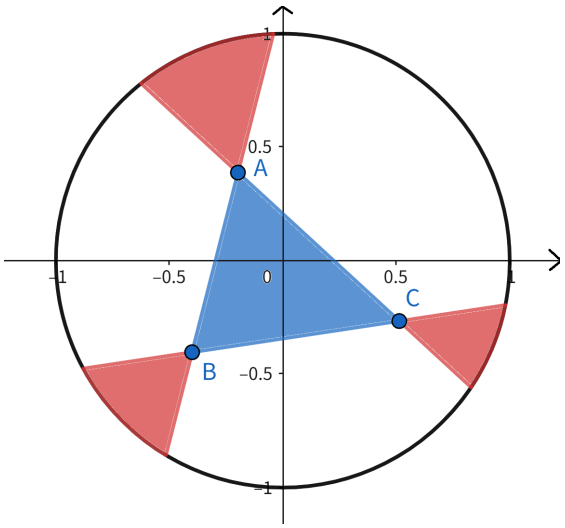

图 1.1: 题图

解答. 此题乍一看无从下手：给定 A, B, C 三点的位置，计算 S 十分繁琐和困难. 但我们注意到题目具有对称性. 能否绕开繁琐的直接计算，从几何概型的第一性原理入手，找到 S 和 T 间更本质的联系呢？答案是肯定的.

作者信息: 2024 级少年班学院, 邮箱: ypyu@mail.ustc.edu.cn

稿件信息: 本稿件于 2 月 3 日来稿。稿件编辑：叶钉

设单位圆内区域为 U；明确起见，记 $\boldsymbol{V}=(\boldsymbol{A},\boldsymbol{B},\boldsymbol{C})$，其所有可能的取值的集合为 W，把 $|S|$ 与 $|T|$ 分别记为六元函数 $|S(\boldsymbol{V})|$ 和 $|T(\boldsymbol{V})|$，$f(\boldsymbol{V})$ 为 $\boldsymbol{V}$ 的联合密度函数. 在已经取定三点的前提下，我们按单位圆内的均匀分布独立地再取一点 D，则 $P(D\in S(\boldsymbol{V})|\boldsymbol{V}=\boldsymbol{v})=P(D\in S(\boldsymbol{v}))=\dfrac{S(\boldsymbol{v})}{|U|}$，因此[1]

$$P(D\in S(\boldsymbol{V}))=\int_W P(D\in S(\boldsymbol{v}))f(\boldsymbol{v})\,d\boldsymbol{v}=\frac{1}{|U|}\int_W S(\boldsymbol{v})f(\boldsymbol{v})\,d\boldsymbol{v}=\frac{\mathrm{E}|S(\boldsymbol{V})|}{|U|}$$

同理

$$P(D\in T(\boldsymbol{V}))=\frac{E|T(\boldsymbol{V})|}{|U|}$$

故所求

$$\frac{\mathrm{E}|T|}{\mathrm{E}|S|}=\frac{P(D\in T(\boldsymbol{V}))}{P(D\in S(\boldsymbol{V}))}$$

细心的读者很快可以发现，D 点虽然是“后取的”，但和 A,B,C 没有任何实质区别. 该过程完全等效于我们随机从圆内以均匀分布取四个点 A_1，A_2，A_3，A_4，再从中等概率随机取一个作为 D 点. 由三点共线事件概率为 0，故不妨设这四点无三点共线. 记 $\boldsymbol{V'}=(\boldsymbol{A_1},\boldsymbol{A_2},\boldsymbol{A_3},\boldsymbol{A_4})$，其所有（无共线的）可能的取值的集合为 W'，易证明 W' 可以划分为两个等价类 W_1 和 W_2，W_1 中任一元素的四个点形成的凸包是三角形（如图 2），W_2 中任一元素的四个点形成的凸包是四边形（如图 3）. 因此，

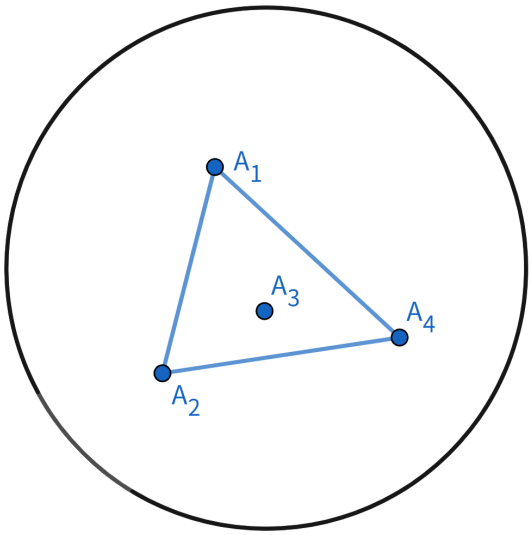

图 1.2: 三角形凸包

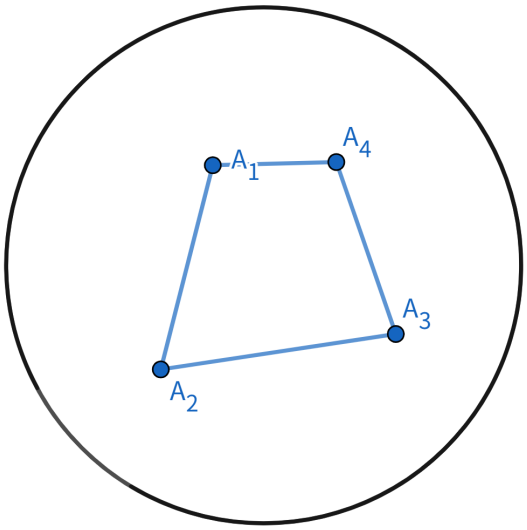

图 1.3: 四边形凸包

$$\begin{aligned}&P(D\in T)=P(\boldsymbol{V}\in W_1)P(D\in T|\boldsymbol{V}\in W_1)+P(\boldsymbol{V}\in W_2)P(D\in T|\boldsymbol{V}\in W_2)\\&=P(\boldsymbol{V}\in W_1)P(D\in T|\boldsymbol{V}\in W_1)\\&=\frac{1}{4}P(\boldsymbol{V}\in W_1)\end{aligned}$$

上述最后一步是因为，在已知四点凸包为三角形的条件下，不妨假设是图 2 的具体情形，则当且仅当 D 为 A_3 时才有 $D\in T$.

[1]此式的积分实际上是六重积分，$d\boldsymbol{v}$ 应理解为 $dx_A dy_A dx_B dy_B dx_C dy_C$。

同理

$$\begin{aligned} &P(D \in S) = P(\boldsymbol{V} \in W_1)P(D \in S|\boldsymbol{V} \in W_1) + P(\boldsymbol{V} \in W_1)P(D \in S|\boldsymbol{V} \in W_2) \\ &= P(\boldsymbol{V} \in W_1)P(D \in S|\boldsymbol{V} \in W_1) \\ &= \frac{3}{4}P(\boldsymbol{V} \in W_1) \end{aligned}$$

故所求

$$\frac{\mathrm{E}|T|}{\mathrm{E}|S|} = \frac{P(D \in T(\boldsymbol{V}))}{P(D \in S(\boldsymbol{V}))} = \frac{1}{3}$$

此外，还可以使用积分计算出 $\mathrm{E}|T|$ 的准确值，从而得到 $\mathrm{E}|S|$ 乃至 $P(\boldsymbol{V} \in W_1)$.

2 题目之外

实际上，本题中的 $P(\boldsymbol{V} \in W_1) = \frac{35}{12\pi^2}$，这也是组合几何的经典命题 Sylvester 四点问题（在外围区域为圆时的情形）的答案. 有兴趣的读者可以尝试计算验证.

回顾本题，解题过程似乎没有显式地用到“单位圆”这一具体形状. 如果把它改为其他图形，情况如何呢？事实上，Sylvester 在 1865 年提出了一个问题：在平面区域 R 中随机选取的四个点具有四边形凸包的概率 $q(R)$(以及相应的，四个点具有三角形凸包的概率 $p(R) = 1 - q(R)$). 很快他得出结论“该问题没有一个确定的解”，意即该概率取决于 R 的具体形状. 1867 年 Woolhouse 给出了圆盘情形的求解. 1917 年，Blaschke 证明了对于平面上具有有限面积的凸区域 R，

$$\frac{2}{3} \le q(R) \le 1 - \frac{35}{12\pi^2}$$

其中下界在 R 为三角形时取到，上界则在 R 为圆或椭圆时取到. (对于椭圆（含圆）而言，$q(R)$ 的值是唯一的，即所有椭圆给出相同的结果.) 本文题目即为取上界情形. Blaschke 论证的核心工具是 Steiner 对称化，这个开创性工作为利用对称化方法 (Symmetrization) 求解几何极值问题奠定了经典范例. 其他数学家计算说明，在其他形状的 R(如正方形、五边形、六边形) 下，$q(R)$ 可以取到不同数值.

1965 年 Efron 撰写论文，为任意概率分布下随机点凸包的期望统计量（如面积、周长、顶点数）开发了一套通用的积分表达式，并证明了当抽样分布是正态分布或圆盘或球体上的均匀分布时，这些复杂的积分会变得“特别简单”，可以直接求解。该论文讨论并解决了 Sylvester 四点问题。论文还给出了 Efron 恒等式：设 R 为任意维[2]的欧几里得空间里的给定凸区域 (勒贝格测度为 $|R|$)，从其中独立随机地抽取 n 个点，用 V_n 表示这 n 个点的凸包的勒贝格测度，N_n 表示这 n 个点的凸包的顶点数，则有

$$\frac{E[V_n]}{|R|} = 1 - \frac{E[N_{n+1}]}{n+1}$$

这篇论文是随机几何领域的一部奠基之作，产生了深远影响，其核心思想被后续学者不断推广，如 2005 年 Buchta 等人将 Efron 恒等式推广到高阶矩，并在更一般的几何体中找到了类似关系.

参考文献

[1] Sylvester, J. J. On a special class of questions on the theory of probabilities. *British Association for the Advancement of Science Report*, page 8, 1865. Originally proposed in Educational Times, April 1864.

[2]原论文中是二维，但很快被推广到高维.

[2] Woolhouse, W. S. B. Solution to Question 1351. *Mathematical Questions with Their Solutions*, 5:82, 1867. Early solution for the disk case of Sylvester's four-point problem.

[3] Blaschke, Wilhelm. Über affine Geometrie XI: Lösung des Vierpunktproblems von Sylvester aus der Theorie der geometrischen Wahrscheinlichkeiten. *Leipziger Berichte*, 69:436–453, 1917.

[4] Alikoski, H. A. Über das Sylvestersche Vierpunktproblem. *Annales Academiae Scientiarum Fennicae*, 51(7):1–10, 1939. General formula for expected triangle area in regular n-gons, applicable to Sylvester's four-point problem.

[5] Efron, Bradley. The convex hull of a random set of points. *Biometrika*, 52(3-4):331–343, 1965.

[6] Buchta, Christian and Reitzner, Matthias. An identity relating moments of functionals of convex hulls. *Discrete & Computational Geometry*, 33:125–142, 2005. Extension of Efron's identity to higher moments.

[7] OEIS Foundation Inc. Sequence A189413: Number of convex quadrilaterals on an n × n grid. *The On-Line Encyclopedia of Integer Sequences*, 2025. The limiting probability that four random grid points form a convex quadrilateral is 25/36.

[8] OEIS Foundation Inc. Sequence A242780: Decimal expansion of the maximum probability that the convex hull of four points, chosen at random inside a convex planar region, is a quadrilateral. *The On-Line Encyclopedia of Integer Sequences*, 2025. $1 - 35/(12 \cdot \pi^2)$.

[9] OEIS Foundation Inc. Sequence A396661: Decimal expansion of (97 + 52*sqrt(2))/2304. *The On-Line Encyclopedia of Integer Sequences*, 2026. Mean area of a random triangle in a unit-area regular octagon; related to Sylvester's four-point problem.

在线背包问题的最优竞争比与鲁棒性

刘厚振

摘 要

本文研究单位价值情形下的在线背包问题, 其中每件物品的价值等于其重量, 因此目标等价于在容量约束下最大化最终装入背包的总重量. 针对这一模型, 我们将问题表述为一个最差情形保证意义下的 minimax 问题: 在线算法希望在所有输入序列上最大化其最低利用率. 基于这一视角, 我们首先给出最优竞争比上界 $\frac{\sqrt{5}-1}{2}$ 的一个更直观证明, 并明确区分单个输入上的利用率与算法在所有输入上的竞争比. 随后, 文中提出一个能够达到该竞争比的在线算法[a], 并对其正确性与时间复杂度进行分析. 最后, 我们使用离线动态规划最优解作为 Oracle 基准, 对不同参数和不同输入规模设置下的算法利用率进行了实验比较. 本文的重点是说明: 在单位价值在线背包模型中, $\frac{\sqrt{5}-1}{2}$ 是确定性在线算法所能保证的最优鲁棒性.

[a]代码仓库：https://github.com/Plusone-Shen/online-knapsack

1 引言

背包问题是组合优化领域的经典问题, 其核心任务是在容量有限的背包中选择若干物品, 使得目标收益最大. 该问题广泛应用于资源分配、投资组合以及货物装载等实际场景.

传统背包问题假设所有物品信息在决策前均已知, 因此可以一次性求得全局最优解. 然而在许多实际情境中, 物品是动态到达的, 决策者只能在观察到当前物品后立即决定是否接纳它, 并允许在必要时丢弃已经装入的物品, 这便形成了本文讨论的在线背包问题.

本文聚焦其一个简化但结构清晰的特例: 每件物品的单位价值均为 1, 等价地说, 每件物品的价值等于其重量, 即 $v_i = w_i$. 在这一设定下, 离线最优解与在线算法的收益都可以统一表示为最终装入背包的总重量, 因此我们关心的是在线算法在最坏输入下能够保证多少比例的装载效果, 也即算法的竞争比或鲁棒性. 从优化视角看, 这实际上对应一个典型的 minimax 问题: 算法设计者希望最大化算法在所有输入序列上的最低利用率.

本文的目标有两点. 其一, 我们重构最优竞争比上界 $\frac{\sqrt{5}-1}{2}$ 的证明, 使其更贴近在线算法的时间推进过程, 并避免不必要的概念混用. 其二, 我们分析一个能够达到该上界的阈值型在线算法, 说明其为何能够在所有输入序列上保证最差情形下的最优利用率. 实验部分则主要用于展示该鲁棒最优算法在随机输入上的利用率分布与参数敏感性.

2 相关工作

在线算法的竞争分析由 Sleator 和 Tarjan 首次提出 [1], 并已成为分析在线算法性能的标准工具. 背包问题的在线版本也在在线装箱、在线调度等多个变种中得到深入研究.

经典在线背包问题的研究主要集中于: (1) 构造对抗性输入以给出竞争比的上界; (2) 设计能够达到该上界的在线算法. 早期证明常依赖大量分类讨论, 使整体结构较为复杂. 近年来, 研究者尝试通过更统一的阈值策略或分段策略来简化分析思路.

作者信息: 2024 级少年班学院, 邮箱: liuhz0919@mail.ustc.edu.cn

稿件信息: 本稿件于 3 月 5 日来稿。稿件编辑：张汇泽

2.1 本文贡献

本文围绕单位价值在线背包的鲁棒性问题, 主要贡献如下:

- **提供更直观的最优竞争比上界证明.** 我们按照在线算法的决策顺序组织对抗性输入, 严谨证明任何确定性算法的竞争比都不能超过 $\frac{\sqrt{5}-1}{2}$, 并解释关键阈值的来源.
- **设计达到最优竞争比的在线算法.** 本文提出一个依赖简单区间划分与动态替换规则的结构化算法, 在单位价值情形下达到理论最优竞争比.
- **给出严格的正确性与性能分析.** 通过关键引理与摊还分析证明算法在所有输入下都满足所需的最差情形保证, 并进一步证明其总时间复杂度为 $O(n)$.
- **提供实验性的鲁棒性观察.** 我们使用离线动态规划最优解作为 Oracle, 比较不同参数与不同输入规模设置下算法的平均利用率与最小利用率, 以观察理论保证与实际表现之间的关系.

3 离线背包问题描述和解法

3.1 定义

为与后文在线问题保持一致, 本文离线部分也采用单位价值情形: 每件物品只有重量 w_i, 且其价值等于重量, 因此目标等价于在不超过容量 C 的前提下最大化被选中物品的总重量. 每件物品仍然只能被选择一次, 因此这是单位价值情形下的 0-1 背包问题.

形式化地, 令决策变量

$$x_i = \begin{cases} 1, & \text{若选择物品} i, \\ 0, & \text{否则}, \end{cases}$$

则问题可表示为如下的 0-1 整数规划:

$$\max \sum_{i=1}^{n} w_i x_i, \qquad \text{s.t.} \quad \sum_{i=1}^{n} w_i x_i \le C, \quad x_i \in \{0,1\}.$$

在这一特例中, 离线最优解的目标值不超过 C, 并将作为后文在线算法利用率与竞争比的 Oracle 基准. 当容量 C 不太大时, 可以使用伪多项式时间的动态规划算法求得最优解.

3.2 动态规划解法

动态规划 (DP) 是求解离线背包问题的经典方法, 关键思想是: 将问题分解为前 i 件物品、容量为 j 的子问题, 并利用其最优子结构与无后效性.

状态定义 令 $f[i][j]$ 表示在只允许使用前 i 件物品、背包容量为 j 时能获得的最大总重量.

状态转移 考虑第 i 件物品是否放入背包:

- 若不放入, 则总重量与前 $i-1$ 件物品相同, 即 $f[i-1][j]$;
- 若放入, 则前提是容量足够, 即 $j \ge w_i$, 总重量为 $f[i-1][j-w_i]+w_i$.

因此有状态转移方程:

$$f[i][j] = \max\big(f[i-1][j],\ f[i-1][j-w_i]+w_i\big).$$

初始条件

$$f[0][j] = 0, \quad 0 \le j \le C.$$

答案 最终答案为 $f[n][C]$.

时间复杂度 该算法需要填表大小为 $n \times C$ 的 DP 矩阵, 因此时间复杂度为 $O(nC)$. 在本文中, 它既是离线问题的标准解法, 也是实验部分计算 Oracle 的基准算法.

4 在线背包问题的解法

4.1 定义

定义 1 (在线背包问题). 给定常数 $C > 0$ 和 $n \in \mathbb{N}^*$. 商店连续 n 天提供商品, 第 i 天出现一件重量为 w_i 的商品, 且 $0 < w_i \le C$. 本文研究单位价值情形, 即每件商品的价值等于其重量, 因此算法收益即为最终背包内物品的总重量. 决策者有容量为 C 的背包, 每天依次:

1. 观察当前商品重量 w_i;
2. 可丢弃背包中任意已有商品 (不可恢复);
3. 决定是否将当前商品放入背包.

任意时刻背包中物品重量总和不得超过 C. 目标是设计在线策略, 使得对任意输入序列, 最终背包重量至少达到最优离线解的某个固定比例.

定义 2 (利用率). 对于输入序列 I 和在线算法 A, 记 $A(I)$ 为算法最终装入背包的总重量, 记 $\mathrm{OPT}(I)$ 为对应离线最优总重量. 定义算法 A 在输入 I 上的利用率为

$$\rho(A, I) = \frac{A(I)}{\mathrm{OPT}(I)}.$$

定义 3 (竞争比). 在线算法 A 的竞争比定义为其在所有输入上的最差利用率, 即

$$\mathrm{CR}(A) = \inf_I \rho(A, I).$$

若 $\mathrm{CR}(A) \ge k$, 则称算法 A 的竞争比至少为 k; 等价地说, 算法在最差情形下能够保证至少 k 的鲁棒性. 因而, 寻找最优竞争比本质上就是求解一个 *max-min* 意义下的鲁棒优化问题.

4.2 竞争比上界

定理 1 (竞争比上界). 任何在线算法的竞争比 k 都不能超过 $\frac{\sqrt{5}-1}{2}$.

证明. 假设存在竞争比 $k > \frac{\sqrt{5}-1}{2}$ 的在线算法. 我们构造如下对抗输入以导出矛盾.

取 $n = 3$, 令

$$a_1 = (1 - k)C + 2\delta,$$

其中 $\delta > 0$ 充分小, 并满足 $kC - 2\delta > 0$ 与 $2kC - 3\delta > C$. 下面按照物品到达的时间顺序构造对抗输入.

第一步: 给出 a_1. 若算法不选择 a_1, 则继续令

$$a_2 = a_3 = \frac{1}{10000} a_1.$$

此时在线算法最多获得

$$a_2 + a_3 = \frac{1}{5000} a_1,$$

而最优离线解可取得

$$a_1 + a_2 + a_3 = \frac{5001}{5000} a_1.$$

显然在线收益与离线收益之比趋向 0, 与竞争比 $k > 0$ 矛盾.

因此算法必须选择 a_1, 此后背包剩余容量为 $C - a_1 = kC - 2\delta$.

第二步：在算法已接受 a_1 的前提下，给出 $a_2 = kC - \delta$. 若算法保留 a_1 而拒绝用 a_2 替换它, 则令 a_3 为趋近于 0 的正数. 此时离线可取 $a_2 + a_3$, 在线可取 $a_1 + a_3$, 对应输入上的利用率为

$$\frac{(1-k)C + 2\delta + a_3}{kC - \delta + a_3}.$$

要使该比值不小于 k, 需满足

$$(k^2 + k - 1)C \le (2 + k)\delta + (1 - k)a_3.$$

当 $\delta, a_3 \to 0$ 时, 因 $k > \frac{\sqrt{5}-1}{2}$ 使得左端为正, 从而无法满足条件, 竞争比必然小于 k, 产生矛盾.

因此算法在第二步中必须放弃 a_1 并选择 a_2.

第三步：在算法已改为选择 a_2 的前提下，给出 $a_3 = kC - 2\delta$. 由于

$$a_2 + a_3 = 2kC - 3\delta > C,$$

在线算法最终最多只能保留其中一个, 故其收益至多为 $kC - \delta$. 另一方面,

$$a_1 + a_3 = (1 - k)C + 2\delta + kC - 2\delta = C,$$

因此离线算法可以同时选择 a_1 与 a_3, 获得收益 C. 于是该输入上的利用率至多为

$$\frac{kC - \delta}{C} = k - \frac{\delta}{C} < k,$$

再次产生矛盾.

综上, 无论算法如何选择, 都会违背假设的竞争比 k, 因此 k 不能超过 $\frac{\sqrt{5}-1}{2}$. □

注记 1. 上述构造的核心直觉是：对手先用 a_1 迫使算法占用一部分容量，再利用 a_2 和一个极小的扰动量制造“保留旧物品”与“替换为新物品”之间的冲突. 最难处理的输入并不是单个特别大的物品，而是那些恰好卡在容量边界附近、持续诱导算法更换决策的输入序列.

4.3 最优算法设计

将物品按重量划分为:

- 小物品 (Tiny) : $\mathcal{T} = \{i : \ w_i \le (1 - k)C\}$;
- 中等物品 (Medium) : $\mathcal{M} = \{i : \ (1 - k)C < w_i < kC\}$;
- 巨大物品 (Huge) : $\mathcal{H} = \{i : \ w_i \ge kC\}$.

记 $\mathcal{B} = \mathcal{T} \cup \mathcal{M} \cup \mathcal{H}$ 为背包中所有物品.

Algorithm 1: Robust-Optimal Online Knapsack Algorithm

Input: Capacity C, competitive ratio $k \le \frac{\sqrt{5}-1}{2}$
Output: Items in the bag
Initialize: $\mathcal{T}, \mathcal{M}, \mathcal{H} \leftarrow \emptyset$; total weights $\mathcal{W}_{\mathcal{T}}, \mathcal{W}_{\mathcal{M}}, \mathcal{W}_{\mathcal{H}} \leftarrow 0$;
Let $\mathcal{B} = \mathcal{T} \cup \mathcal{M} \cup \mathcal{H}$ and $\mathcal{W} = \mathcal{W}_{\mathcal{T}} + \mathcal{W}_{\mathcal{M}} + \mathcal{W}_{\mathcal{H}}$;
for *each item* i *with weight* w_i **do**
  if $\mathcal{W} \ge kC$ **then**
    if $\mathcal{W} + w_i \le C$ **then**
      $\mathcal{B} \leftarrow \mathcal{B} \cup \{i\}$ and $\mathcal{W} \leftarrow \mathcal{W} + w_i$;
    continue;
  if $w_i \ge kC$ **then**
    $\mathcal{B} \leftarrow \{i\}$ and $\mathcal{W} \leftarrow w_i$;
  else if $w_i \le (1-k)C$ **then**
    $\mathcal{T} \leftarrow \mathcal{T} \cup \{i\}$; $\mathcal{W}_{\mathcal{T}} \leftarrow \mathcal{W}_{\mathcal{T}} + w_i$;
  else if $\mathcal{M} = \emptyset$ **then**
    while $\mathcal{W} + w_i > C$ **do**
      Pick an arbitrary item a from $\mathcal{T}$;
      $\mathcal{T} \leftarrow \mathcal{T} \setminus \{a\}$; $\mathcal{W}_{\mathcal{T}} \leftarrow \mathcal{W}_{\mathcal{T}} - w_a$;
    end
    $\mathcal{M} \leftarrow \mathcal{M} \cup \{i\}$; $\mathcal{W}_{\mathcal{M}} \leftarrow w_i$;
  else if $w_i + \mathcal{W}_{\mathcal{M}} \le C$ **then**
    $\mathcal{M} \leftarrow \mathcal{M} \cup \{i\}$; $\mathcal{T} \leftarrow \emptyset$; $\mathcal{W}_{\mathcal{T}} \leftarrow 0$; $\mathcal{W}_{\mathcal{M}} \leftarrow \mathcal{W}_{\mathcal{M}} + w_i$;
  else if $w_i < \mathcal{W}_{\mathcal{M}}$ **then**
    $\mathcal{M} \leftarrow \{i\}$; $\mathcal{W}_{\mathcal{M}} \leftarrow w_i$;
  end
end
return $\mathcal{B}$;

为便于理解, Algorithm 1 的执行过程可以按如下流水线描述.

步骤 1: 阈值检查. 算法首先检查当前背包总重量 $\mathcal{W}$ 是否已经达到 kC. 若 $\mathcal{W} \ge kC$, 则算法转入一个基础贪心阶段: 只要当前物品仍能放入剩余容量, 就将其直接加入背包; 否则跳过该物品. 这一阶段只会增加最终装载重量, 不会降低已经建立的阈值保证, 因此它可以在不破坏竞争比下界的前提下改善算法的实际表现.

步骤 2: 处理巨大物品. 若当前物品满足 $w_i \ge kC$, 则算法立即仅保留该物品. 原因是单个巨大物品本身已经足以提供不低于 k 的利用率下界; 在此之后, 算法同样转入步骤 1 所述的基础贪心阶段, 用剩余容量继续接纳能够放入的后续物品.

步骤 3: 处理小物品. 若当前物品满足 $w_i \le (1-k)C$, 则算法在尚未达到阈值前持续接纳这类物品. 这样做法是贪心地接受小物品, 因为它们不会单独导致容量冲突, 且有助于逐步填充背包以接近 kC 的目标.

步骤 4: 处理中等物品时的条件分支. 当当前物品属于中等物品时, 算法按以下三种情形处理.

Case 1: 当前背包中尚无中等物品. 算法先删除若干小物品, 直到当前中等物品能够被装入, 然后将其作为背包中的第一个中等物品保留. 这里优先删除小物品, 是因为小物品只

承担 “过渡填充” 的作用, 而第一个中等物品对后续竞争比保证更关键.

Case 2: 当前背包中已有中等物品, 且新旧中等物品总重量不超过 C. 此时算法同时保留这些中等物品, 并清空所有小物品. 这样做的原因是: 一旦两个中等物品能够共存, 其总重量就足以直接将背包重量推进到阈值附近, 从而形成更稳定的最差情形保证.

Case 3: 当前背包中已有中等物品, 但新旧中等物品无法同时保留. 若当前到达的中等物品更轻, 则用它替换原有较重的中等物品; 否则保持原状. 这个分支的目的是始终维护一个 “更轻” 的中等物品配置, 以便为后续可能到达的第二个中等物品预留更多容量.

综上, 算法围绕 “尽快达到并稳定维持至少 kC 的总重量” 这一目标组织决策. 小物品用于填充空位, 中等物品是需要小心处理选择的, 巨大物品用于快速建立阈值保证; 一旦达到该阈值, 算法再切换到最简单的装得下就装的基础贪心阶段. 因此整个算法本质上是一种 “鲁棒阈值保证 + 阈值后基础贪心补强” 的混合策略.

定理 2. *Algorithm 1 实现了竞争比 $k = \frac{\sqrt{5}-1}{2}$.*

4.4 算法正确性分析

引理 1. *若在达到阈值 kC 之前存在中等物品到达, 则算法在进入阈值后的基础贪心阶段之前, 背包中至少保留一个中等物品.*

证明. 根据算法, 当出现第一个中等物品时, 它必被保留; 之后算法不会丢弃已有中等物品, 除非算法已经达到容量阈值 kC 并转入阈值后的基础贪心阶段. 故结论成立. □

引理 2. *若算法最终保留至少两个中等物品, 则算法的背包总重量严格大于 kC.*

证明. 设算法最终保留的两个中等物品中较轻的两个重量为 w_1, w_2. 由于它们最终能够同时保留在背包中, 必有

$$w_1 + w_2 \le C.$$

根据算法规则, 当第二个中等物品到达时, 若它与已有中等物品之和不超过 C, 算法会同时保留它们. 因此算法至少会保留这两个中等物品. 又因为每个中等物品都严格大于 $(1-k)C$, 故

$$w_1 + w_2 > 2(1-k)C > kC.$$

从而算法的背包总重量严格大于 kC. □

引理 3. *设算法在某一时刻首次达到阈值 $W \ge kC$, 并从该时刻起对后续物品执行 “装得下就装” 的基础贪心策略. 记达到阈值时背包中的总重量为 W_τ, 算法最终总重量为 W_{final}, 则有*

$$W_{\text{final}} \ge W_\tau.$$

特别地, 若达到阈值时已经证明 $W_\tau \ge k \cdot \mathrm{OPT}(I)$, 则最终仍有

$$W_{\text{final}} \ge k \cdot \mathrm{OPT}(I).$$

证明. 在达到阈值后的基础贪心阶段中, 算法对后续每件物品只可能执行两种操作: 若剩余容量足够则将其加入背包, 否则跳过该物品. 两种操作都不会删除已有物品, 因此背包总重量关于时间单调不减, 从而有 $W_{\text{final}} \ge W_\tau$. 第二个结论立即成立. □

引理 4. *若算法直到输入结束都未达到阈值 kC, 且最终保留一个中等物品与若干小物品, 则其最终利用率至少为 k.*

证明. 设算法最终保留的中等物品重量为 m, 所有最终保留的小物品总重量为 S. 由于算法直到结束都未达到阈值, 故

$$m + S < kC.$$

又因为该中等物品属于中等区间, 故

$$(1-k)C < m < kC.$$

下面说明此情形下算法从未删除过小物品. 反设在第一次装入某个中等物品 m' 时, 算法曾删除过一个最后被删除的小物品, 其重量记为 t. 在删除该物品之前, 背包总重量满足

$$W_{\text{before}} > C,$$

而删除后装入中等物品得到的新重量为

$$W_{\text{after}} = W_{\text{before}} - t.$$

由于 $t \le (1-k)C$, 可得

$$W_{\text{after}} > C - (1-k)C = kC.$$

这说明算法在该时刻已经达到阈值, 与假设矛盾. 故在当前情形下, 小物品从未被删除, 因而 S 恰好等于输入序列中所有小物品的总重量.

再说明离线最优解至多包含一个中等物品. 若存在两个中等物品 m_1, m_2 满足 $m_1 + m_2 \le C$, 则当较晚到达的那个中等物品出现时, 算法会触发 “同时保留两个中等物品” 的分支, 从而得到总重量

$$m_1 + m_2 > 2(1-k)C > kC,$$

再次与 “算法直到结束都未达到阈值” 矛盾. 因此, 任意两个中等物品都不能同时装入背包, 离线最优解至多选择其中一个.

最后说明算法保留的是所有出现过的中等物品中最轻的一个. 事实上, 当新的中等物品到达时, 若它更轻, 则算法会用它替换当前中等物品; 否则保持原状. 因此最终保留的中等物品 m 满足

$$m \le m'$$

对所有出现过的中等物品 m' 都成立.

设离线最优解所选的中等物品重量为 $m^\star$. 若离线最优解不选中等物品, 则其总收益至多为 S, 而算法收益为 $m + S > S$, 故此时利用率严格大于 1, 结论显然成立. 以下只需讨论 $m^\star > 0$ 的情形. 由上面的讨论, 离线最优解只能由一个中等物品与若干小物品构成, 且这些小物品都来自总重量为 S 的同一批小物品, 因此

$$\mathrm{OPT}(I) \le m^\star + S.$$

另一方面, 算法最终收益为 $m + S$, 且由 $m \le m^\star < kC$ 不能直接比较出所需结论; 这里利用的是: 若 $m^\star > m$, 则由算法最终保留最轻中等物品的性质, 有

$$\frac{m+S}{m^\star + S} \ge \frac{m}{m^\star}.$$

又由于

$$m > (1-k)C, \qquad m^\star < kC,$$

得到

$$\frac{m}{m^\star} > \frac{(1-k)C}{kC} = \frac{1-k}{k} = k,$$

其中使用了恒等式 $k^2 + k = 1$. 故

$$\rho(A, I) = \frac{m + S}{\mathrm{OPT}(I)} \geq \frac{m + S}{m^\star + S} \geq k.$$

命题得证. □

定理 2 的证明. 将整个运行过程分为两大情形讨论.

情形 A: 算法在某一时刻已经达到阈值 $W \geq kC$. 由于对任意输入序列都有 $\mathrm{OPT}(I) \leq C$, 故一旦达到该阈值, 就立刻有 $\rho(A, I) \geq \frac{kC}{C} = k$. 再由引理 3, 阈值后的基础贪心阶段不会降低这一保证, 因此最终利用率仍至少为 k.

情形 B: 算法直到输入结束都未达到阈值 $W \geq kC$. 我们证明这种情形不可能导致利用率低于 k.

B1. 输入中若出现巨大物品, 则算法在该物品到达时立即保留它, 从而背包总重量立刻达到至少 kC, 这与情形 B 矛盾. 故情形 B 中不可能出现巨大物品.

B2. 若输入中仅有小物品, 则算法始终接纳所有到达的小物品. 若某一时刻无法再接纳新的小物品, 则当前背包总重量必满足 $W > C - (1 - k)C = kC$, 这同样与情形 B 矛盾. 故在这种情况下, 算法实际上接纳了输入中的全部物品, 从而其最终收益等于离线最优值, 利用率为 1.

B3. 若输入中出现中等物品, 则由引理 1, 算法最终至少保留一个中等物品. 此时再分两种情况:

B3.1. 算法最终只保留一个中等物品与若干小物品. 由引理 4, 该情形下最终利用率至少为 k.

B3.2. 算法最终保留至少两个中等物品. 由引理 2, 算法的背包总重量严格大于 kC, 这与情形 B 矛盾.

综上, 算法在所有输入上的最终利用率都至少为 k, 故其竞争比至少为 $k = \frac{\sqrt{5}-1}{2}$. □

4.5 时间复杂度分析

除去处理中等物品时的删除操作, 算法对每个到达物品只执行常数次比较、分类和更新, 因此若忽略删除, 小于等于 n 次到达只会带来 $O(n)$ 的基本代价. 真正需要额外分析的是: 当一个中等物品到达且当前容量不足时, 算法可能在 while 循环中连续删除若干小物品.

为证明这一部分的总代价仍然是线性的, 我们采用摊还分析. 定义势能函数为

$$\Phi = \text{当前背包中的物品个数}.$$

记某一步操作的实际代价为 c, 摊还代价为 $\hat{c} = c + (\Phi_{\text{after}} - \Phi_{\text{before}})$. 下面分别讨论三类基本操作.

1. 加入操作 无论是加入小物品、加入中等物品, 还是在阈值后的基础贪心阶段加入新物品, 实际代价都可以记为常数 1. 同时, 加入一个物品会使势能增加 1, 即 $\Delta\Phi = +1$, 因此其摊还代价满足 $\hat{c} = 1 + 1 = 2$.

2. 删除操作 while 循环中每删除一个小物品, 实际代价也是常数 1, 但此时势能减少 1, 即 $\Delta\Phi = -1$, 故摊还代价为 $\hat{c} = 1 - 1 = 0$. 这说明 while 循环虽然在某一步中可能连续执行多次删除, 但这些删除的成本已经由先前的加入操作所积累的势能完全支付.

3. 中等物品替换操作 当算法用一个更轻的中等物品替换当前中等物品时, 背包中的物品个数不变, 因此 $\Delta\Phi = 0$. 该操作的实际代价为常数 1 , 从而 $\hat{c} = 1$.

由此可见, 每个物品至多经历一次加入, 而被删除的小物品也至多删除一次; 删除操作虽然可能集中出现, 但其总摊还成本为 0. 因此, 全部加入操作的总摊还代价不超过 $2n$, 全部中等物品替换操作的总摊还代价不超过 n, 从而整个算法的总摊还成本满足 $\hat{C} \le 3n = O(n)$. 由于势能函数始终非负, 实际总代价不超过总摊还代价加上初始势能与终止势能之差, 而这里初始势能为 0, 故算法的实际运行时间也为 $O(n)$.

定理 3. *Algorithm 1 的时间复杂度为* $O(n)$.

5 实验

我们从鲁棒性测试的角度检验本文方法. 具体而言, 我们设计了若干不同数据分布的输入, 考察算法在不同情形下的利用率, 并比较其与理论竞争比下界之间的差距, 从数值上验证该理论下界的鲁棒性与有效性. 其中, 离线算法使用前文介绍的动态规划方法, 在线算法使用本文证明有效的 Algorithm 1.

5.1 实验设置

我们将背包容量固定为 $C = 1000$, 并设计四类输入分布: (i) **小物品分布 (SD)** , 物品重量在 $[1, \lfloor (1-k)C \rfloor]$ 内均匀生成; (ii) **中等物品分布 (MD)** , 物品重量在 $[\lfloor (1-k)C \rfloor + 1, \lceil kC \rceil - 1]$ 内均匀生成; (iii) **小中混合分布 (SMD)** , 物品重量在 $[1, \lceil kC \rceil - 1]$ 内均匀生成, 即只包含小物品与中等物品; (iv) **全混合分布 (MIX)** , 物品重量在 $[1, 0.9C]$ 内均匀生成.

对每一类分布, 我们独立生成 1000 组测试数据. 每组数据持续随机生成物品, 直到物品总重量首次超过 $2C = 2000$ 为止, 以保证数据规模本身不会过小或者过大. 然后依次把这些物品输入在线算法和离线算法, 计算每组数据上的利用率 $\rho(A, I)$, 并统计四类分布下的最小利用率、5% 分位数利用率以及平均利用率, 以全面评估算法在不同输入结构下的表现.

5.2 结果与讨论

实验结果如表所示.

输入分布	最小利用率	5% 分位	平均利用率
SD	0.6965	0.8549	0.9512
MD	0.6770	0.8173	0.9362
SMD	0.6380	0.7545	0.9154
MIX	0.6246	0.7143	0.9085

表 5.1: 不同输入分布下算法利用率的鲁棒性实验

可以看到, 在四类分布下, 算法的最小利用率都稳定高于理论阈值 $k \approx 0.6180$. 其中, 全混合分布 MIX 的最小利用率为 0.6246, 已经非常接近理论下界; 小中混合分布 SMD 的最小利用率为 0.6380, 也处于较低水平. 相比之下, 小物品分布 SD 和中等物品分布 MD 的最小利用率分别为 0.6965 和 0.6770, 说明当输入结构更单一时, 算法的实际表现通常更稳定. 这说明算法的低端表现与理论竞争比是相符的. 另一方面, 各分布下的平均利用率都显著高于理论值, 表明该算法虽然是围绕最差情形保证设计的, 但在一般随机输入上也具有较好的经验表现.

总体来看, 这些实验结果与本文的理论分析是相符的: 在不同输入分布下, 算法的最低利用率始终稳定地接近理论竞争比, 这说明本文关注的最差情形保证不仅体现在证明中, 也

能够在数值实验中得到较为一致的体现.

6 总结与展望

本文研究了单位价值情形下的在线背包鲁棒性问题, 给出了最优竞争比上界 $\frac{\sqrt{5}-1}{2}$ 的一个更直观证明, 并分析了达到该上界的在线算法. 换言之, 本文刻画了这一 minimax 问题在单位价值情形下的最优鲁棒保证. 该算法结构清晰, 运行时间线性; 实验结果也表明, 其样本内最小利用率与理论保证相一致.

未来研究方向包括:

- 探索带价值、多背包或带随机顺序假设的在线背包问题;
- 在物品密度受限的情境下, 寻找更优阈值策略;
- 将本文方法推广到其他在线优化与选择类问题.

参考文献

[1] Daniel D. Sleator, Robert E. Tarjan. Amortized efficiency of list update and paging rules. *Communications of the ACM*, 28(2):202–208, 1985. https://doi.org/10.1145/2786.2793

蛙声一片

稻花香里说丰年，听取蛙声一片。

——《西江月·夜行黄沙道中》

双曲平面的一些几何性质

舒屹扬

摘 要

数千年来，数学家们一度认为 Euclid 几何是唯一正确的几何学. 但是无数数学家在证明第五公设如果一条线段与两条直线相交，在某一侧的内角之和小于两直角和，则这两条直线在不断延伸后，会在该侧相交的时候屡屡碰壁，于是数学家尝试采用反证法. 自然我们的假设是“过直线外一点，没有直线与已知直线平行”和“过直线外一点，有至少两条直线与已知直线平行”. 其中，Riemann 研究了前者的几何性质，现在叫做椭圆几何，而 Никола́й Ива́нович Лобаче́вский 研究了后者的几何性质，现在叫做双曲几何. 几乎同时，Gauss 和 Bolyai 都给出了完全一致的结论，然而 Gauss 惧怕它带来的“波希米亚人的叫喊”，而 Bolyai 因为 Gauss 告诉他自己早已得到相关成果而失望 [1].

不过，尽管数学家在 19 世纪初已经提出了这种观点，但毫无疑问，我们永远无法在一般的平面，配以我们熟悉的几何结构，得到双曲几何学的模型，其中，Beltrami 提出了伪球面模型，即 $(\operatorname{sech} t, t - \tanh t)$ 绕着 y 轴旋转一周得到的曲面；Klein 利用 Euclid 平面上面一个圆和内部的弦构造出了一个模型，同时他提出了前文所述的“双曲几何”和“椭圆几何”的名称；而 Poincaré 提出了另一种圆盘模型和我们将要提到的半平面模型. 至此，数学界才正式承认了双曲几何学作为一种几何学的“合法性”. 本文我们将会讨论 Poincaré 的半平面模型，并以此为基础研究双曲平面的一些几何性质.

1 双曲平面的 Poincaré 半平面模型

1.1 复数和复平面

定义 1.1

在 $\mathbb{R}^2$ 上定义加法和乘法

$$(a,b) +_{\mathbb{C}} (c,d) = (a+c, b+d),$$
$$(a,b) \times_{\mathbb{C}} (c,d) = (ac-bd, ad+bc)$$

之后，我们称这样得到的集合为 $\mathbb{C}$.

我们称 $\mathrm{i} = (0,1)$，这样 $\mathrm{i} \times_{\mathbb{C}} \mathrm{i} = (-1,0)$ 且 $(a,b) = a + b\mathrm{i}$.

我们容易证明限制在 $\mathbb{R}$ 上之后，这两个运算和实数的加法、乘法没有区别，不会引起混淆，所以之后我们不会再用 $+_{\mathbb{C}}$ 和 $\times_{\mathbb{C}}$ 这两个记号，而是统一采用 $+, \times$.

作者信息: 2025 级少年班学院, 邮箱: shuyiy@mail.ustc.edu.cn

稿件信息: 本稿件于 2 月 3 日来稿。稿件编辑：倪嘉晖，张玉诚

1.2 Poincaré 半平面模型

定义 1.2

我们称上半复平面为 $\mathbb{H}=\{(x,y):y>0\}$，在上面赋予度量

$$\mathrm{d}s^2=\frac{\mathrm{d}x^2+\mathrm{d}y^2}{y^2}$$

之后，得到的几何结构就是 Poincaré 的半平面模型.

下面我们将推导测地线方程和两点之间的距离公式.

定理 1.1

在 Poincaré 半平面模型当中，测地线只有两种：

- 垂直于 x 轴的射线 $z=x+\mathrm{i}t$，记作 l_x；
- 和 x 轴正交的半圆弧 $z=c+r\mathrm{e}^{\mathrm{i}\theta}$，其中 $\theta\in(0,\pi)$，记作 $l_{c,r}$.

证明 考虑平面曲线

$$\begin{cases}x=x(t),\\ y=y(t),\end{cases}\qquad t\in(t_1,t_2),$$

其长度为

$$d=\int_{t_1}^{t_2}\frac{(\mathrm{d}x/\mathrm{d}t)^2+(\mathrm{d}y/\mathrm{d}t)^2}{y^2}\mathrm{d}t.$$

注意到被积分式与 t 无关，这样，系统“能量”

$$H=\dot{x}\frac{\partial d}{\partial\dot{x}}+\dot{y}\frac{\partial d}{\partial\dot{y}}$$

守恒 [4]，化简可以得到

$$\frac{\dot{x}^2+\dot{y}^2}{y^2}=\text{const.}.$$

注意到，这个式子就是第一基本形式 $\mathrm{d}s^2$. 只要取 t 为自然坐标，这样

$$\dot{x}^2+\dot{y}^2=y^2.$$

又对 x 求变分可以得到 $\frac{\mathrm{d}}{\mathrm{d}t}\left(\frac{\dot{x}}{y^2}\right)=0$，从而 $\dot{x}=Ay^2$. 这样可以得到

$$\dot{y}=y\sqrt{1-A^2y^2}\implies\frac{\mathrm{d}y}{\mathrm{d}x}=\frac{\sqrt{1-A^2y^2}}{Ay}.$$

当 $A=0$ 的时候，不难得到 $\frac{\mathrm{d}x}{\mathrm{d}y}=0$，从而，$x$ 是一个定值，于是就能够得到射线 $x+\mathrm{i}t$.

当 $A\neq0$ 的时候，积分可以得到 $x=-\frac{\sqrt{1-A^2y^2}}{A}+C$，这样可以得到 $(x-C)^2+y^2=A^{-2}$，显然这是一个圆心在 $(C,0)$ 的圆，也就是 $z=C+\frac{1}{A}\mathrm{e}^{\mathrm{i}\theta}$.

综上，我们证明了这个定理. □

现在讨论两点之间的距离公式. 显然，对于同在一个射线上面的两个点 $z_1=x+t_1\mathrm{i},z_2=x+t_2\mathrm{i}$，容易得到

$$d=\int_{t_1}^{t_2}\left|\frac{\mathrm{d}y}{y}\right|=\left|\ln\left(\frac{t_1}{t_2}\right)\right|.$$

而对于一段圆弧上的两个点 θ_1 和 θ_2（以 θ 参数化），不难发现 $\mathrm{d}x^2+\mathrm{d}y^2=r^2\mathrm{d}\theta^2$，这样，$\mathrm{d}s=\frac{\mathrm{d}\theta}{\sin\theta}$. 从而

$$d=\int_{\theta_1}^{\theta_2}\frac{\mathrm{d}\theta}{\sin\theta}=\left|\ln\left(\frac{\tan\frac{\theta_1}{2}}{\tan\frac{\theta_2}{2}}\right)\right|.$$

这就得到了下面的定理：

定理 1.2

对于 Poincaré 半平面的两个点，它们的距离（即测地线段的长度）为

$$d=\begin{cases}\left|\ln\left(\frac{t_1}{t_2}\right)\right|, & z_1,z_2\in l_x;\\ \left|\ln\left(\frac{\tan\frac{\theta_1}{2}}{\tan\frac{\theta_2}{2}}\right)\right|, & z_1,z_2\in l_{c,r}.\end{cases}$$

后面我会用 $d(A,B)$ 表示两个点的双曲距离，而用 $|AB|$ 表示它们的 Euclid 距离. 对于线段而言，我会用 a 表示它的双曲长度，而用 $|a|$ 表示其 Euclid 长度.

另外应该注意，当其中一个点无限靠近 x 轴的时候，它们的距离就会变成无穷大，这样我们可以说，x 轴就是 Poincaré 模型当中的“无穷远直线”（[2]）.

现在我们证明这个距离的一个重要性质：

定理 1.3

点 $A(x_A,y_A),B(x_B,y_B)$ 之间的双曲距离和 Euclid 距离满足

$$\cosh d(A,B)=1+\frac{|AB|^2}{2y_Ay_B}.$$

证明 首先注意到，$\tan(\theta_X/2)=\sqrt{\frac{r-(x_X-c)}{r+(x_X-c)}}$，其中 $X\equiv A,B$. 从而，

$$\mathrm{e}^{d(A,B)}=\sqrt{\frac{r-(x_B-c)}{r+(x_B-c)}\cdot\frac{r+(x_A-c)}{r-(x_A-c)}}.$$

利用 $(x-c)^2+y^2=r^2$ 的条件，可以得到，$\frac{r-(x-c)}{r+(x-c)}=\frac{r^2-(x-c)^2}{[r+(x-c)]^2}=\frac{y^2}{[r+(x-c)]^2}$，这样可以化简得到

$$\mathrm{e}^{d(A,B)}=\frac{y_B}{y_A}\cdot\frac{r+(x_A-c)}{r+(x_B-c)},$$

代入 $c=\frac{1}{2}\left(x_A+x_B+\frac{y_B^2-y_A^2}{x_B-x_A}\right)$ 以及 $r^2=\frac{[(x_A-x_B)^2+(y_A+y_B)^2]\cdot[(x_A-x_B)^2+(y_A-y_B)^2]}{4(x_A-x_B)^2}$ 可以得到

$$\mathrm{e}^{d(A,B)}=\frac{(x_A-x_B)^2+(y_A+y_B)^2+\sqrt{[(x_A-x_B)^2+(y_A+y_B)^2]\cdot[(x_A-x_B)^2+(y_A-y_B)^2]}}{2y_Ay_B}.$$

这样就能证明

$$\cosh d(A,B)=1+\frac{|AB|^2}{2y_Ay_B}.$$ □

考虑令 $\omega_1=\mathrm{d}x/y,\omega_2=\mathrm{d}y/y$，现在我们求这上面的联络. 首先，$\mathrm{d}\omega_1=\mathrm{d}x\wedge\mathrm{d}y/y^2,\mathrm{d}\omega_2=0$，假设 $\omega_2^1=a\omega_1+b\omega_2$，那么，

$$\begin{cases}\mathrm{d}\omega_1+\omega_2^1\wedge\omega_2=0 & \Longrightarrow\ a=-1;\\ \mathrm{d}\omega_2+\omega_1^2\wedge\omega_1=0 & \Longrightarrow\ b=0,\end{cases}$$

从而 $\omega_2^1 = -\omega_1$，这样它的 Gauss 曲率就是

$$K = \frac{\mathrm{d}\omega_2^1}{\omega_1 \wedge \omega_2} = -1.$$

2 该模型和 Hilbert 公理的兼容性

2.1 和关联公理 I.1–I.3 的兼容性

首先我们回顾一下关联公理：

公理

I.1 任意两点 A, B，都存在一条经过这两个点的直线 a；
I.2 任意两点 A, B，至多存在一条直线经过这两个点；
I.3 每条直线至少有两个点，至少存在一组三个点不共线.

现在我们逐一证明：

与公理 I.1 的兼容性 如果两个点 z_1, z_2 的实部相等，都是 x_0，那么测地线 l_{x_0} 满足条件；而如果两个点实部不相等，那么取

$$c = \frac{1}{2}\left(x_1 + x_2 + \frac{y_1^2 - y_2^2}{x_1 - x_2}\right), \quad r = \sqrt{(x_1 - c)^2 + y_1^2}$$

得到的 $l_{c,r}$ 就能够满足条件了. 从而公理 I.1 成立.

与公理 I.2 的兼容性 不难看出，对于实部相等的两个复数 z_1, z_2，显然只会存在一个射线 l_{x_0}，而显然不存在一个经过这两个点且与 x 轴正交的圆；而对于实部不相等的复数，显然没有满足条件的射线，并且满足 $|c - z_1| = |c - z_2|$ 的点 $c \in \mathbb{R}$ 显然只会存在唯一一个（就是 x 轴和中垂线的交点）. 这样我们就证明了公理 I.2 成立.

与公理 I.3 的兼容性 毫无疑问，任何一条直线上都有无穷多个点，并且点 $0, \mathrm{i}, 1$ 一定不共线，这是因为连接 $0, \mathrm{i}$ 的是测地线 l_0，而连接 $0, 1$ 的是测地线 $l_{1/2,1/2}$. 根据公理 I.2，显然连接两点的直线是唯一的. 从而我们证明了公理 I.3 成立.

综上，我们有：

定理 2.1

如上所述定义的双曲平面满足关联公理 I.1-I.3.

2.2 和顺序公理 II.1–II.4 的兼容性

为了研究顺序公理，我们必须得先定义 z_2 在 z_1, z_3 之间的概念.

定义 2.1

称共线的三个点 z_1, z_2, z_3 满足 z_2 在 z_1 和 z_3 之间，如果

- 它们在某个 l_x 上面且参数化得到的 t_1, t_2, t_3 满足 t_2 在 t_1, t_3 之间；
- 它们在某个 $l_{c,r}$ 上且参数化得到的 $\theta_1, \theta_2, \theta_3$ 满足 θ_2 在 θ_1 和 θ_3 之间.

我们回顾顺序公理：

公理

II.1 如果 A 在 B, C 之间，那么 A 也在 C, B 之间；
II.2 对于任何两个点 A, C，一定可以找到一个点 B 在 A, C 之间；
II.3 一条直线上不同的三个点当中，至多有一个点在另外两个之间；
II.4 对于平面上不共线的三点 A, B, C，如果不经过 A, B, C 当中任何一个的直线 a 和 BC 有公共点，那么它和 AB, AC 至少一个也有公共点.

与公理 II.1-II.3 的兼容性 显然，利用实数集合的序的性质就能够得到.

与公理 II.4 的兼容性 首先我们声明一点，即任何两个测地线都不可能相切. 这是因为，根据定义域来看，它们都不定义在 x 轴上，这样也就没有办法相切了. 并且，任何两条测地线都至多有一个交点，因为显然，在整个 $\mathbb{C}$ 上有两个交点，但是其中一个位于下半平面，仅有一个在 $\mathbb{H}$ 上。容易看出，双曲三角形 ABC 在 $\mathbb{R}^2$ 上也是一个闭曲线，利用 Jordan 曲线定理，一定存在一个 a 上面的点 Q 位于这个双曲三角形内部. 考虑另外两个点 P, R 它们在三角形外面但是 Q 在 P, R 之间. 注意到 $\mathbb{H}$ 上的直线和圆都是连续的，这样一定可以找到 PQ 和 QR 和三角形的边的交点，从而它和三角形的边有两个交点. 前面已经论证了，直线 a 和 BC 至多有一个交点，这样另一个交点一定在 AB 和 AC 上，这就证明了公理 II.4.

综上，我们有：

定理 2.2

如上所述定义的双曲平面满足顺序公理 II.1-II.4.

2.3 和合同公理 III.1–III.5 的兼容性

首先我们定义：

定义 2.2

对于两个线段 AB 和 $A'B'$，称 $AB \simeq A'B'$ 当且仅当 $d(A, B) = d(A', B')$.

我们先回忆线段合同公理：

公理

III.1 给定线段 AB 和一个点 A'，给定一个从 A' 出发的射线 a，这上面存在唯一一个点 B' 满足 $AB \simeq A'B'$；
III.2 线段的合同是等价关系；
III.3 若点 C 在 A, B 之间，C' 在 A' 和 B' 之间，且 $AC \simeq A'C'$，$BC \simeq B'C'$，那么 $AB \simeq A'B'$.

与公理 III.1 的兼容性 我们只需要令

$$t_{B'} = \mathrm{e}^{d(A,B)\pm\ln(t_{A'})} \quad \text{或} \quad \theta_{B'} = 2\arctan\left(\mathrm{e}^{d(A,B)\pm\ln(\tan(\theta_{A'})/2)}\right)$$

即可. 注意这里的正负具体需要根据这个射线 a 的方向来决定. 从函数来看，距离函数伴随着参数 $t(\theta)$ 是单调递增的并且逐步从 0 跑到 $+\infty$，这个性质也带来了存在性和唯一性的另一种证明.

与公理 III.2 的兼容性 这等价于实数相等是一个等价关系，这是显然的.

与公理 III.3 的兼容性 只需要证明线段的可加性就行了，我们以 $l_{c,r}$ 为例，根据定义，$d(A,C)=d(A',C'),d(B,C)=d(B',C')$，

$$d(A,B)=\left|\ln\left(\frac{\tan\frac{\theta_A}{2}}{\tan\frac{\theta_B}{2}}\right)\right|=\left|\ln\left(\frac{\tan\frac{\theta_A}{2}}{\tan\frac{\theta_C}{2}}\right)\right|+\left|\ln\left(\frac{\tan\frac{\theta_C}{2}}{\tan\frac{\theta_B}{2}}\right)\right|=d(A,C)+d(C,B),$$

同样地，$d(A',B')=d(A',C')+d(C',B')$，这样，$d(A',B')=d(A,B)$，即 $AB\simeq A'B'$.

接下来我们定义角度和角度的合同：

定义 2.3

对于两个交于 P 点的射线 h,k，定义它们的夹角为

$$\angle(h,k)=\angle(T_Ph,T_Pk),$$

其中 T_Ph 和 T_Pk 指的是在 P 处和两个射线同向相切的 Euclid 射线.
称 $\angle(h,k)\simeq\angle(h',k')$ 如果 $\angle(h,k)=\angle(h',k')$.

我们回顾角的合同公理：

公理

III.4 给定角 $\angle(h,k)$ 和从 O' 出发的射线 h'，给定一个 h' 分出的半平面，一定存在唯一一个从 O' 出发的射线 k' 满足 $\angle(h',k')\simeq\angle(h,k)$.
III.5 如果三角形 ABC 和 $A'B'C'$ 满足 $AB\simeq A'B'$，$AC\simeq A'C'$，$\angle(AB,AC)\simeq\angle(A'B',A'C')$，那么 $\angle(B'A',B'C')\simeq\angle(BA,BC)$.

与公理 III.4 的兼容性 首先我们指出，一旦给定了点 P 和 T_Ph，那么直线 h 一定唯一确定，这是因为如果 T_Ph 垂直于 x 轴，那么 $h=T_Ph$ 是唯一确定的；而如果不满足，那么显然，只需要沿着 P 做出 T_Ph 的垂线，和 x 轴有一个交点 Q，那么 $l_{Q,|PQ|}$ 是唯一满足的双曲直线. 首先在 Euclid 平面上使用公理 III.4，便可得到 $T_{O'}k'$ 了，再利用上面的论证，不难发现 k' 是唯一存在的.

与公理 III.5 的兼容性 利用 4.2 的余弦定理和正弦定理可以证明这一点，我们留到后面补证.

综上，我们有：

定理 2.3

如上所述定义的双曲平面满足合同公理 III.1-III.5.

2.4 和平行公理 IV 不兼容性的例子

对于直线 l_{x_*} 和点 $A(x_0,y_0)$，如果取 $(x-c)^2+y^2=(x_0-c)^2+y_0^2$ 满足和直线 $x=x_*$ 没有交点即可，不难发现，只要取 $c<\frac{x_*^2-y_0^2-x_0^2}{2x_*-2x_0}$ 就满足条件了；

对于直线 $l_{c,r}$ 和点 $A(x_0,y_0)$，构造双曲直线 $l_{a,\sqrt{(x_0-a)^2+y_0^2}}$，其中满足

$$\sqrt{(x_0-a)^2+y_0^2}+r<|a-c|\quad\text{或}\quad\left|\sqrt{(x_0-a)^2+y_0^2}-r\right|\geq|a-c|$$

即可.

不过，在一些数学教材当中，例如 [2]，提出只有两者相切于 x 轴上才算是平行，其他的只是不相交的观点（因为这个观点和射影几何更为符合一些），那么在这个意义下，就应该说，过直线外一点有两个平行于该直线的直线，但存在无穷多不相交的直线. 不过无论如何，都应该承认，平行公理 IV 不再成立了.

综上，我们发现，双曲平面就是把 Hilbert 公理当中的平行公理改成“过直线外一点存在无穷多个不相交的直线”所得到的几何学.

3 双曲平面的一些变换群

3.1 双曲平面和 2 级特殊线性群的关系

首先回忆 2 级特殊线性群为

$$\mathbf{SL}(2) = \{g \in \mathbf{M}_2 : \det g = 1\}.$$

然后，对于任何一个 $g = \begin{pmatrix} a & b \\ c & d \end{pmatrix} \in \mathbf{SL}(2)$，定义映射

$$M_g : \mathbb{C} \to \mathbb{C}, \quad z \rightsquigarrow \frac{az+b}{cz+d},$$

首先我们证明：

定理 3.1

这样定义的映射 M_g 具有如下性质：

- M_g 会把 $\mathbb{H}$ 打到 $\mathbb{H}$ 自己；
- 对于 $g_1, g_2 \in \mathbf{SL}(2)$，一定有

$$M_{g_1} \circ M_{g_2} = M_{g_1 g_2}.$$

证明 给出一个 $g \in \mathbf{SL}(2)$，可以写出

$$\operatorname{Im}\frac{az+b}{cz+d} = \frac{1}{|cz+d|^2}\operatorname{Im}((az+b)(c\bar{z}+d)) = \frac{(ad-bc)y}{|cz+d|^2} > 0,$$

这就意味着，M_g 把 $\mathbb{H}$ 打到自身. 进一步，直接计算可以得到，

$$g_1 = \begin{pmatrix} a_1 & b_1 \\ c_1 & d_1 \end{pmatrix} \quad \text{和} \quad g_2 = \begin{pmatrix} a_2 & b_2 \\ c_2 & d_2 \end{pmatrix},$$

它们对应的映射可以写成

$$\frac{a_1\frac{a_2z+b_2}{c_2z+d_2} + b_1}{c_1\frac{a_2z+b_2}{c_2z+d_2} + d_1} = \frac{(a_1a_2+b_1c_2)z + (a_1b_2+b_1d_2)}{(c_1a_2+d_1c_2)z + (c_1b_2+d_1d_2)},$$

这恰好是

$$g_1g_2 = \begin{pmatrix} a_1a_2+b_1c_2 & a_1b_2+b_1d_2 \\ c_1a_2+d_1c_2 & c_1b_2+d_1d_2 \end{pmatrix}$$

对应的映射. □

3.2 双曲平面和 2 级特殊射影线性群的关系

我们发现，由于 2 是一个偶数，那么

$$\det(gI_2) = \det(g(-I_2)) = \det g = 1,$$

这样，我们可以考虑

$$\mathbf{PSL}(2) = \mathbf{SL}(2)/(\pm I_2),$$

即我们把 g 和 $-g$“等同起来”得到的一个群. 我们将要证明：

定理 3.2

PSL(2) 会保持双曲平面的交比，测地线，距离，角度，面积.

证明 首先我们只需要验证距离，这样测地线，角度，面积都会自动保证（由等距变换保证）. 我们从第一基本形式出发，从复数的角度，我们可以写 $\mathrm{d}s^2 = \mathrm{d}z\mathrm{d}\bar{z}/(\mathrm{Im}(z))^2$. 我们用 $\tilde{z}$ 表示 $M_g(z)$，那么根据定义，

$$\mathrm{d}\tilde{z}\mathrm{d}\bar{\tilde{z}} = \frac{\mathrm{d}z\mathrm{d}\bar{z}}{(cz+d)^2(c\bar{z}+d)^2},$$

而我们应该发现，

$$\mathrm{Im}(\tilde{z}) = \frac{1}{2\mathrm{i}}(\tilde{z} - \bar{\tilde{z}}) = \frac{\mathrm{Im}(z)}{(cz+d)(c\bar{z}+d)}.$$

这样我们就会发现，$\mathrm{d}s^2 = \mathrm{d}\tilde{s}^2$，从而第一基本形式保持不变，换言之这是一个等距变换. 这样，距离，测地线，角度，面积都保持不变.

对于交比，其实只需要发现

$$\frac{\tilde{z}_1 - \tilde{z}_3}{\tilde{z}_1 - \tilde{z}_4} = \frac{\frac{az_1+b}{cz_1+d} - \frac{az_3+b}{cz_3+d}}{\frac{az_1+b}{cz_1+d} - \frac{az_4+b}{cz_4+d}} = \frac{z_1 - z_3}{z_1 - z_4} \cdot \frac{cz_4+d}{cz_3+d},$$

注意到后面那个式子和 z_1, z_2 无关，这样一定交比不变. □

接下来我们自然要问，在双曲平面上，如果一个映射 φ 保持长度，这样的映射会构成什么样的一个群呢？答案是，$\mathbf{PSL}(2) \rtimes \mathbb{Z}_2$. 几何上来说，后面那个 $\mathbb{Z}_2$ 表示的就是是否会发生一个对称变换（参见定理4.3），因此我们现在将要证明：

定理 3.3

对于双曲平面而言，保持定向的等距群就是 **PSL**(2).

证明 根据复分析的结果，保持直线和广义圆的只有 $f(z) = (az+b)/(cz+d)$ 这种形式的. 然而，我们会发现，如果只是考虑这个映射的作用，那么我们应该发现，$\begin{pmatrix} a & b \\ c & d \end{pmatrix}$ 和 $\begin{pmatrix} ka & kb \\ kc & kd \end{pmatrix}$ 的作用完全一致，从而我们可以直接把这个矩阵放在 $\mathbf{GL}(2)/(I_2\mathbb{Z})$ 也就是 **PSL**(2) 上面去，而利用定理3.2，很容易发现等距群就是 **SL**(2). □

4 双曲平面上的三角形

4.1 三角形的内角和与面积

我们先研究三角形的内角和. 我们先用初等方法给出下面定理的证明.

定理 4.1

对于双曲三角形而言，一定有

$$A + B + C < \pi$$

成立.

证明 考虑三角形的 KIJ 的 Euclid 内角和和双曲内角和，它们之间满足

$$S_{\text{hyper}} = S_{\text{Euclid}} - \angle ICJ - \angle IGK + \angle JEK,$$

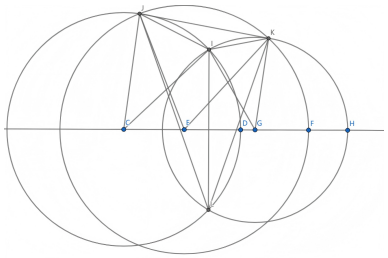

根据这个图形，不难发现 $\angle ICJ + \angle IGK = 2(\angle ILJ + \angle ILK) = 2\angle JLK > \angle JEK$，最后一步是因为 E 在圆内，且不在圆心处. 这就证明了

$$S_{\text{hyper}} < S_{\text{Euclid}} = \pi.$$ □

现在我们定义面积，我们熟知，球面三角形的面积等于 $A + B + C - \pi$，所以这里我们定义：

定义 4.1

对于三角形 A, B, C 而言，定义

$$\mathcal{A}_{ABC} = \pi - (A + B + C).$$

容易验证：

定理 4.2

对于三角形 ABC 和 BC 边上一个点 D，

$$\mathcal{A}_{ABC} = \mathcal{A}_{ABD} + \mathcal{A}_{ACD}$$

一定成立.

证明 只需要利用 $\angle ADB + \angle ADC = \pi$ 即可. □

这样，我们定义了双曲平面上面的面积和角度. 不过自然要问，此前我们定义了这上面的第一基本形式，这两者是否兼容呢？答案是肯定的. 现在我们就来证明，这样定义出来的面积和角度和第一基本形式决定的面积和角度是完全一致的.

定理 4.3

在上半复平面上面，由第一基本形式 $\mathrm{d}s^2 = (\mathrm{d}x^2 + \mathrm{d}y^2)/y^2$ 定义的几何结构上自然赋予的角度和面积概念与前文定义的相同.

证明 只要注意到，对于平面上两个向量 $\boldsymbol{u}=(u^1,u^2),\boldsymbol{v}=(v^1,v^2)$，就可以得到，

$$\begin{aligned}\cos\angle(\boldsymbol{u},\boldsymbol{v})_{\text{hyper}}&=\frac{<\boldsymbol{u},\boldsymbol{v}>_{\text{hyper}}}{|\boldsymbol{u}|_{\text{hyper}}|\boldsymbol{v}|_{\text{hyper}}}=\frac{(u^1v^1+u^2v^2)/y^2}{\frac{\sqrt{(u^1)^2+(u^2)^2}}{y}\cdot\frac{\sqrt{(v^1)^2+(v^2)^2}}{y}}\\&=\frac{u^1v^1+u^2v^2}{\sqrt{(u^1)^2+(u^2)^2}\cdot\sqrt{(v^1)^2+(v^2)^2}}=\cos\angle(\boldsymbol{u},\boldsymbol{v})_{\text{Euclid}},\end{aligned}$$

这就证明了角度定义是符合的.

对于面积而言，注意到 $K=-1$，然后只需要利用 Chern-Gauss-Bonnet 定理就可以证明了. □

4.2 正弦定理和余弦定理

我们首先给出正弦定理和余弦定理的形式：

定理 4.4

在双曲平面上，三角形的边和角满足：

- 正弦定理：
$$\frac{\sinh a}{\sin A}=\frac{\sinh b}{\sin B}=\frac{\sinh c}{\sin C}.$$
- 余弦定理：
$$\cosh c=\cosh a\cosh b-\sinh a\sinh b\cos C.$$

证明 我们以三个边都是圆来证明，设 $a=l_{x_a,r_a},b=l_{x_b,r_b},c=l_{x_c,r_c}$，这样，根据定义，

$$\cos A=\pm\frac{(x_A-x_b)(x_A-x_c)+y_A^2}{r_br_c}.$$

不难得出，

$$\begin{aligned}r_c^2=(x_A-x_c)^2+y_A^2&=\frac{[(x_A-x_B)^2+y_B^2-y_A^2]^2+4y_A^2(x_A-x_B)^2}{4(x_A-x_B)^2}\\&=\frac{[|c|^2+2y_A(y_B-y_A)]^2+4y_A^2(x_A-x_B)^2}{4(x_A-x_B)^2}=\frac{|c|^2(|c|^2+4y_Ay_B)}{4(x_A-x_B)^2}.\end{aligned}$$

另一方面可以得到，

$$\sinh^2c=\cosh^2c-1=\left(1+\frac{|c|^2}{2y_Ay_B}\right)^2-1\implies\frac{y_Ay_B}{|x_A-x_B|}\sinh c=r_c.$$

同时我们还能得到 $x_A-x_c=\frac{1}{2}\left(x_A-x_B-\frac{y_A^2-y_B^2}{x_A-x_B}\right)=\frac{y_Ay_B}{x_A-x_B}\cosh c-\frac{y_A^2}{x_A-x_B}$，从而，

$$\begin{aligned}\cos A&=\frac{(y_B^2-y_A^2)}{2y_Ay_B}\cdot\frac{\cosh b-\frac{y_A}{y_C}}{\sinh b\sinh c}\\&=\frac{\left(\cosh c-\frac{y_A}{y_B}\right)\left(\cosh b-\frac{y_A}{y_C}\right)}{\sinh b\sinh c}\\&=\frac{\cosh b\cosh c-\frac{y_A}{y_B}\cosh b-\frac{y_A}{y_C}\cosh c+\frac{y_A^2}{y_By_C}}{\sinh b\sinh c}.\end{aligned}$$

而我们还可以注意到，

$$\frac{y_A}{y_B}\cosh b+\frac{y_A}{y_C}\cosh c-\frac{y_A^2}{y_By_C}=\frac{(x_C-x_B)^2+(y_C-y_B)^2+2y_By_C}{2y_By_C}=\cosh a,$$

从而我们就有 $\cos A = \frac{\cosh b \cosh c - \cosh a}{\sinh b \sinh c}$，也就证明了余弦定理.

进而，容易得到

$$\sin A = \frac{\sqrt{1 + 2\cosh a \cosh b \cosh c - \cosh^2 a - \cosh^2 b - \cosh^2 c}}{\sinh b \sinh c}$$
$$\Longrightarrow \frac{\sinh a}{\sin A} = \frac{\sinh a \sinh b \sinh c}{\sqrt{1 + 2\cosh a \cosh b \cosh c - \cosh^2 a - \cosh^2 b - \cosh^2 c}}$$

是一个对称式，从而正弦定理得证. □

作为推论，不难看出对于两个双曲三角形 ABC 和 $A'B'C'$ 而言，一旦 $AB = A'B', AC = A'C', \angle BAC = \angle B'A'C'$，那么利用余弦定理得到

$$\cosh c = \cosh a \cosh b - \sinh a \sinh b \cos C = \cosh a' \cosh b' - \sinh a' \sinh b' \cos C' = \cosh c'.$$

由于 cosh 在 $x > 0$ 的地方是单调递增函数，从而必须有 $c = c'$. 这就证明了 Hilbert 公理 III.5.

4.3 双曲平面上的 Pappus 定理和 Desargues 定理

同理，以下我们只考虑所有直线都理解成为半圆的情形. 首先，我们回忆一般平面上面 Pappus 定理的证明. 值得注意的一点是，双曲平面没有射影几何结构，所以我们只能利用面积，长度等 Euclid 几何的内容来证明这个问题.

定理 4.5

对于直线 l_1, l_2，上面分别有三个点 $A, B, C; D, E, F$，那么点 $G = AE \cap BD, H = AF \cap CD, I = BF \cap CE$，这三个共线.

证明（在 Euclid 平面上） 考虑设 $I_1 = AF \cap GI, I_2 = CD \cap GI$. 这样，就能得到

$$\frac{GI_1}{I_1H} = \frac{\mathcal{S}_{AGI_1}}{\mathcal{S}_{AHI_1}} = \frac{\mathcal{S}_{FGI_1}}{\mathcal{S}_{FHI_1}} \Longrightarrow \frac{GI_1}{I_1H} = \frac{\mathcal{S}_{AGF}}{\mathcal{S}_{AHF}}.$$

同理可以得到

$$\frac{HI_2}{I_2G} = \frac{\mathcal{S}_{CDH}}{\mathcal{S}_{CGD}},$$

现在只要证明右边两个面积比例相等，不难发现，

$$\begin{aligned}\frac{\mathcal{S}_{AGF}}{\mathcal{S}_{AHF}} \cdot \frac{\mathcal{S}_{CGD}}{\mathcal{S}_{CDH}} &= \frac{\mathcal{S}_{AGF}}{\mathcal{S}_{ADG}} \frac{\mathcal{S}_{CHF}}{\mathcal{S}_{AHF}} \frac{\mathcal{S}_{CDH}}{\mathcal{S}_{CHF}} \frac{\mathcal{S}_{ADG}}{\mathcal{S}_{CDG}} \\ &= \frac{EF}{DE} \frac{BC}{AB} \frac{DE}{EF} \frac{AB}{BC} = 1,\end{aligned}$$

从而就证明了 $I_1 = I_2$，也就是 I，即证. □

仔细考察这个证明，为了把它推广到双曲平面上去，我们需要的就是最后一步那个所谓*共边比例定理*，所以我们只需要把它推广到双曲平面上即可！

定理 4.6

在双曲平面上，给定一个三角形 ABC 和 BC 边上一点 D，一定有

$$\frac{\mathcal{A}_{ABD}}{\mathcal{A}_{CBD}} = \frac{d(B, D)}{d(C, D)},$$

其中 $\mathcal{A}$ 表示的是其双曲面积.

首先，我们证明*双曲平面上，存在对称变换*. 为此，我们指出：

定理 4.7

在双曲平面上，对于一个直线 l 和一个点 P，设 PQ_0 这个测地线和 l 正交，那么

$$\min_{Q\in l} d(P,Q) = d(P,Q_0).$$

证明 利用 §3 的结论，我们可以直接把 l 打到 $x=0$ 这个射线上去，假设这个点是 $P(a,b)$. 进而，利用前面证明的 $\cosh d(P,Q) = 1 + \frac{|PQ|^2}{2y_P y_Q}$ 可知，我们只需要最小化

$$f(Y) = \frac{a^2 + (Y-b)^2}{2bY}$$

即可，利用基本不等式，

$$f(Y) = \frac{Y^2 + (a^2+b^2) - 2bY}{2bY} \geq \frac{2\sqrt{a^2+b^2}Y - 2bY}{2bY},$$

从而可以知道，当且仅当 $Y = \sqrt{a^2+b^2}$ 的时候，取到最小值，不难验证，这个时候半圆和直线 $x=0$ 正交，这就证明了命题. □

进而我们对于每个直线 l 构造对称变换：

定理 4.8

对于每个测地线 l，存在一个 $\pi_l : \mathbb{H} \to \mathbb{H}$ 满足：对于任何一个点 A，一定有 $A\pi_l(A)$ 垂直 l 于 O 点且 $d(A,O) = d(\pi_l(A),O)$.

证明 根据 Poincaré 半平面模型中测地线的分类，我们分别构造如下反射变换：

1. 当 l 为垂直于实轴的直线 $l_x : x = x_0$ 时：定义反射变换 $\pi_{l_x}(z) = 2x_0 - \bar{z}$. 对于任意点 $A(x_A, y_A)$，其关于 l_x 的垂足为 $O(x_0, y_A)$. 显然 $\pi_{l_x}(A) = (2x_0 - x_A, y_A)$. 由于 (x_A, y_A) 与 $(2x_0 - x_A, y_A)$ 关于 $x = x_0$ 对称，且在 $x = x_0$ 竖直线上度量 $ds^2 = dy^2/y^2$ 与 x 无关，易证 $d(A,O) = d(\pi_{l_x}(A), O)$.

2. 当 l 为圆心在 $(c,0)$ 半径为 r 的半圆弧 $l_{c,r} : (x-c)^2 + y^2 = r^2$ 时：定义反射变换为关于该圆的反演变换：$\pi_{l_{c,r}}(z) = c + \frac{r^2}{\bar{z}-c}$. 该变换将圆周 $l_{c,r}$ 上的点映射到自身. 对于圆周外的点 A，连接 A 与圆心 $(c,0)$ 的直线即为过 A 且与 $l_{c,r}$ 正交的测地线，垂足 O 位于该射线上. 根据反演的几何性质，反演变换保持圆周正交性，且容易验证其保持双曲度量 $\mathrm{d}s^2 = \frac{\mathrm{d}x^2+\mathrm{d}y^2}{y^2}$ 不变，即 $\pi_{l_{c,r}}$ 是等距变换.

不难看出，对于上述两种情况，通过直接计算拉回度量，均可得到 $\pi_l^*(\mathrm{d}s^2) = \mathrm{d}s^2$. 这意味着对于 $\mathbb{H}$ 中任意两点 X, Y，均有 $d(\pi_l(X), \pi_l(Y)) = d(X,Y)$. □

定理 4.6 的证明 我们分成三步解决，主要采用的是二进制有理逼近的思想.

Step 1 如果 D 是 BC 的中点，那么命题成立. 事实上，考虑对测地线 AD 进行对称变换，那么 $\pi_{AD}(B) = C$，这样不难发现

$$\frac{\mathcal{A}_{ABD}}{\mathcal{A}_{CBD}} = 1 = \frac{d(B,D)}{d(C,D)};$$

Step 2 接下来，我们用归纳法证明，如果点 D 是 BC 的某一个靠近 B 的 ε 等分点，其中，ε 是一个 n 位二进制小数，那么 $\mathcal{A}_{ABD} = \varepsilon \cdot \mathcal{A}_{ABC}$ 成立.

首先，当 $n=1$ 的时候已经证明完毕了. 假设 $n-1$ 位的时候始终成立，那么考虑 $\varepsilon = \sum_{i=1}^{n} a_i 2^{-i}$，其中 $a_i = 0, 1$. 我们总可以把 ε 写成

$$\varepsilon = \sum_{i=1}^{n-1} a_i 2^{-i} + a_n 2^{-n}$$

的形式，如果 $a_n = 0$，这就是 $n-1$ 位的情况；如果 $a_n = 1$，这样，我们可以假设有两个点 D_1, D_2 分别是靠近 B 的 $\sum_{i=1}^{n-1} a_i 2^{-i}$ 等分点和 $\sum_{i=1}^{n-1} a_i 2^{-i} + 2^{-(n-1)}$ 等分点，不难发现

$$\begin{cases} \mathcal{A}_{ABD_1} = \left(\sum_{i=1}^{n-1} a_i 2^{-i}\right) \cdot \mathcal{A}_{ABC}, \\ \mathcal{A}_{ABD_2} = \left(\sum_{i=1}^{n-1} a_i 2^{-i} + 2^{-(n-1)}\right) \cdot \mathcal{A}_{ABC} \end{cases}$$
$$\Longrightarrow \mathcal{A}_{ABD} = \mathcal{A}_{ABD_1} + \frac{\mathcal{A}_{ABD_2} - \mathcal{A}_{ABD_1}}{2} = \left(\sum_{i=1}^{n-1} a_i 2^{-i} + 2^{-n}\right) \cdot \mathcal{A}_{ABC}.$$

不难发现，最后那个括号里面的内容就是 ε，这就证明了这一点. 注意两个等号中间那个分数项是对 $\mathcal{A}_{AD_1D_2}$ 采用了 Step 1 的结果. 进而，我们就可以说，对于有限位二进制小数 ε，当 $d(B,D) = \varepsilon \cdot d(B,C)$ 的时候，成立

$$\frac{\mathcal{A}_{ABD}}{\mathcal{A}_{CBD}} = \frac{\varepsilon}{1-\varepsilon} = \frac{d(B,D)}{d(C,D)};$$

Step 3 最后，对于一般情况，我们要做的就是对这个数进行二进制展开之后，采用有限位逼近就行了.

综上，我们证明了，对于任意的 D，一定满足

$$\frac{\mathcal{A}_{ABD}}{\mathcal{A}_{CBD}} = \frac{d(B,D)}{d(C,D)}.$$ □

这样，我们就可以把一般情况的共边比例定理推广到双曲平面上了：

定理 4.9

对于双曲三角形 ABD 和 CBD 而言，如果 $BD \cap AC = P$，那么

$$\frac{\mathcal{A}_{ABD}}{\mathcal{A}_{CBD}} = \frac{d(A,P)}{d(C,P)}.$$

证明 我们对 ABC 和 P 利用定理4.3，可以得到

$$\frac{\mathcal{A}_{ABP}}{\mathcal{A}_{CBP}} = \frac{d(A,P)}{d(C,P)}.$$

然后，我们再对 ABP 和 D 利用定理4.3，可以得到

$$\frac{\mathcal{A}_{ABP}}{\mathcal{A}_{ABD}} = \frac{d(A,P)}{d(A,D)},$$

同理，对 CBP 和 D 利用定理4.3，可以得到

$$\frac{\mathcal{A}_{CBP}}{\mathcal{A}_{CBD}} = \frac{d(A,P)}{d(A,D)},$$

结合这三者，就能得到

$$\frac{\mathcal{A}_{ABD}}{\mathcal{A}_{CBD}} = \frac{d(A,P)}{d(C,P)}.$$ □

利用定理4.3，我们就可以完全仿照 Euclid 平面的思路证明双曲平面上对应的 Pappus 定理了.

进而，我们可以利用 Pappus 定理证明 Desargues 定理 [3]：

定理 4.10

对于双曲三角形 $ABC, A'B'C'$，直线 AA', BB', CC' 共点当且仅当

$$P = AB \cap A'B', \quad Q = BC \cap B'C', \quad R = AC \cap A'C'$$

共线.

证明 首先设 $X = AC \cap OQ, Y = OB \cap PX, Z = OA \cap CY$，那么

1. 对 OYB 和 CAX 采用 Pappus 定理可以得到 PQZ 共线；
2. 对 OYB' 和 PQZ 采用 Pappus 定理可以得到 $XA'W$（其中 $W = OB' \cap ZY$）共线；
3. 对 $WA'X$ 和 OCC' 采用 Pappus 定理可以得到 ZQR 共线；

这样，我们就证明了 $PQRZ$ 共线，Desargues 定理得证. □

参考文献

[1] 周兴和、杨明升. 高等几何. 科学出版社, 北京, 2008.
[2] 梅向明，黄敬之. 微分几何. 高等教育出版社, 北京, 2016.
[3] 盛茂，王作勤. 几何学基础. 中国科学技术大学数学科学学院, 2025.
[4] 秦敢、向守平. 力学与理论力学（第二版）下册. 科学出版社, 北京, 2014.

基于行列式乘子表示的 LMSD 收敛证明及加权 Ritz 推广

杨书泰

摘 要

本文研究严格凸二次问题上 LMSD、harmonic-LMSD 及一类加权 Ritz-sweep 方法的收敛性质。核心做法是把完整 Ritz-sweep 在谱分量上的乘子写成行列式之比，再由 Cauchy–Binet 展开得到非负加权平均，从而避开 Krylov 子空间维数下降时单个 Ritz 值极限不连续的问题。基于这一框架，本文发现 Fletcher 原始论证在 Krylov 子空间维数下降时并不适用，并给出一种修正。从而在更一般的情形下严格建立 LMSD 与 harmonic-LMSD 的全局收敛性，并进一步推广到统一的 ω-加权 Ritz 结构。最后给出若干数值模拟，验证理论结论及新算法族的有效性。

关键词： Barzilai–Borwein 步长；LMSD；Ritz 值；Cauchy–Binet 公式；加权 Ritz 步长；数值实验。

1 引言

考虑无约束优化问题

$$\min_{x\in\mathbb{R}^n} f(x), \tag{1.1}$$

其梯度法基本迭代格式为

$$x_{k+1} = x_k - \alpha_k g_k, \qquad g_k = \nabla f(x_k).$$

Barzilai 与 Borwein 提出的 BB1/BB2 步长 [1]

$$\alpha_k^{\mathrm{BB1}} = \frac{s_k^T s_k}{s_k^T y_k}, \qquad \alpha_k^{\mathrm{BB2}} = \frac{s_k^T y_k}{y_k^T y_k}, \tag{1.2}$$

其中 $s_k = x_{k+1} - x_k$、$y_k = g_{k+1} - g_k$，是谱梯度法最重要的出发点之一。Raydan [2] 证明了 BB 方法在严格凸二次问题上的全局收敛，Dai–Liao [3] 给出了 R-线性收敛证明。

由 BB 方法衍生出众多固定记忆谱梯度方法。Fletcher 在二次情形下把一个 BB 步长推广成一整个 Ritz-sweep [4]，得到了 limited memory steepest descent (LMSD) 方法及其 harmonic 变体。Ferrandi–Hochstenbach [6] 进一步从 Hessian 矩阵的子空间投影、割线最小二乘与对称化的角度，给出了 LMSD 的统一解释。Curtis–Guo [5] 在一定的非退化条件下证明了 fixed-cycle LMSD 的 R-线性收敛。

这里先约定两个术语，并说明固定记忆谱梯度方法的基本更新方式。经典 BB 方法每一步只利用当前的一对割线信息 (s_k, y_k)，而固定记忆（limited-memory）谱梯度方法保留最近 p 对割线 $(s_{k,r}, y_{k,r})$，由它们一次性解出 p 个谱步长，再在随后的 p 步迭代中依次使用。我们把这样一组“由同一批历史信息生成、并被连续使用的 p 个步长所对应的 p 步迭代”称为一个块（block，或一次 Ritz-sweep），并把整数 p 称为块长或历史窗口。每走完一

作者信息: 2022 级数学科学学院, 邮箱: taitai@mail.ustc.edu.cn

稿件信息: 本稿件于 4 月 30 日来稿。稿件编辑：朱葛瑄，邓博文

个块，历史窗口随之向前滑动：用新产生的割线对替换最旧的一对，再据此生成下一块所用的步长。本文的分析正是以“块”为基本单位展开的。

这些步长的具体取法由 Ritz 值给出。设 H 为对称矩阵、$\mathcal{V} \subset \mathbb{R}^n$ 为一子空间，取 $\mathcal{V}$ 的一组标准正交基排成列正交矩阵 Q，则称 $|\mathcal{V}| \times |\mathcal{V}|$ 小矩阵 $Q^T H Q$ 的特征值为 H 在 $\mathcal{V}$ 上的 Ritz 值。它们是 H 的特征值在子空间 $\mathcal{V}$ 上的标准 Rayleigh–Ritz 逼近，并总落在 H 的谱区间内。直观地说，LMSD 把“一个 BB 步长”升级为“由当前历史子空间上的 p 个 Ritz 值（取倒数）构成的一整块步长”，从而在每个块内同时照顾到 H 谱的多个方向。

本文给出 LMSD 与 harmonic-LMSD 方法在严格凸二次问题上的全局收敛证明。证明分为两个互补部分：首先，在精确二次模型中，同一块内连续生成的历史矩阵不可能在仍有超过 p 个互异活跃特征值时发生真正的 Krylov 秩降，一旦剩余活跃特征值个数不超过 p，秩自适应 sweep 反而会有限终止。其次，在非有限终止的正则区域内，我们把一整块步长作用在某个谱分量上的总乘子写成两个对称行列式之比，再通过 Cauchy–Binet 展开把它表示为有限组非负权重下的加权平均，最后借助一个简单的“乘子权重引理”控制其极限。这一过程绕开了 Fletcher [4] 附录中“从极限向量推导单个 Ritz 值的渐进位置”这一在 Krylov 子空间维数下降时难以直接成立的步骤。

更进一步地，我们将看到这一证明框架并不依赖于 LMSD 步长的特定代数形式。把每一块的标准步长 $\theta_{k,r}^{-1}$ 替换为某种“加权 Ritz 值”型步长后，同样的框架仍然适用。本文最后给出这一拓展，从而把 LMSD 方法的收敛证明推广到一个更广泛的、覆盖一类固定记忆谱梯度方法的统一图景之中。

记号约定。固定块长 $p \in \mathbb{N}$。本文统一把第 k 个完整块中第 r 个位置的点、梯度与位移记为

$$x_{k,r}, \qquad g_{k,r} = \nabla f(x_{k,r}), \qquad s_{k,r} = x_{k,r+1} - x_{k,r}, \qquad r = 0, \dots, p-1,$$

其中 $x_{k,p} = x_{k+1,0}$。相应地把第 k 个完整块的状态、位移束、梯度束分别记为

$$E_k = [x_{k,0}, \dots, x_{k,p}], \quad S_k = [s_{k,0}, \dots, s_{k,p-1}], \quad G_k = [g_{k,0}, \dots, g_{k,p-1}].$$

本文所有“p 个 Ritz 值”的说法均按重数计数。若某一小型对称广义特征值问题产生重复 Ritz 值，则对应步长在 Ritz-sweep 中也按相同重数重复使用。

不失一般性，本文对二次问题做出如下标准形约定。

假设 1.1. 对严格凸二次函数

$$q(x) = q(x^*) + \frac{1}{2}(x - x^*)^T H (x - x^*), \qquad H \succ 0,$$

我们总是先作平移，把极小点移到原点，再作正交变换把 H 对角化。若某个特征值有重数，则把问题压缩到由初始梯度生成的活跃不变子空间，并在每个活跃特征子空间内选择正交基，使初始梯度至多在其中一个方向上有非零坐标。由于一旦某个坐标为零，二次梯度递推会永远保持它为零，故可不失一般性地假设

$$q(x) = \frac{1}{2} x^T H x, \qquad H = \operatorname{diag}(\lambda_1, \dots, \lambda_n), \qquad 0 < \lambda_1 < \cdots < \lambda_n,$$

其中 $\lambda_1, \dots, \lambda_n$ 是关于初始梯度活跃的不同特征值。

在这个约定下，二次理论里 x 同时也是迭代点相对最优点的误差变量。

本文结构如下：第 2 节回顾 BB1/BB2 的最小二乘解释及其向 p 阶矩阵的推广，引出 LMSD 与 harmonic-LMSD 的步长定义。第 3 节讨论 Krylov 子空间结构与有限终止性质。

第 4 节是本文核心，给出 LMSD 与 harmonic-LMSD 全局收敛的完整证明。第 5 节给出步长公式的一类自然推广，并指出同一证明框架可继续使用。第 6 节给出数值实验。第 7 节给出若干结语与展望。

2 LMSD 的最小二乘解释与步长定义

2.1 BB1/BB2 的一维最小二乘解释

设

$$s_{k,0} = x_{k,1} - x_{k,0}, \qquad y_{k,0} = g_{k,1} - g_{k,0}.$$

BB1 与 BB2 分别可以由下面两个一维最小二乘问题导出：

$$\eta_{k,0}^{\mathrm{BB1}} := \arg\min_{\eta\in\mathbb{R}} \left\|\eta s_{k,0} - y_{k,0}\right\|^2 = \frac{s_{k,0}^T y_{k,0}}{s_{k,0}^T s_{k,0}}, \qquad \alpha_k^{\mathrm{BB1}} = \frac{1}{\eta_{k,0}^{\mathrm{BB1}}}; \tag{2.1}$$

$$\alpha_k^{\mathrm{BB2}} := \arg\min_{\alpha\in\mathbb{R}} \left\|s_{k,0} - \alpha y_{k,0}\right\|^2 = \frac{s_{k,0}^T y_{k,0}}{y_{k,0}^T y_{k,0}}. \tag{2.2}$$

也就是说，BB1 是“用一个标量拟合 Hessian”的最小二乘解，而 BB2 是“用一个标量拟合逆 Hessian”的最小二乘解。这正是把 BB 推广到更高维步长的自然出发点。

2.2 p 阶矩阵的最小二乘推广

固定正整数 p。在第 k 个完整块起点，记最近 p 个割线对所构成的位移束与梯度差束为

$$S_k = [s_{k,0}, \ldots, s_{k,p-1}] \in \mathbb{R}^{n\times p}, \qquad Y_k = [y_{k,0}, \ldots, y_{k,p-1}] \in \mathbb{R}^{n\times p},$$

并令

$$M_k = S_k^T S_k, \qquad B_k = S_k^T Y_k, \qquad D_k = Y_k^T Y_k.$$

按照 [6] 中的解释，把 (2.1)–(2.2) 中的标量分别提升为 $p\times p$ 矩阵，可得到原始矩阵最小二乘模型

$$M_k^{\mathrm{LS}} := \arg\min_{M\in\mathbb{R}^{p\times p}} \|Y_k - S_k M\|_F^2, \qquad N_k^{\mathrm{LS}} := \arg\min_{N\in\mathbb{R}^{p\times p}} \|S_k - Y_k N\|_F^2. \tag{2.3}$$

当 M_k 与 D_k 可逆时，由正规方程立刻得到

$$M_k^{\mathrm{LS}} = M_k^{-1} B_k, \qquad N_k^{\mathrm{LS}} = D_k^{-1} B_k^T. \tag{2.4}$$

命题 2.1. 当 $p = 1$ 时，(2.4) 精确退化为经典 BB1/BB2：

$$M_k^{\mathrm{LS}} = \frac{s_{k,0}^T y_{k,0}}{s_{k,0}^T s_{k,0}} = \frac{1}{\alpha_k^{\mathrm{BB1}}}, \qquad N_k^{\mathrm{LS}} = \frac{s_{k,0}^T y_{k,0}}{y_{k,0}^T y_{k,0}} = \alpha_k^{\mathrm{BB2}}.$$

可见经典 BB 与更高维的 pD-BB 步长可以放在同一个“矩阵最小二乘谱拟合”框架下来理解。

2.3 严格凸二次情形下与 Ritz 值的等价性

由假设 1.1，严格凸二次情形可在标准形

$$q(x) = \frac{1}{2} x^T H x, \qquad H = \mathrm{diag}(\lambda_1, \ldots, \lambda_n), \qquad 0 < \lambda_1 < \cdots < \lambda_n \tag{2.5}$$

下讨论。这时 $Y_k = HS_k$。Ferrandi–Hochstenbach [6] 给出了如下严格的等价关系。

定理 2.2. 设 q 由 (2.5) 给出。令 $S_k = Q_k R_k$ 与 $Y_k = W_k T_k$ 为相应薄 QR 分解，则

$$M_k^{\mathrm{LS}} = R_k^{-1}(Q_k^T H Q_k)R_k, \qquad N_k^{\mathrm{LS}} = T_k^{-1}(W_k^T H^{-1} W_k)T_k. \tag{2.6}$$

因此：

(i) M_k^{LS} 的特征值精确等于 H 在子空间 $\mathrm{span}(S_k)$ 上的 Ritz 值；

(ii) N_k^{LS} 的特征值精确等于 H^{-1} 在子空间 $\mathrm{span}(Y_k)$ 上的 Ritz 值。

证明. 由 $Y_k = HS_k$ 与 $S_k = Q_k R_k$ 得 $M_k = R_k^T R_k$、$B_k = R_k^T(Q_k^T H Q_k)R_k$，故

$$M_k^{\mathrm{LS}} = (R_k^T R_k)^{-1} R_k^T (Q_k^T H Q_k) R_k = R_k^{-1}(Q_k^T H Q_k) R_k.$$

N_k^{LS} 的写法完全类似。 □

定理 2.2 把一组步长直接刻画成了 H 或 H^{-1} 在某子空间上的 Ritz 值，这是后续证明所依赖的核心代数结构。

2.4 两类块步长定义：S 型与 Y 型

我们采用与 [6] 一致的命名约定。

定义 2.3 (S 型块步长，对应 LMSD)**.** 设当前完整块的历史子空间为

$$\mathcal{S}_k := \mathrm{span}(S_k), \qquad d_k := \dim \mathcal{S}_k \le p.$$

秩自适应解释下，记 H 在 $\mathcal{S}_k$ 上的 d_k 个 Ritz 值为 $\theta_{k,0}, \dots, \theta_{k,d_k-1}$。下一有效 sweep 依次使用步长

$$\alpha_{k+1,r}^{(S)} = \theta_{k,r}^{-1}, \qquad r = 0, \dots, d_k - 1.$$

在固定块长的正则情形中 $d_k = p$，这正是 LMSD 的 p 步 Ritz-sweep。

定义 2.4 (Y 型块步长，对应 harmonic-LMSD)**.** 设当前完整块的历史梯度差子空间为

$$\mathcal{Y}_k := \mathrm{span}(Y_k) = H\,\mathrm{span}(S_k), \qquad d_k := \dim \mathcal{Y}_k \le p.$$

秩自适应解释下，记 H^{-1} 在 $\mathcal{Y}_k$ 上的 d_k 个 Ritz 值为 $\tau_{k,0}, \dots, \tau_{k,d_k-1}$。下一有效 sweep 依次使用步长

$$\alpha_{k+1,r}^{(Y)} = \tau_{k,r}, \qquad r = 0, \dots, d_k - 1.$$

在固定块长的正则情形中 $d_k = p$，这正是 harmonic-LMSD 的 p 步 Ritz-sweep。

3 Krylov 子空间结构与有限终止定理

下面给出严格凸二次情形下 LMSD 历史子空间的 Krylov 描述以及有限终止性质。

命题 3.1. 设 $q(x) = \frac{1}{2}x^T H x$ 为严格凸二次函数，考虑某个固定块中的 p 步梯度迭代。则

$$\mathrm{span}(G_k) = \mathrm{span}(S_k) = \mathcal{K}_p(H, g_{k,0}), \qquad \mathrm{span}(Y_k) = H\,\mathrm{span}(G_k) = H\mathcal{K}_p(H, g_{k,0}).$$

特别地，无论由 G_k、S_k 还是由 $K_k = [g_{k,0}, Hg_{k,0}, \dots, H^{p-1}g_{k,0}]$ 出发得到的 Ritz 值都只由子空间 $\mathcal{K}_p(H, g_{k,0})$ 决定。

证明. 由二次递推 $g_{k,r+1} = (I - \alpha_{k,r}H)g_{k,r}$，对每个 r 存在次数恰为 r 且首项系数非零的多项式 $P_{k,r}$，使 $g_{k,r} = P_{k,r}(H)g_{k,0}$。因此存在可逆上三角矩阵 U_k 使 $G_k = K_k U_k$，于是 $\mathrm{span}(G_k) = \mathrm{span}(K_k) = \mathcal{K}_p(H, g_{k,0})$。由 $s_{k,r} = -\alpha_{k,r}g_{k,r}$、$\alpha_{k,r} > 0$ 知 $\mathrm{span}(S_k) = \mathrm{span}(G_k)$。最后，由 $y_{k,r} = -\alpha_{k,r}Hg_{k,r}$ 可知 $\mathrm{span}(Y_k) = H\,\mathrm{span}(G_k)$。 □

引理 3.2 (Krylov 秩判据)**.** 设 $u \in \mathbb{R}^n$，记

$$\mathcal{A}(u) := \{i : \ u^{(i)} \neq 0\}, \qquad s(u) := |\mathcal{A}(u)|,$$

则

$$\operatorname{rank}[u, Hu, \dots, H^{p-1}u] = \min\{p, s(u)\}.$$

因此，在假设 1.1 的互异活跃谱标准形下，只要当前梯度仍含有至少 p 个互异活跃特征值，连续 Krylov 历史矩阵就不可能精确降到低于 p 维。

证明. 在特征基下，$[u, Hu, \dots, H^{p-1}u]$ 的第 i 行等于

$$u^{(i)}(1, \lambda_i, \dots, \lambda_i^{p-1}).$$

删去 $u^{(i)} = 0$ 的行并提出非零因子 $u^{(i)}$ 后，剩下的是由互异节点 $\{\lambda_i : i \in \mathcal{A}(u)\}$ 生成的 Vandermonde 型矩阵。任取其中 $\min\{p, s(u)\}$ 行与相同数量的前若干列即可得到非零 Vandermonde 子式，故其列秩为 $\min\{p, s(u)\}$。 □

引理 3.3. H 关于 g_0 的极小多项式为 $\pi(t) = \prod_{i=1}^{n}(t-\lambda_i)$，次数为 n，从而 $\dim \mathcal{K}_n(H, g_0) = n$。

证明. 由于 $H = \operatorname{diag}(\lambda_i)$ 对角，对任意多项式 P 有 $P(H)g_0 = \left(P(\lambda_i)g_0^{(i)}\right)_i$。因为标准形下 $g_0^{(i)} \neq 0$，$P(H)g_0 = 0$ 当且仅当 $P(\lambda_i) = 0$ 对所有 i 成立。次数最低的首一这样的多项式正是 π。极小多项式次数等于 Krylov 维数。 □

引理 3.4. 对任意正预热步长，

$$\mathcal{K}_n(H, g_0) = \operatorname{span}\{g_0, \dots, g_{n-1}\} = \operatorname{span}\{s_0, \dots, s_{n-1}\} = \mathbb{R}^n.$$

当历史窗口 $p \geq n$ 时，第一个完整块的历史位移矩阵满足 $\operatorname{span}(S_0) = \mathbb{R}^n$。

证明. 由 $g_j = P_j(H)g_0$（P_j 次数为 j、首项系数非零）即得 $\operatorname{span}\{g_0, \dots, g_{n-1}\} = \mathcal{K}_n(H, g_0)$，由极小多项式次数为 n 知它是全空间。再由 $s_j = -\alpha_j g_j$ 得 $\operatorname{span}\{s_0, \dots, s_{n-1}\}$ 为同一空间。 □

定理 3.5 (有限终止)**.** 设目标函数满足 (2.5) 且已规约至标准形，活跃特征值个数为 n。则在 $p = n$ 且前 n 个预热步长均为正时，第一个完整块识别出全空间 $\mathbb{R}^n$，下一块使用的步长集合在 S 型与 Y 型中都恰为

$$\{\lambda_1^{-1}, \dots, \lambda_n^{-1}\},$$

从而再经过 n 步迭代后梯度变为零。若采用秩压缩，即遇到历史子空间降秩时只使用有效的 Ritz 值构造下一轮步长，则同一结论对 $p \geq n$ 成立，算法在至多 $p + n \leq 2p$ 步内有限终止。

证明. 先看固定维数情形 $p = n$。由引理 3.4，第一个完整块的历史子空间 $\operatorname{span}(S_0) = \mathbb{R}^n$。对 S 型，由定义 2.3 得到的 Ritz 值正是 H 在 $\mathbb{R}^n$ 上的特征值 $\lambda_1, \dots, \lambda_n$，下一块使用步长 $\lambda_1^{-1}, \dots, \lambda_n^{-1}$。对 Y 型，由定义 2.4 得到的是 H^{-1} 在同一全空间上的特征值，因此直接作为步长时仍得到同一个集合。于是

$$g_{p+n} = \prod_{j=1}^{n}\Big(I - \frac{1}{\lambda_j}H\Big)g_p = \frac{(-1)^n}{\prod_j \lambda_j}\,\pi(H)g_p = 0,$$

其中最后一步用到 $\pi(H) = 0$。

若 $p > n$，固定的 $p \times p$ 小矩阵公式本身会因历史束秩至多为 n 而退化。因此此时需要先压缩到实际秩 n，或等价地直接在活跃 Krylov 子空间上取 Ritz 值。压缩后得到的有效特征值仍是 $\lambda_1, \dots, \lambda_n$，后续消去多项式与上面相同，故有限终止步数不超过 $p + n$。 □

定理 3.5 表明：有限终止本质上来自“前 p 步识别出有效 Krylov 子空间，后 n 步用全部活跃特征值构造消去多项式”。

4 LMSD 与 harmonic-LMSD 在正则块状态下的全局收敛

本节进入本文的核心。根据引理 3.2，严格凸二次模型中的块状态自然分成两个分支：若当前梯度中剩余的互异活跃特征值个数不超过 p，秩自适应 sweep 会有限终止；若该个数大于 p，则当前 Krylov 历史矩阵满列秩，固定长度的 p 个 Ritz 步长良好定义。因此，真正需要渐进收敛分析的只有非有限终止的正则区域。

对 $u \in \mathbb{R}^n$，记

$$\mathcal{A}(u) := \{i : \ u^{(i)} \neq 0\}, \qquad s(u) := |\mathcal{A}(u)|,$$

并定义非终止正则区域

$$\mathcal{R}_p := \{u \in \mathbb{R}^n : \ s(u) > p\}.$$

注意 $s(u) = p$ 时 $K_p(H, u)$ 仍然满列秩，但此时 Krylov 子空间已经等于剩余活跃不变子空间，由定理 3.5，下一次完整 Ritz-sweep 会直接消去所有剩余分量。因此本文把 $s(u) = p$ 视为有限终止边界，而不归入需要渐进分析的正则区域。

定义 4.1 (正则块状态)**.** 对给定的 S 型或 Y 型方法，若某条非零块轨道的每个块起点梯度都满足

$$g_{k,0} \in \mathcal{R}_p,$$

则称该轨道处于正则块状态。等价地，在这条非终止轨道上，每个完整块都生成按重数计的 p 个 Ritz 步长，并且不会进入有限终止边界。

由定理 3.5，我们可以直接得到如下定理。

定理 4.2 (正则区域外的有限终止)**.** 设 q 满足 (2.5)，并考虑精确秩自适应的 S 型或 Y 型块步长。若某个块起点 $g_{k,0}$ 满足

$$m := s(g_{k,0}) \leq p,$$

则从该块起点出发，算法在至多 m 个有效 Ritz 步长后达到 $g = 0$。因此，任何非有限终止的精确秩自适应轨道必然在每个非零块起点满足 $s(g_{k,0}) > p$，即处于定义 4.1 的正则区域。

注 4.3. 定理 4.2 说明，在精确严格凸二次模型和同一块内连续历史的设定下，不存在“真实 Krylov 维数降到小于等于 p 但算法仍需继续做渐进收敛分析”的第三种情形。真正的秩降等价于剩余互异活跃谱已经不超过 p，而这正是有限终止分支。

4.1 相关引理

我们先给出两个辅助引理。第一个引理是 Fletcher [4] 附录中证明 LMSD 收敛性结论时用到的一个引理，我们也将其作为后续证明的工具。第二个引理是乘子权重引理，它是将后续对于 LMSD 及 harmonic-LMSD 收敛性质推广到一般情形的关键。事实上，后续证明某种程度上可以看做 Raydan [2] 证明 BB 步长在严格凸二次问题上的全局收敛方法的高维推广。

引理 4.4 (Fletcher [4] 附录中的引理)**.** 设 $\{a_k\}_{k\geq 0}$ 为一列非负实数，并且存在常数 $M \geq 1$ 使

$$a_{k+2} \leq M a_{k+1}, \qquad k \geq 0.$$

若对任意 $\varepsilon > 0$ 都存在常数 $c_\varepsilon \in (0,1)$ 与正整数 k_ε，使得对一切 $k \geq k_\varepsilon$ 均有

$$a_k \geq \varepsilon \Longrightarrow a_{k+2} \leq c_\varepsilon a_{k+1},$$

则 $a_k \to 0$。

证明. 任取 $\varepsilon > 0$。我们首先证明：存在 $N \geq k_\varepsilon$，使得 $a_N < \varepsilon$。若不然，则对一切 $k \geq k_\varepsilon$ 均有 $a_k \geq \varepsilon$。于是由题设条件可知，对于所有 $k \geq k_\varepsilon$，都有 $a_{k+2} \leq c_\varepsilon a_{k+1}$。通过递推可得，对于任意 $j \in \mathbb{N}$，有

$$a_{k_\varepsilon+j+1} \leq c_\varepsilon^j a_{k_\varepsilon+1}.$$

由于 $0 < c_\varepsilon < 1$，当 $j \to \infty$ 时 $c_\varepsilon^j \to 0$，故存在 j_0 使得 $a_{k_\varepsilon+j_0+1} < \varepsilon$，这与假设矛盾。因此，集合 $\{n \geq k_\varepsilon \mid a_n < \varepsilon\}$ 是非空的。令 $N_1 = \min\{n \geq k_\varepsilon \mid a_n < \varepsilon\}$。

接下来，我们利用数学归纳法证明：对于所有 $n \geq N_1$，均有 $a_n < M^2\varepsilon$。当 $n = N_1$ 时，$a_{N_1} < \varepsilon < M^2\varepsilon$，命题成立。当 $n = N_1 + 1$ 时，由全局性质 $a_{k+2} \leq Ma_{k+1}$（取 $k = N_1 - 1$）得

$$a_{N_1+1} \leq Ma_{N_1} < M\varepsilon \leq M^2\varepsilon.$$

假设对于 $N_1 \leq n \leq m$（其中 $m \geq N_1 + 1$），命题 $a_n < M^2\varepsilon$ 均成立。现在考虑 a_{m+1}。考察 a_{m-1} 的取值：

(i) 若 $a_{m-1} < \varepsilon$，则由全局递推性质：

$$a_{m+1} \leq Ma_m \leq M(Ma_{m-1}) = M^2 a_{m-1} < M^2\varepsilon.$$

(ii) 若 $a_{m-1} \geq \varepsilon$，由于 $m - 1 \geq N_1 \geq k_\varepsilon$，满足触发条件，故：

$$a_{m+1} \leq c_\varepsilon a_m.$$

由归纳假设 $a_m < M^2\varepsilon$ 且 $c_\varepsilon < 1$，得 $a_{m+1} < c_\varepsilon M^2\varepsilon < M^2\varepsilon$。

综上所述，对所有 $n \geq N_1$，恒有 $a_n < M^2\varepsilon$。由于 M 是与 ε 无关的常数，根据极限的定义知 $\lim_{k\to\infty} a_k = 0$。 □

引理 4.5 (乘子权重引理)**.** 设 $r \in \{2, \ldots, n\}$，$\mathcal{I}_p$ 为所有 p 元指标集。若某一块方法存在乘子多项式 χ_k，使得

$$g_{k+2,0}^{(i)} = \chi_k(\lambda_i)\, g_{k+1,0}^{(i)}, \qquad i = 1, \ldots, n,$$

并且对 λ_r 有表示

$$\chi_k(\lambda_r) = \frac{\sum_{I\in\mathcal{I}_p} \beta_I^{(k)} \phi_I^{(r)}}{\sum_{I\in\mathcal{I}_p} \beta_I^{(k)}}, \qquad \beta_I^{(k)} \geq 0, \quad \sum_{I\in\mathcal{I}_p} \beta_I^{(k)} > 0$$

（最后一式保证该加权平均有意义）。设 $\mathcal{I}_p = A_r \cup B_r \cup C_r$ 为不交并，满足：

(i) 若 $I \in A_r$，则 $\phi_I^{(r)} = 0$；

(ii) 若 $I \in B_r$，则 $0 \leq \phi_I^{(r)} \leq \rho_r < 1$；

(iii) 对每个 $I \in C_r$，存在 $i(I) < r$，$J(I) \in A_r$ 和与 k 无关的常数 $c_I > 0$，使

$$\frac{\beta_I^{(k)}}{\beta_{J(I)}^{(k)}} = c_I \frac{(g_{k,0}^{(i(I))})^2}{(g_{k,0}^{(r)})^2}.$$

若 $g_{k,0}^{(1)} \to 0$，…，$g_{k,0}^{(r-1)} \to 0$，且对某个 $\varepsilon > 0$，集合 $S_\varepsilon := \{k \geq 1 : |g_{k,0}^{(r)}| \geq \varepsilon\}$ 是无限的，则

$$\limsup_{k\in S_\varepsilon} |\chi_k(\lambda_r)| \leq \rho_r < 1.$$

证明. 按三类分组：

$$|\chi_k(\lambda_r)| \le \frac{\sum_{I\in B_r}\beta_I^{(k)}\phi_I^{(r)}}{\sum_{I\in\mathcal{I}_p}\beta_I^{(k)}} + \frac{\sum_{I\in C_r}\beta_I^{(k)}|\phi_I^{(r)}|}{\sum_{I\in\mathcal{I}_p}\beta_I^{(k)}}.$$

由 (ii) 第一项不超过 ρ_r。再记 $M_r := \max_{I\in C_r}|\phi_I^{(r)}| < \infty$，便有

$$|\chi_k(\lambda_r)| \le \rho_r + M_r\,\frac{\sum_{I\in C_r}\beta_I^{(k)}}{\sum_{I\in\mathcal{I}_p}\beta_I^{(k)}}.$$

对每个 $I\in C_r$，由 $J(I)\in A_r$ 与 $|g_{k,0}^{(r)}|\ge\varepsilon$ 有

$$\frac{\beta_I^{(k)}}{\sum_{J\in\mathcal{I}_p}\beta_J^{(k)}} \le \frac{\beta_I^{(k)}}{\beta_{J(I)}^{(k)}} = c_I\,\frac{(g_{k,0}^{(i(I))})^2}{(g_{k,0}^{(r)})^2} \le c_I\,\frac{(g_{k,0}^{(i(I))})^2}{\varepsilon^2}.$$

由于 $i(I)<r$ 且前 $r-1$ 个分量已收敛到零，故右端随 $k\in S_\varepsilon$ 趋于零。对有限个 I 求和即得结论。 □

注 4.6 (Fletcher [4] 附录论证在维数下降情形下的局限性)**.** Fletcher [4] 附录中 LMSD 收敛性论证的关键困难在于：若试图从极限向量的谱支撑直接推出“所有单独的 Ritz 值最终都远离某些特征值”，这一步在 Krylov 维数下降时需要额外说明，并且不能按原表述直接成立。一个简单反例如下：取 $H=\mathrm{diag}(1,2)$、$p=2$，并取

$$q_n = \frac{(1/n,\,1)^T}{\sqrt{1+(1/n)^2}} \to e_2.$$

对每个 n，都有 $\mathrm{span}\{q_n, Hq_n\} = \mathbb{R}^2$，因此由该二维 Krylov 空间得到的两个 Ritz 值始终等于 $\{1,2\}$，它们不会随着 $q_n\to e_2$ 而一起落入子区间 $(\frac{4}{3},2)$ 之内。这说明在极限点发生 Krylov 维数下降时，单个 Ritz 值的渐进性态不是一个可靠的分析对象。本文下面的证明改为直接控制一个完整块作用在第 i 个特征分量上的乘子多项式

$$\psi_k(\lambda_i) = \prod_{\ell=0}^{p-1}\Big(1-\frac{\lambda_i}{\theta_{k,\ell}}\Big),$$

从而绕开了这一障碍。

4.2 S 型方法的全局收敛

定理 4.7 (S 型方法（LMSD）的全局收敛)**.** 设 q 由 (2.5) 给出，并考虑精确秩自适应的 S 型步长。则从任意初始块状态出发，相应块轨道要么有限步终止于原点，要么满足 $E_k\to 0$。特别地，在定义 4.1 的正则非终止分支上，固定长度的 LMSD Ritz-sweep 全局收敛。

证明. 若轨道在某个块起点满足 $s(g_{k,0})\le p$，则由定理 4.2 有限终止。故只需考虑非有限终止情形。此时每个非零块起点都满足 $s(g_{k,0})>p$。若某个活跃分量在有限块后变为零，则由二次递推它此后将永久保持为零，删去这些分量等价于把问题压缩到更小的活跃不变子空间。这样的删减至多发生有限次；若删减后剩余活跃特征值个数不超过 p，仍由定理 4.2 有限终止。因而在一条非有限终止尾轨道上，可重新编号并不失一般性地假设所有剩余活跃分量始终非零且其个数 $n>p$。

记 $g_k := g_{k,0}$，先证 $g_k\to 0$。定义 Krylov 矩阵 $K_k=[g_{k,0}, Hg_{k,0},\dots,H^{p-1}g_{k,0}]$。由命题 3.1，$\mathrm{span}(S_k)=\mathrm{span}(K_k)=\mathcal{K}_p(H,g_k)$。因此 S 型步长所用的 Ritz 值 $\theta_{k,0},\dots,\theta_{k,p-1}$ 正是 H 在 $\mathcal{K}_p(H,g_k)$ 上的标准 Ritz 值。它们都属于 H 的谱区间，故

$$\lambda_1 \le \theta_{k,\ell} \le \lambda_n, \qquad \ell=0,\dots,p-1. \tag{4.1}$$

设

$$\psi_k(t) := \prod_{\ell=0}^{p-1}\Big(1 - \frac{t}{\theta_{k,\ell}}\Big).$$

块 k 生成的这组 Ritz 值会在块 $k+1$ 中依次使用，因此

$$g_{k+2,0} = \psi_k(H) g_{k+1,0}, \qquad g^{(i)}_{k+2,0} = \psi_k(\lambda_i)\, g^{(i)}_{k+1,0}. \tag{4.2}$$

由 (4.1)，对任意 ℓ 有 $0 \le 1 - \lambda_1/\theta_{k,\ell} \le 1 - \lambda_1/\lambda_n < 1$，于是

$$|g^{(1)}_{k+2,0}| = |\psi_k(\lambda_1)|\,|g^{(1)}_{k+1,0}| \le \Big(1 - \frac{\lambda_1}{\lambda_n}\Big)^p |g^{(1)}_{k+1,0}|,$$

故 $g^{(1)}_{k,0} \to 0$。

若所有分量都趋零则定理已证。否则设 $r > 1$ 为满足 $g^{(j)}_{k,0} \to 0$（$j < r$）但 $g^{(r)}_{k,0} \not\to 0$ 的最小指标。则存在 $\bar\varepsilon > 0$，使对每个 $0 < \varepsilon \le \bar\varepsilon$ 集合

$$S_\varepsilon := \{k \ge 1 :\ |g^{(r)}_{k,0}| \ge \varepsilon\}$$

都是无限的。以下先固定 $0 < \varepsilon \le \bar\varepsilon$，并简记 $S := S_\varepsilon$。即先在非平凡的无限子列上建立收缩估计，最后再统一处理任意 $\varepsilon > 0$。

为处理无限情形，将 $\psi_k(\lambda_r)$ 写成行列式比。$\{\theta_{k,\ell}\}$ 是广义特征值问题 $(K_k^T H K_k)v = \theta(K_k^T K_k)v$ 的根。由严格凸二次性 $K_k^T H K_k \succ 0$，从而

$$\det(K_k^T H K_k - \lambda K_k^T K_k) = \det(K_k^T H K_k) \prod_{\ell=0}^{p-1}\Big(1 - \frac{\lambda}{\theta_{k,\ell}}\Big).$$

取 $\lambda = \lambda_r$，便得到

$$\psi_k(\lambda_r) = \frac{\det\big(K_k^T (H - \lambda_r I) K_k\big)}{\det(K_k^T H K_k)}. \tag{4.3}$$

再作 Cauchy–Binet 展开。记

$$D_k := \operatorname{diag}(g^{(1)}_{k,0}, \dots, g^{(n)}_{k,0}), \qquad V \in \mathbb{R}^{n\times p}, \quad V_{ij} = \lambda_i^{j-1},$$

则 $K_k = D_k V$。令 $\mathcal{I}_p := \{I \subset \{1,\dots,n\} : |I| = p\}$，$V_I$ 表示 V 中行指标属于 I 的 $p \times p$ 子矩阵。由 Cauchy–Binet 公式，

$$\det(K_k^T H K_k) = \sum_{I\in\mathcal{I}_p} \det(V_I)^2 \prod_{i\in I} \lambda_i\, (g^{(i)}_{k,0})^2,$$

$$\det\big(K_k^T (H - \lambda_r I) K_k\big) = \sum_{I\in\mathcal{I}_p} \det(V_I)^2 \prod_{i\in I} (\lambda_i - \lambda_r)\, (g^{(i)}_{k,0})^2.$$

若令

$$\beta_I^{(k)} := \det(V_I)^2 \prod_{i\in I} \lambda_i\, (g^{(i)}_{k,0})^2 \ge 0, \qquad \phi_I^{(r)} := \prod_{i\in I}\Big(1 - \frac{\lambda_r}{\lambda_i}\Big),$$

则 (4.3) 化为

$$\psi_k(\lambda_r) = \frac{\sum_{I\in\mathcal{I}_p} \beta_I^{(k)} \phi_I^{(r)}}{\sum_{I\in\mathcal{I}_p} \beta_I^{(k)}}. \tag{4.4}$$

下面应用乘子权重引理。将 $\mathcal{I}_p$ 分成三类：

$$A_r := \{I \in \mathcal{I}_p :\ r \in I\},$$
$$B_r := \{I \in \mathcal{I}_p :\ I \subset \{r+1,\dots,n\}\},$$
$$C_r := \{I \in \mathcal{I}_p :\ r \notin I,\ I \cap \{1,\dots,r-1\} \ne \emptyset\}.$$

对 $I \in A_r$，$\phi_I^{(r)} = 0$；对 $I \in B_r$，每个因子都落在 $(0,1)$ 内，故

$$0 \le \phi_I^{(r)} \le \left(1 - \frac{\lambda_r}{\lambda_n}\right)^p =: \rho_r < 1.$$

对 $I \in C_r$，从 $I \cap \{1,\dots,r-1\}$ 中任选一个指标 $i(I)$，并令 $J(I) := (I \setminus \{i(I)\}) \cup \{r\} \in A_r$。由活跃特征值互异，相关 Vandermonde 子式都非零，故存在与 k 无关的常数 $c_I > 0$ 使

$$\frac{\beta_I^{(k)}}{\beta_{J(I)}^{(k)}} = \frac{\det(V_I)^2}{\det(V_{J(I)})^2} \cdot \frac{\lambda_{i(I)}}{\lambda_r} \cdot \frac{(g_{k,0}^{(i(I))})^2}{(g_{k,0}^{(r)})^2} = c_I \frac{(g_{k,0}^{(i(I))})^2}{(g_{k,0}^{(r)})^2}.$$

于是 $\psi_k(\lambda_r)$ 满足引理 4.5 的全部假设，从而

$$\limsup_{k \in S} |\psi_k(\lambda_r)| \le \rho_r < 1.$$

任选 $c_r(\varepsilon) \in (\rho_r, 1)$，便存在 k_ε，使对所有 $k \in S$ 且 $k \ge k_\varepsilon$ 都有

$$|g_{k+2,0}^{(r)}| \le c_r(\varepsilon) |g_{k+1,0}^{(r)}|. \tag{4.5}$$

以上固定的是某个 $\varepsilon \in (0, \bar{\varepsilon}]$。事实上，对任意 $\varepsilon > 0$ 都可同样处理：若 S_ε 无限，则 (4.3)–(4.4) 的行列式比与 Cauchy–Binet 推导逐字适用（其中只用到 S_ε 无限以及 $g_{k,0}^{(j)} \to 0$（$j < r$）），从而同样得到 (4.5) 形式的收缩；若 S_ε 有限，则 k 充分大时 $|g_{k,0}^{(r)}| \ge \varepsilon$ 不成立，收缩蕴含式平凡为真。因此引理 4.4 所需的收缩蕴含式对一切 $\varepsilon > 0$ 都成立。另一方面，由 (4.1)，对任意 $\theta \in [\lambda_1, \lambda_n]$ 有

$$\left|1 - \frac{\lambda_r}{\theta}\right| \le \max\left\{\frac{\lambda_n}{\lambda_1} - 1,\ 1 - \frac{\lambda_1}{\lambda_n}\right\}.$$

故存在常数 $C_r^* := \max\left\{1, \left(\lambda_n/\lambda_1 - 1\right)^p\right\} \ge 1$，使

$$|g_{k+2,0}^{(r)}| \le C_r^* |g_{k+1,0}^{(r)}|, \qquad \forall k. \tag{4.6}$$

令 $a_k := |g_{k,0}^{(r)}|$。(4.6) 给出与 ε 无关的全局界 $a_{k+2} \le C_r^* a_{k+1}$，而上一段已说明 (4.5) 形式的收缩蕴含式对每个 $\varepsilon > 0$ 都成立。于是引理 4.4 的两个条件均满足，从而 $a_k \to 0$，即 $g_{k,0}^{(r)} \to 0$，与 r 的最小性矛盾。故 $g_{k,0} \to 0$。

最后，由 (4.1) 与块内递推 $g_{k,j+1} = (I - \alpha_{k,j} H) g_{k,j}$，每一步的放大因子一致有界，于是对任意固定 $r = 0, \dots, p$ 都有 $\|g_{k,r}\| \le C \|g_{k,0}\|$，从而 $g_{k,r} \to 0$。再由 $g_{k,r} = H x_{k,r}$ 与 $H \succ 0$，得 $x_{k,r} \to 0$，于是 $E_k \to 0$。 □

4.3 Y 型方法的全局收敛

定理 4.8 (Y 型方法（harmonic-LMSD）的全局收敛)**.** 设 q 由 (2.5) 给出，并考虑精确秩自适应的 Y 型步长。则从任意初始块状态出发，相应块轨道要么有限步终止于原点，要么满足 $E_k \to 0$。特别地，在正则非终止分支上，固定长度的 harmonic-LMSD Ritz-sweep 全局收敛。

证明. 由定理 4.2，非正则分支有限终止。故在非有限终止情形中，与 S 型证明开头相同，可以删去已经永久为零的分量并重新编号，使得所有剩余活跃分量始终非零且活跃特征值个数 $n > p$。

仍记 $g_k := g_{k,0}$，先证 $g_k \to 0$。令 $K_k = [g_k, H g_k, \dots, H^{p-1} g_k]$，$Z_k := H K_k$。由命题 3.1，$\operatorname{span}(Y_k) = \operatorname{span}(Z_k) = H\mathcal{K}_p(H, g_k)$。因此按定义 2.4 得到的步长 $\tau_{k,r}$ 是广义特征值问题 $Z_k^T H^{-1} Z_k\, w = \tau Z_k^T Z_k\, w$ 的特征值，由 $Z_k = H K_k$ 等价于

$$K_k^T H K_k\, w = \tau\, K_k^T H^2 K_k\, w.$$

它们直接被用作下一块步长 $\alpha_{k+1,r}=\tau_{k,r}$。设 $\varphi_k(t):=\prod_{r=0}^{p-1}(1-\tau_{k,r}t)$，则

$$g_{k+2,0}=\varphi_k(H)g_{k+1,0},\qquad g_{k+2,0}^{(i)}=\varphi_k(\lambda_i)\,g_{k+1,0}^{(i)}. \tag{4.7}$$

由 $\tau_{k,r}\in[1/\lambda_n,1/\lambda_1]$，有

$$|\varphi_k(\lambda_1)|\le\Big(1-\frac{\lambda_1}{\lambda_n}\Big)^p<1,$$

故 $g_{k,0}^{(1)}\to 0$。

设 $r>1$ 是满足 $g_{k,0}^{(j)}\to 0$（$j<r$）但 $g_{k,0}^{(r)}\not\to 0$ 的最小指标，仍记 $S=S_\varepsilon$。

下面把 $\varphi_k(\lambda_r)$ 写成行列式比。设 $A_k:=K_k^THK_k$、$B_k:=K_k^TH^2K_k$。由 $\tau_{k,j}$ 是 $A_kw=\tau B_kw$ 的全部根，故

$$\det(B_k-\lambda A_k)=\det(B_k)\prod_{j=0}^{p-1}(1-\lambda\tau_{k,j}).$$

取 $\lambda=\lambda_r$ 得

$$\varphi_k(\lambda_r)=\frac{\det\big(K_k^T(H^2-\lambda_rH)K_k\big)}{\det(K_k^TH^2K_k)}. \tag{4.8}$$

再作 Cauchy–Binet 展开。仍写 $K_k=D_kV$。则

$$\det(K_k^TH^2K_k)=\sum_{I\in\mathcal{I}_p}\det(V_I)^2\prod_{i\in I}\lambda_i^2\,(g_{k,0}^{(i)})^2,$$

$$\det\big(K_k^T(H^2-\lambda_rH)K_k\big)=\sum_{I\in\mathcal{I}_p}\det(V_I)^2\prod_{i\in I}\lambda_i(\lambda_i-\lambda_r)\,(g_{k,0}^{(i)})^2.$$

定义 $\widetilde{\beta}_I^{(k)}:=\det(V_I)^2\prod_{i\in I}\lambda_i^2(g_{k,0}^{(i)})^2\ge 0$，$\phi_I^{(r)}:=\prod_{i\in I}(1-\lambda_r/\lambda_i)$，便有

$$\varphi_k(\lambda_r)=\frac{\sum_{I\in\mathcal{I}_p}\widetilde{\beta}_I^{(k)}\phi_I^{(r)}}{\sum_{I\in\mathcal{I}_p}\widetilde{\beta}_I^{(k)}}. \tag{4.9}$$

把 $\mathcal{I}_p$ 同样分成 A_r、B_r、C_r 三类。对 $I\in C_r$，取 $i(I)<r$、$J(I)\in A_r$，存在 $\widetilde{c}_I>0$ 使

$$\frac{\widetilde{\beta}_I^{(k)}}{\widetilde{\beta}_{J(I)}^{(k)}}=\widetilde{c}_I\,\frac{(g_{k,0}^{(i(I))})^2}{(g_{k,0}^{(r)})^2}.$$

于是 $\varphi_k(\lambda_r)$ 满足引理 4.5 的假设，从而

$$\limsup_{k\in S_\varepsilon}|\varphi_k(\lambda_r)|\le\Big(1-\frac{\lambda_r}{\lambda_n}\Big)^p<1.$$

另一方面，由 $\tau_{k,j}\in[1/\lambda_n,1/\lambda_1]$ 可得存在常数 $M_r\ge 1$，使

$$|g_{k+2,0}^{(r)}|\le M_r|g_{k+1,0}^{(r)}|,\qquad k\ge 0.$$

结合这个全局界以及上一段对 S_ε 无限情形的估计，便得到引理 4.4 所需的收缩蕴含式：当 S_ε 无限时由乘子权重引理给出严格收缩，当 S_ε 有限时该蕴含式最终平凡成立。因此该条件对一切 $\varepsilon>0$ 成立。由引理 4.4 得 $g_{k,0}^{(r)}\to 0$，与 r 的最小性矛盾。故 $g_{k,0}\to 0$。

最后由块内每步乘子一致有界、$H\succ 0$ 固定，即得 $E_k\to 0$。 □

5 一般加权步长的推广

通过上一节的证明过程，可以发现真正起作用的代数结构有以下两点：

- 块乘子多项式 ψ_k（或 φ_k）在每个 λ_r 处都可以写成两个对称行列式之比；
- 在 Cauchy–Binet 展开后，$\psi_k(\lambda_r)$ 化为一组以 $\beta_I^{(k)} \geq 0$ 为权重、以 $\phi_I^{(r)}$ 为函数值的加权平均，并且该权重的相对比可以由初始梯度分量的平方之比表示。

对于“取 $\theta_{k,r}^{-1}$ 作步长”这一点，证明里只用到了如下两个事实：步长属于谱区间 $[1/\lambda_n, 1/\lambda_1]$，并且整块乘子可以用对称二次型行列式比表达。这就提示我们：把 S 型步长里出现的“分母矩阵 $K_k^T K_k$”（对应权重为 1）替换为某种正定权重矩阵 $K_k^T \omega(H) K_k$，便能得到一类更一般的“ω-加权 LMSD”步长，同一证明框架完全适用。下文便把这一拓展形式化地写出来。

5.1 ω-加权 Ritz 值与广义 LMSD 步长

固定一个连续函数 $\omega : [\lambda_1, \lambda_n] \to (0, \infty)$。在严格凸二次模型 (2.5) 下，把“$H$ 在 $\mathcal{K}_p(H, g_{k,0})$ 上的标准 Ritz 值”替换为下面的 ω-加权 Ritz 值：考虑广义特征值问题

$$\big(K_k^T \omega(H) H K_k\big) v = \theta \, \big(K_k^T \omega(H) K_k\big) v. \tag{5.1}$$

由于 $\omega(H) \succ 0$，分母矩阵 $K_k^T \omega(H) K_k$ 在 K_k 满列秩时正定可逆，于是正则情形下 (5.1) 给出按重数计的 p 个实正特征值，非满秩时则先压缩到实际 Krylov 子空间。

引理 5.1. (5.1) 的特征值 $\theta_{k,0}^{\omega}, \dots, \theta_{k,p-1}^{\omega}$ 都属于 H 的谱区间，即 $\theta_{k,r}^{\omega} \in [\lambda_1, \lambda_n]$。

证明. 对任意非零 v，

$$\frac{v^T K_k^T \omega(H) H K_k v}{v^T K_k^T \omega(H) K_k v} = \frac{(K_k v)^T \omega(H) H (K_k v)}{(K_k v)^T \omega(H) (K_k v)} = \frac{\sum_i \omega(\lambda_i) \lambda_i \, u_i^2}{\sum_i \omega(\lambda_i) \, u_i^2},$$

其中 $u = K_k v$、u_i 为其第 i 个分量。这是一个以 $\omega(\lambda_i) u_i^2 \geq 0$ 为权重的 λ_i 加权平均，故落在 $[\lambda_1, \lambda_n]$ 内。再由 Courant–Fischer 极小极大定理，所有广义特征值都属于该区间。 □

定义 5.2 (ω-加权 LMSD 步长)**.** 固定 $\omega : [\lambda_1, \lambda_n] \to (0, \infty)$ 连续。令 $d_k := \dim \mathcal{K}_p(H, g_k) \leq p$。秩自适应解释下，对当前块由实际历史子空间 $\mathcal{K}_p(H, g_k)$ 经 (5.1) 提取出的 d_k 个加权 Ritz 值 $\theta_{k,r}^{\omega}$，下一有效 sweep 依次使用步长

$$\alpha_{k+1,r}^{\omega} = \big(\theta_{k,r}^{\omega}\big)^{-1}, \qquad r = 0, \dots, d_k - 1.$$

在正则非终止情形中 $d_k = p$，于是得到固定长度的 p 步 ω-加权 Ritz-sweep。

注意到 $\omega \equiv 1$ 时 $\theta_{k,r}^{\omega} = \theta_{k,r}$，定义 5.2 退化为标准 LMSD（定义 2.3）。而取 $\omega(t) = t$ 则会把分母矩阵换成 $K_k^T H K_k$，分子为 $K_k^T H^2 K_k$，相应的 $\theta_{k,r}^{\omega}$ 正是定义 2.4 中 harmonic-LMSD 步长 $\tau_{k,r}$ 的倒数（此时 $\alpha_{k+1,r}^{\omega} = 1/\theta_{k,r}^{\omega} = \tau_{k,r}$）。因此该框架同时把 S 型与 Y 型纳入一个连续族，并允许在它们之间插值。

上面给出的是步长生成规则。算法 1 则给出固定权重 ω 下对应的完整优化算法：它先用 Cauchy 步长预热以填满历史窗口，随后逐块求解小型对称正定广义特征值问题 (5.1)，取加权 Ritz 值的倒数作为该块的步长，并在每个块结束后滑动历史窗口，当历史子空间降秩时则自动改用该子空间上的有效 Ritz 值（秩自适应）。

Algorithm 1: 固定权重 ω 的 ω-加权 LMSD 方法

Input:

严格凸二次 $q(x)=\frac{1}{2}x^THx$（$H\succ 0$）；初值 x_0；块长 p；连续正权重 $\omega:[\lambda_1,\lambda_n]\to(0,\infty)$；容许误差 $\mathrm{tol}>0$.

Output:

近似解 x，满足 $\|\nabla q(x)\|\le \mathrm{tol}$。$x\leftarrow x_0$， $g\leftarrow Hx$；历史梯度束 $G\leftarrow[\,]$;

for $j=1$ **to** p **do**

  // Cauchy step preheating to fill history window

  $\alpha\leftarrow\dfrac{g^Tg}{g^THg}$;

  将 g 并入 G;

  $x\leftarrow x-\alpha g$;

  $g\leftarrow Hx$;

end

while $\|g\|>\mathrm{tol}$ **do**

  $d\leftarrow\mathrm{rank}(G)$；取列正交 $Q\in\mathbb{R}^{n\times d}$ 使 $\mathrm{span}(Q)=\mathrm{span}(G)$。; // $d\le p$，秩自适应

  $A\leftarrow Q^T\omega(H)HQ$， $B\leftarrow Q^T\omega(H)Q$;

  求解 d 维对称正定广义特征值问题 $Av=\theta Bv$，得加权 Ritz 值 $\theta_0,\dots,\theta_{d-1}\in[\lambda_1,\lambda_n]$;

  置步长队列 $\alpha_r\leftarrow\theta_r^{-1}$， $r=0,\dots,d-1$;

  for $r=0$ **to** $d-1$ **do**

    if $\|g\|\le\mathrm{tol}$ **then**

      return x;

    end

    $x\leftarrow x-\alpha_r g$； $g\leftarrow Hx$；用 g 刷新 G（移除最旧列、并入 g）;

  end

end

return x;

无论取何种连续正权重 ω，由定理 5.3 知该算法在严格凸二次问题上都具有“有限终止或全局收敛”的二分性质。

5.2 统一的全局收敛定理

定理 5.3 (ω-加权 LMSD 的全局收敛)**.** 设 q 由 (2.5) 给出，$\omega:[\lambda_1,\lambda_n]\to(0,\infty)$ 连续。考虑精确秩自适应的 ω-加权 LMSD 步长。则从任意初始块状态出发，相应块轨道要么有限步终止于原点，要么满足 $E_k\to 0$。

证明. 若某个块起点满足 $s(g_{k,0})\le p$，则实际 Krylov 子空间等于剩余活跃不变子空间。由于 $\omega(H)$ 在该子空间上仍为正定且与 H 对角可交换，(5.1) 的加权 Ritz 值就是剩余活跃特征值本身，因此下一短 sweep 使用它们的倒数并有限终止。故只需考虑正则非终止尾轨道，并可如定理 4.7 的证明开头那样删去永久为零的分量，假设剩余活跃分量始终非零且个数 $n>p$。

之后的过程也完全平行于定理 4.7 的证明。在这条尾轨道上，由命题 3.1 与 (5.1)，块

乘子多项式

$$\psi_k^{\omega}(t) := \prod_{\ell=0}^{p-1}\Big(1 - \frac{t}{\theta_{k,\ell}^{\omega}}\Big)$$

仍然满足 $g_{k+2,0} = \psi_k^{\omega}(H) g_{k+1,0}$。由引理 5.1，$\theta_{k,\ell}^{\omega} \in [\lambda_1, \lambda_n]$，因此对每个 ℓ 有 $0 \le 1 - \lambda_1/\theta_{k,\ell}^{\omega} \le 1 - \lambda_1/\lambda_n < 1$，故 $g_{k,0}^{(1)} \to 0$。

设 $r > 1$ 为满足 $g_{k,0}^{(j)} \to 0$（$j < r$）但 $g_{k,0}^{(r)} \not\to 0$ 的最小指标。对任意 $\varepsilon > 0$，仍令

$$S_{\varepsilon} := \{k \ge 1 : \ |g_{k,0}^{(r)}| \ge \varepsilon\}.$$

下面先在 S_{ε} 为无限集时估计块乘子。由广义特征值的代数关系，

$$\det\big(K_k^T \omega(H) H K_k - \lambda K_k^T \omega(H) K_k\big) = \det\big(K_k^T \omega(H) H K_k\big) \prod_{\ell=0}^{p-1}\Big(1 - \frac{\lambda}{\theta_{k,\ell}^{\omega}}\Big).$$

取 $\lambda = \lambda_r$ 得

$$\psi_k^{\omega}(\lambda_r) = \frac{\det\big(K_k^T \omega(H)(H - \lambda_r I) K_k\big)}{\det\big(K_k^T \omega(H) H K_k\big)}. \tag{5.2}$$

仍写 $K_k = D_k V$，由 Cauchy–Binet，

$$\det\big(K_k^T \omega(H) H K_k\big) = \sum_{I \in \mathcal{I}_p} \det(V_I)^2 \prod_{i \in I} \omega(\lambda_i)\lambda_i \, (g_{k,0}^{(i)})^2,$$

$$\det\big(K_k^T \omega(H)(H - \lambda_r I) K_k\big) = \sum_{I \in \mathcal{I}_p} \det(V_I)^2 \prod_{i \in I} \omega(\lambda_i)(\lambda_i - \lambda_r) \, (g_{k,0}^{(i)})^2.$$

定义

$$\beta_I^{(k,\omega)} := \det(V_I)^2 \prod_{i \in I} \omega(\lambda_i)\lambda_i \, (g_{k,0}^{(i)})^2 \ge 0, \qquad \phi_I^{(r)} := \prod_{i \in I}\Big(1 - \frac{\lambda_r}{\lambda_i}\Big),$$

则

$$\psi_k^{\omega}(\lambda_r) = \frac{\sum_{I \in \mathcal{I}_p} \beta_I^{(k,\omega)} \phi_I^{(r)}}{\sum_{I \in \mathcal{I}_p} \beta_I^{(k,\omega)}}.$$

仍将 $\mathcal{I}_p$ 分成定理 4.7 中的三类 A_r、B_r、C_r。注意 $\omega(\lambda_i)$ 是与 k 无关的正常数，故对每个 $I \in C_r$ 仍有

$$\frac{\beta_I^{(k,\omega)}}{\beta_{J(I)}^{(k,\omega)}} = \frac{\det(V_I)^2}{\det(V_{J(I)})^2} \cdot \frac{\omega(\lambda_{i(I)})\lambda_{i(I)}}{\omega(\lambda_r)\lambda_r} \cdot \frac{(g_{k,0}^{(i(I))})^2}{(g_{k,0}^{(r)})^2} = c_I^{\omega} \, \frac{(g_{k,0}^{(i(I))})^2}{(g_{k,0}^{(r)})^2},$$

其中 $c_I^{\omega} > 0$ 与 k 无关，因此满足引理 4.5 的假设 (iii)。再结合 $\phi_I^{(r)} \le \rho_r = (1 - \lambda_r/\lambda_n)^p < 1$ 与 $\phi_I^{(r)} = 0$（$I \in A_r$），便得到

$$\limsup_{k \in S_{\varepsilon}} |\psi_k^{\omega}(\lambda_r)| \le \rho_r < 1.$$

于是，在 S_{ε} 无限时可得到与 (4.5) 同型的严格收缩。当 S_{ε} 有限时，蕴含式在充分大的 k 后平凡成立。另一方面，由引理 5.1 知所有步长均落在 $[1/\lambda_n, 1/\lambda_1]$，故与 (4.6) 同样可得一个与 k 无关的全局放大界。由引理 4.4 推出 $g_{k,0}^{(r)} \to 0$，与 r 的最小性矛盾，故 $g_{k,0} \to 0$。再由块内每步乘子一致有界进一步得到 $E_k \to 0$。 $\square$

注 5.4. 该推广有几点值得注意：

(i) 取 $\omega \equiv 1$，定理 5.3 退化为定理 4.7（标准 LMSD）；取 $\omega(t) = t$，则退化为定理 4.8（harmonic-LMSD）。因此 S 型与 Y 型作为同一个 ω-族中的两个端点，被自然地连接起来。

(ii) 任意取 ω 为多项式或其他正函数，例如 $\omega(t)=t^k$（$k\in\mathbb{Z}$）或 $\omega(t)=\exp(at)$，都能得到一族新的固定记忆谱步长。它们在严格凸二次问题上都具有全局收敛性。

(iii) 另一个特例是 $\omega(t)=t^{-1}$（在 $[\lambda_1,\lambda_n]$ 上有界且正）：此时 $K_k^T\omega(H)K_k=K_k^TH^{-1}K_k$、$K_k^T\omega(H)HK_k=K_k^TK_k$，从而 (5.1) 写为 $K_k^TK_kv=\theta K_k^TH^{-1}K_kv$。其特征值是 H^{-1} 在 $\mathcal{K}_p(H,g_k)$ 上的（标准）Ritz 值的倒数（与 Y 型在 $H\mathcal{K}_p(H,g_k)$ 上的 Ritz 值不同），这给出又一种新的步长生成方式。

表 5.1 列出几种典型权重及其对应的小广义特征值问题。

表 5.1: ω-加权 Ritz 结构下的若干典型方法

$\omega(t)$	广义特征值问题	对应方法
1	$K^THKv=\theta K^TKv$	LMSD
t	$K^TH^2Kv=\theta K^THKv$	harmonic-LMSD 等价形式
t^{-1}	$K^TKv=\theta K^TH^{-1}Kv$	逆加权新变体
t^a	$K^TH^{a+1}Kv=\theta K^TH^aKv$	幂加权族

6 数值实验

本节给出四组小规模数值实验，以说明前文理论中的四个现象：块长覆盖全部活跃谱时的有限终止；不同 $\omega(t)=t^a$ 权重下的收敛行为；块长 p 与权重共同变化时的迭代步数；以及条件数增大后问题难度的变化。

所有实验均考虑对角严格凸二次函数

$$q(x)=\frac{1}{2}x^THx,\qquad H=\operatorname{diag}(\lambda_1,\dots,\lambda_n),$$

并采用第 5 节的 $\omega(t)=t^a$ 加权 Ritz 步长。前 p 步使用 Cauchy 步长预热，此后按块生成 Ritz-sweep。若活跃维数不超过 p，程序采用精确秩压缩机制，即只在实际活跃子空间上取 Ritz 值。为便于复现，初始梯度均由确定性公式

$$g_0^{(i)}=\sin(0.37(i+s))+0.3\cos(1.17(i+s))+0.5\sin(0.11(i+s))+1$$

生成，其中 s 是实验中指定的偏移量。停止准则为 $\|g_k\|\le 10^{-8}$，有限终止实验中使用 10^{-12} 作为显示阈值。

6.1 有限终止现象

取 $n=8$，谱为

$$(1,1.7,2.9,5.1,9,16,28,50),$$

取偏移量 $s=3$ 生成初始梯度。表 6.1 给出 $p=n$ 与 $p>n$ 的结果。可以看到，$p=n$ 时算法在 $p+n=16$ 步内终止；$p>n$ 时若使用秩压缩，也在 $p+n$ 步内终止。这与定理 3.5 一致。

表 6.1: 有限终止性质的实验验证（$n=8$）

块长 p	权重 $\omega(t)$	实际步数	理论上界 $p+n$	最终 $\|g\|$
8	t^{-1}, 1, t	16	16	0.0
10	t^{-1}, 1, t	18	18	0.0
12	t^{-1}, 1, t	20	20	0.0

6.2 不同权重函数的收敛行为

取 $n = 30$、$p = 4$，谱按对数均匀分布在 $[1, 500]$ 内，并取偏移量 $s = 0$。表 6.2 比较了 $\omega(t) = t^a$ 的八个取值。所有权重都能达到同一精度，说明第 5 节给出的加权 Ritz 族不只是形式推广，在该实验设置下也能稳定工作。

表 6.2: $\omega(t) = t^a$ 加权 Ritz 步长的收敛步数

权重 $\omega(t)$	迭代步数	块数	最终 $\|g\|$
t^{-2}	283	70	4.69×10^{-9}
t^{-1}	241	60	4.32×10^{-9}
$t^{-1/2}$	278	69	6.89×10^{-9}
1	230	57	5.46×10^{-9}
$t^{1/2}$	280	69	5.78×10^{-9}
t	257	64	7.31×10^{-9}
t^2	260	64	9.40×10^{-9}
t^3	264	65	5.59×10^{-9}

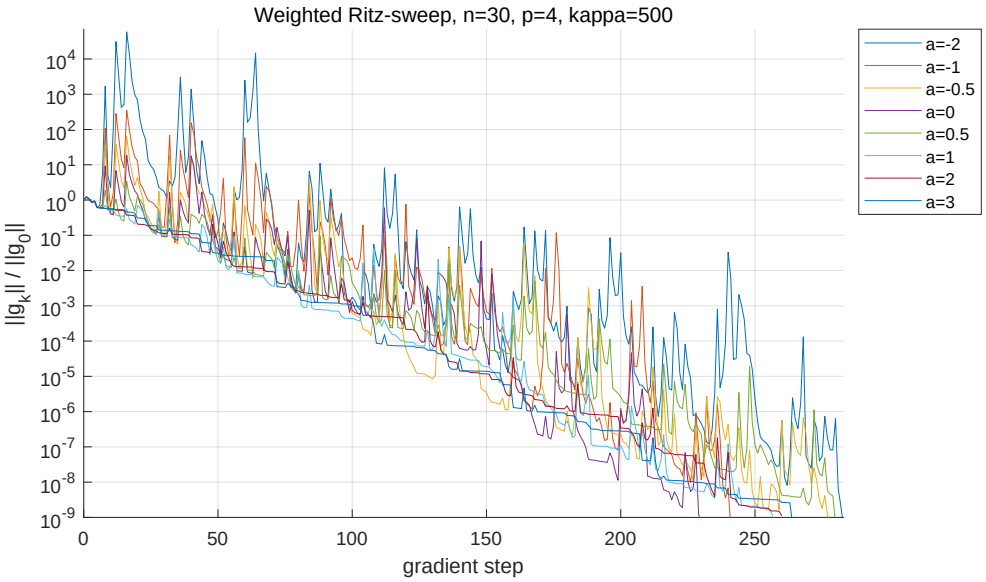

图 6.1: 不同权重 $\omega(t) = t^a$ 下的相对梯度范数下降曲线

6.3 块长与权重共同变化

进一步固定 $n = 40$，谱按对数均匀分布在 $[1, 100]$ 内，取偏移量 $s = 7$，比较 $p = 1, 2, 3, 4, 6, 8, 10$ 与 $a = -1, 0, \frac{1}{2}, 1, 2$ 的组合。表 6.3 给出达到阈值所需的迭代步数，图 6.2 展示相同数据的趋势。该测试问题中，块长增大后每个块能提取更多 Ritz 信息，达到阈值所需的迭代步数总体上有所减少（从 $p = 1$ 时的约 140 步降至 $p = 10$ 时的约 100 步），但下降幅度相对有限，且在小块长处并不严格单调。在同一块长下，权重的影响相对较温和。

表 6.3: 不同块长和不同权重下达到 $\|g\| \le 10^{-8}$ 所需的迭代步数

p	t^{-1}	1	$t^{1/2}$	t	t^2
1	147	154	139	117	142
2	149	137	153	145	126
3	120	116	121	117	116
4	123	124	111	113	120
6	112	113	106	108	104
8	100	100	100	99	107
10	96	96	103	101	103

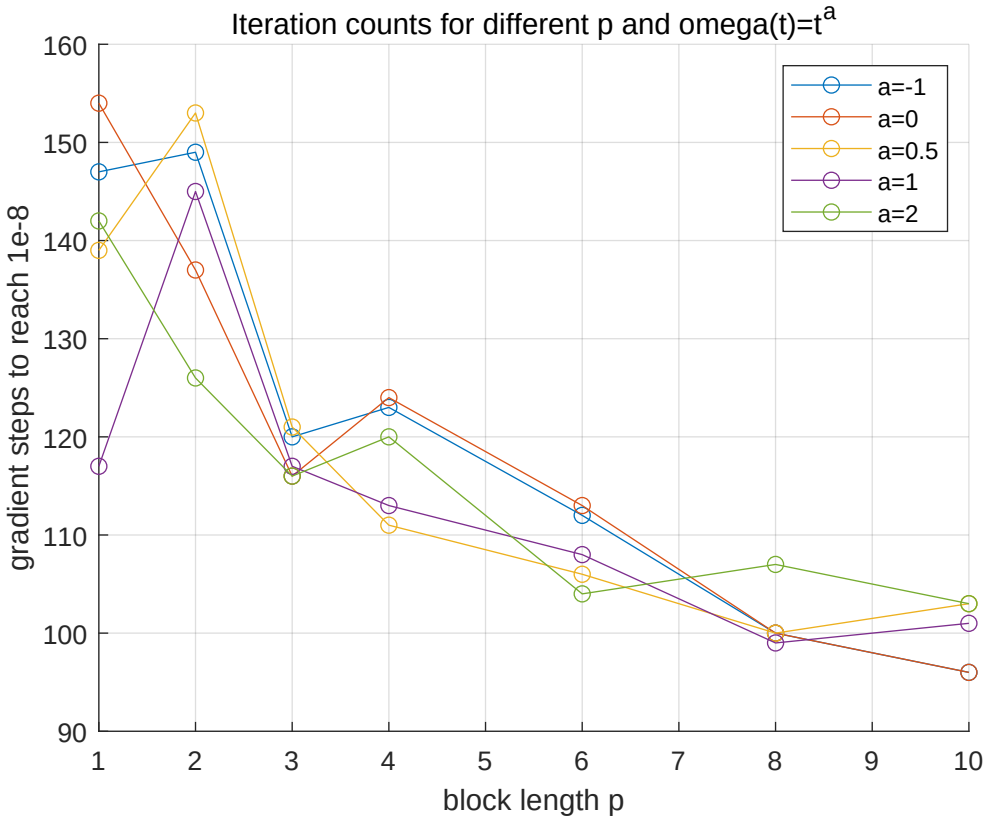

图 6.2: 表 6.3 的图示。横轴为块长 p，纵轴为达到 $\|g\| \le 10^{-8}$ 所需的迭代步数

6.4 条件数变化

最后固定 $n = 40$、$p = 4$，谱按对数均匀分布在 $[1, \kappa]$ 内，取偏移量 $s = 11$。表 6.4 给出 $\kappa = 10, 100, 1000$ 时的步数。条件数增大后，所有权重下的步数都明显上升，这与谱梯度法对谱分布敏感的经验相符。

表 6.4: 条件数变化时的迭代步数变化

κ	t^{-1}	1	t	t^2
10	35	33	34	33
100	113	116	105	112
1000	505	371	342	340

7 结语

本文的主体是 LMSD 与 harmonic-LMSD 方法在严格凸二次问题上的全局收敛证明。证明的核心在于把一整块步长作用在第 i 个谱分量上的总乘子 $\psi_k(\lambda_i)$ 写成两个对称行列式之比，再通过 Cauchy–Binet 展开化为非负权重下的加权平均，最后借助乘子权重引理逐分量地控制其极限。与 Fletcher [4] 附录中以“单个 Ritz 值的渐进位置”为分析对象的思路相比，这一改写把精确秩降作为有限终止分支单独处理，并在非终止正则区域内直接控制完整块乘子，从而绕开了接近秩降边界时单个 Ritz 值连续性失效的问题。

第 5 节的推广进一步说明：对任意连续正函数 $\omega : [\lambda_1, \lambda_n] \to (0, \infty)$ 而言，一类形式更宽的“ω-加权 LMSD”步长在同样的精确秩自适应二次模型下都享有“有限终止或全局收敛”的二分结论。S 型（标准 LMSD）与 Y 型（harmonic-LMSD）恰好对应于 $\omega \equiv 1$ 与 $\omega(t) = t$ 两个端点，因此这一框架把它们放进了同一个连续族里，并允许在两者之间自由插值。

值得指出的是，本文的证明给出一种“模板化”的分析框架范式：

$$\text{乘子可写成行列式比} \quad \Longrightarrow \quad \text{Cauchy–Binet 展开} \quad \Longrightarrow \quad \text{加权权重相对比可控.}$$

这一框架可用于分析多种由 Ritz 型乘子生成的步长规则。第 6 节的数值实验也从有限终止、权重函数变化、块长变化和条件数变化四个角度验证了这些结论的基本现象。因此，将该思路推广到更多固定记忆谱方法，可作为后续工作的一个出发点。

把“二次模型上的全局收敛”进一步提升为“全局无条件 R-线性收敛”（不再依赖 Curtis–Guo [5] 的非退化条件假设），以及把其 R-线性收敛性质传递到一般非线性问题的全局化算法中（如 GLL 非单调线搜索版本），也是很自然的推广点，这也正是笔者近期所做的主要工作。这一方向需要额外引入连续正齐次块映射的抽象工具与局部扰动控制的手段，超出了本文范围，相关讨论留待后续。

参考文献

[1] J. Barzilai and J. M. Borwein, Two-point step size gradient methods, *IMA Journal of Numerical Analysis*, 8 (1988), pp. 141–148.

[2] M. Raydan, On the Barzilai and Borwein choice of steplength for the gradient method, *IMA Journal of Numerical Analysis*, 13 (1993), pp. 321–326.

[3] Y.-H. Dai and L.-Z. Liao, R-linear convergence of the Barzilai and Borwein gradient method, *IMA Journal of Numerical Analysis*, 22 (2002), pp. 1–10.

[4] R. Fletcher, A limited memory steepest descent method, *Mathematical Programming*, 135 (2012), pp. 413–436.

[5] F. E. Curtis and W. Guo, R-linear convergence of limited memory steepest descent, *IMA Journal of Numerical Analysis*, 38 (2018), pp. 720–742.

[6] G. Ferrandi and M. E. Hochstenbach, Limited memory gradient methods for unconstrained optimization, *Numerical Algorithms*, 99 (2025), pp. 735–764.

降维的艺术：
Krylov 子空间与 GMRES 方法

张汇泽

摘 要

大规模线性方程组的求解是计算数学与科学工程计算的核心。本文从用代数工具对直接法进行处理的视角出发，梳理了 Krylov 子空间方法的底层逻辑。通过对比完全正交化方法 (FOM) 与广义极小残量法 (GMRES)，剖析了在非对称方程组求解中不同约束条件的数学本质与工程代价。文章进一步探讨了 GMRES 的提前终止现象、带重启 GMRES(m) 的停滞痛点以及预处理技术。最后，基于多项式逼近理论对 GMRES 的收敛性进行了简要分析介绍，并附以 PDE 求解的数值模拟验证。

1 引言：从逆矩阵的多项式展开到 Krylov 子空间

在求解大规模线性方程组 $Ax = b$ 时，如果矩阵 A 非奇异，我们有直接解法：$x^* = A^{-1}b$。然而，显式地计算并存储如此的高维稠密逆矩阵 A^{-1} 在工程上是极其昂贵甚至不可行的。

为了寻找更高效的求解途径，除了常规的迭代法，我们还可以仔细观察一下，到底怎么处理这个难搞的 A^{-1} 。

非常好！在科大有着扎实的线性代数基础的你，一眼就看出了，我们能否重写 A^{-1} ，变成我们喜欢的形式呢？根据 Cayley-Hamilton 定理，矩阵 A 必然满足其自身的特征多项式（或最小多项式）。设 A 的特征多项式为 $p(\lambda) = \det(\lambda I - A) = \lambda^n + c_{n-1}\lambda^{n-1} + \cdots + c_1\lambda + c_0 = 0$。由于 A 是非奇异矩阵，其常数项 $c_0 = (-1)^n \det(A) \neq 0$。

将矩阵 A 代入多项式中，我们得到：

$$A^n + c_{n-1}A^{n-1} + \cdots + c_1 A + c_0 I = 0 \tag{1.1}$$

通过移项并在等式两边同乘 A^{-1}，我们可以将逆矩阵完全表示为 A 的多项式形式：

$$A^{-1} = -\frac{1}{c_0}\left(A^{n-1} + c_{n-1}A^{n-2} + \cdots + c_1 I\right) \equiv P_{n-1}(A) \tag{1.2}$$

这表明，**矩阵的逆本质上是可以由矩阵自身的幂次线性组合而成的**。进一步地，如果我们将求解的初始猜测设为零向量 $x_0 = 0$，那么方程的精确解可以写为：

$$x^* = A^{-1}b = P_{n-1}(A)b = \gamma_0 b + \gamma_1 Ab + \cdots + \gamma_{n-1}A^{n-1}b \tag{1.3}$$

从几何上看，这说明精确解 x^* 天然地落在了由向量序列 $b, Ab, A^2b, \ldots, A^{n-1}b$ 所张成的向量空间中。

更一般地，对于任意非零的初始猜测 x_0，我们拥有初始残量 $r_0 = b - Ax_0$。因为精确解满足 $A(x^* - x_0) = b - Ax_0 = r_0$，同理可得解的修正量满足：

$$x^* - x_0 = A^{-1}r_0 = P_{n-1}(A)r_0 \quad \Longrightarrow \quad x^* \in x_0 + \operatorname{span}\{r_0, Ar_0, A^2r_0, \ldots, A^{n-1}r_0\} \tag{1.4}$$

这个由初始残量 r_0 及其不断被矩阵 A 乘积作用所生成的空间，正是著名的**第 n 阶 Krylov 子空间**，记为 $\mathcal{K}_n(A, r_0)$！

作者信息：2023 级数学科学学院，邮箱：zhz@mail.ustc.edu.cn

稿件信息：本稿件于 3 月 23 日来稿。稿件编辑：冯玉山，郑登煜

1.1 别废话了！到底怎么求解 x^* 呢？

别着急，你刚刚发现了一个极其优美的理论结论：只要我们在 Krylov 子空间 $\mathcal{K}_n(A, r_0)$ 中去寻找，就一定能找到原方程组的绝对精确解 x^*。

然而，现实是残酷的，在真实的大规模科学工程场景中，矩阵维度 n 往往高达数百万量级。我们不可能真的去生成并计算高达 n 阶的矩阵多项式。就像我们在 Taylor 展开中做的那样，我们在这里采取的妥协之举是**截断、逼近、拟合**：我们只生成前 m 个基向量（$m \ll n$，例如经验值 $m = 30$），转而在一个较低维度的仿射子空间 $x_0 + \mathcal{K}_m(A, r_0)$ 中寻找近似解 x_m。

当然，我们面临一个新的难题：因为 $m \ll n$，精确解 x^* 几乎不可能恰好落在这个极低维的子空间内。也就是说，任何一个 $x_m \in x_0 + \mathcal{K}_m$ 都会产生非零的残量 $r_m = b - Ax_m$。那么，**我们该如何在这个 m 维空间中挑出“最好”的那一个点作为最终的近似解呢？**

聪明的你，这时候又想到了：既然是求最优，那其必定是在某种条件限制下的最优，而其最优性必定也和此条件的结构紧密相关。那么，如何来定义这个限制条件呢？这正是**投影条件**（Projection Condition）必须介入的原因。我们可以从以下两个视角来理解投影约束的必然性：

视角一：自由度与约束的平衡

近似解 x_m 被限制在一个仅有 m 维的子空间中，意味着它只拥有 m 个可调的未知自由度。我们显然不能奢望用区区 m 个变量去强行满足 n 个独立方程（即使得高维残量向量完全等于零向量）。既然不能让残量在所有方向上都消失，我们需要妥协：要求残量在某个特定的 m 维“测试空间” $\mathcal{L}_m$ 上的投影为 0，即

$$r_m \perp \mathcal{L}_m \tag{1.5}$$

这相当于用测试空间中的有限个方向来规定误差的消失方式，从而把无法直接求解的高维超定问题，强行“配平”并转化为一个可解的低维投影方程。

视角二：多项式逼近的最优性标准

通过选择不同的测试空间 $\mathcal{L}_m$，我们为“最优近似解”赋予了不同的代数评价准则：

- 当 $\mathcal{L}_m = \mathcal{K}_m(A, r_0)$ 时，我们得到 Galerkin 投影条件（典型代表是完全正交化方法 FOM）。一方面，这是很自然的定义，因为天然的，我们没有必要再去引入一个太复杂的东西，用天然就有的材料就行。另一方面，直观上，它要求残量垂直于当前的搜索空间，即残量中不再包含任何属于当前搜索方向的信息。
- 当 $\mathcal{L}_m = A\mathcal{K}_m(A, r_0)$ 时，我们得到 Petrov-Galerkin 投影条件。在数学范数意义上，这严格等价于在整个 $\mathcal{K}_m$ 空间中使得残量的 2-范数 $\|r_m\|_2$ 达到极小（其典型代表即为本文的主角：广义极小残量法 GMRES）。

因此，我们在本文中讨论的 Krylov 子空间的核心逻辑是：**利用矩阵逆的多项式特性将求解问题转化为低维 Krylov 空间中的逼近，再利用不同的投影条件精确锁定最优的近似解。**

2 基底的搭建：Arnoldi 过程

不要高兴的太早，要记住我们生活在现实世界，为了让算法高效可行，我们还有很多“脏活”要干。但是，学计算数学的人就是要有勇于面对并解决真实世界中一切丑陋和不完美的勇气！（这真的不简单）

为了在数值上稳定地利用 Krylov 子空间，我们必须为其构建一组标准正交基。Arnoldi 过程承担了这一使命。

2.1 为何自然基底是“数值灾难”？

根据定义，Krylov 子空间最直观的基底是自然多项式基（也称幂基）：

$$\mathcal{K}_m = \text{span}\{r_0, Ar_0, A^2r_0, \ldots, A^{m-1}r_0\}$$

在纯粹的理论数学（无限精度）中，只要这些向量线性无关，它们完全可以作为子空间的基底。但在计算机的浮点数世界里，直接使用这组基底是一场彻头彻尾的“数值灾难”。

其根本原因在于**幂法（Power Method）效应**。为了直观理解，假设矩阵 A 拥有完备的特征向量系 $v_1, v_2, \ldots, v_n$，对应的特征值按绝对值降序排列：$|\lambda_1| > |\lambda_2| \geq \cdots \geq |\lambda_n|$。我们将初始残量在特征空间中展开：

$$r_0 = c_1v_1 + c_2v_2 + \cdots + c_nv_n$$

当我们不断用矩阵 A 左乘 r_0 时，第 k 个自然基向量为：

$$A^kr_0 = c_1\lambda_1^kv_1 + c_2\lambda_2^kv_2 + \cdots + c_n\lambda_n^kv_n = \lambda_1^k\left(c_1v_1 + c_2\left(\frac{\lambda_2}{\lambda_1}\right)^k v_2 + \cdots + c_n\left(\frac{\lambda_n}{\lambda_1}\right)^k v_n\right) \quad (2.1)$$

由于对于 $i \geq 2$，存在 $|\lambda_i/\lambda_1| < 1$。随着幂次 k 的增加，括号内后续的项会呈指数级迅速衰减。这意味着，当 k 稍微变大时，向量 A^kr_0 的方向会**迅速向绝对值最大的特征值 λ_1 对应的特征向量 v_1 的方向靠拢**。

在几何上，这意味着序列 $r_0, Ar_0, A^2r_0, \ldots$ 会变得越来越“平行”。它们不再像三维空间中的直角坐标轴那样均匀地张开，而是挤成了一把极其狭窄的“伞”，甚至退化成几乎重合的一根“针”。直白的说，就是当前选的这组基的“分辨率”不够高。

在代数上，如果我们把这些自然基向量拼成一个矩阵 $K_m = [r_0, Ar_0, \ldots, A^{m-1}r_0]$，那么矩阵的列向量将极其线性相关。此时，在典型的存在占优特征值的情形下，K_m 的条件数容易迅速恶化，甚至呈指数级增长。在这样病态的基底上求解投影方程，极微小的舍入误差都可能被显著放大，严重影响算法的有效性。

2.2 改进的 Gram-Schmidt 正交化 (MGS)

如前所述，在生成 Krylov 子空间时，直接使用自然多项式基会导致严重的条件数恶化。为了在数值上稳定地利用该子空间，Arnoldi 过程采用“边生成，边正交”的策略。这一步骤的核心正是改进的 Gram-Schmidt (Modified Gram-Schmidt, 简称 MGS) 正交化算法。

算法细节与数学推导

考虑：在 Arnoldi 过程的第 j 步，我们已经拥有一组标准正交基 $v_1, v_2, \ldots, v_j$。我们希望生成下一个与它们都正交的单位向量 v_{j+1}。数学上，我们需要在算法中使用矩阵 A 乘以上一步的正交基向量 v_j，然后与之前的 Arnoldi 向量进行正交化。

这等价于对产生的新向量进行投影分解，提出它在已有基向量上的投影，并保留与其垂直的成分：

$$Av_j = \sum_{i=1}^{j} h_{ij}v_i + h_{j+1,j}v_{j+1} \quad (2.2)$$

其中，投影系数 h_{ij} 是内积。基于 MGS 的 Arnoldi 过程具体算法如下：

Algorithm 1: 基于 MGS 的 Arnoldi 过程

计算初始残量 r_0 及其 2-范数 $\beta = \|r_0\|_2$
if $\beta == 0$ **then**
  break // 算法已收敛
end
$v_1 = r_0/\beta$
for $j = 1, 2, \ldots, m-1$ **do**
  $w_j = Av_j$
  for $i = 1, 2, \ldots, j$ **do**
    // 依次对之前的基向量做正交化
    $h_{ij} = (w_j, v_i)$
    $w_j = w_j - h_{ij}v_i$ // 算完即更新（MGS 的核心）
  end
  $h_{j+1,j} = \|w_j\|_2$
  if $h_{j+1,j} == 0$ **then**
    break // Arnoldi 过程提前终止
  end
  $v_{j+1} = w_j/h_{j+1,j}$
end

很好，我们现在提出了一个可以解决正交化问题的算法。作为一个入门的研究者，我们先不着急，仔细地看看这个算法给我们带来了什么，有没有什么“创新点”值得挖掘，有没有可以拿来发论文的东西。

Arnoldi 过程带给我们最重要的结构信息，可以浓缩为下面这个结论。

定理 2.1 (Arnoldi 关系的投影形式)**.** 设 $V_m = [v_1, v_2, \ldots, v_m] \in \mathbb{R}^{n\times m}$ 是 *Arnoldi* 过程生成的标准正交基，$\bar{H}_m \in \mathbb{R}^{(m+1)\times m}$ 是对应的上 *Hessenberg* 矩阵（即次对角线下方元素全为 *0* 的矩阵），满足

$$AV_m = V_{m+1}\bar{H}_m. \tag{2.3}$$

记 $\bar{H}_m$ 的前 m 行为 $H_m \in \mathbb{R}^{m\times m}$，则有

$$V_m^T AV_m = H_m. \tag{2.4}$$

证明. 对 Arnoldi 递推式

$$Av_j = \sum_{i=1}^{j+1} h_{ij}v_i, \qquad j = 1, 2, \ldots, m, \tag{2.5}$$

按列拼接，就得到矩阵形式 $AV_m = V_{m+1}\bar{H}_m$。（这一步是在整理我们的已有结果，蛮好验证并观察得到的，对比上一个式子，按列逐步验证即可）。现在在等式左侧乘以 V_m^T（如何想到的呢？出于对于正交性利用的观察和尝试），便有

$$V_m^T AV_m = V_m^T V_{m+1}\bar{H}_m. \tag{2.6}$$

由于 $v_1, \ldots, v_{m+1}$ 标准正交，

$$V_m^T V_{m+1} = [I_m \;\; 0], \tag{2.7}$$

因此

$$V_m^T AV_m = [I_m \;\; 0]\bar{H}_m = H_m. \tag{2.8}$$

□

需要特别注意的是，如果在第 k 步计算中发现 $h_{k+1,k} = 0$，则表明新向量 Av_k 必定可以由之前的 k 个向量完全线性表出，此时方法会发生提前终止。

为什么不用经典 CGS？

在理论上，经典 Gram-Schmidt (CGS) 与改进的 Gram-Schmidt (MGS) 是完全等价的。但在计算机的有限字长计算中，二者表现截然不同。

经典 CGS 的做法是同时投影：在计算第 j 步时，CGS 统一使用原始的新向量 $w = Av_j$ 分别和所有基向量算内积，再统一减去这些投影分量。在有限精度下，由于舍入误差的累加，这种做法极易导致新生成的向量 v_{j+1} 与原有基向量不再严格正交。一旦正交性严重丧失，后续的降维投影将失去理论基础，进而偏离期望的算法运行轨迹。

相比之下，如上述算法伪代码第 6-9 行所示，MGS 的精髓在于 **“顺序投影，算完立刻更新”**。每剔除一个方向的成分，就立刻用更新后的、更干净的向量计算下一个内积。这种贪心式的顺序更新有效抑制了舍入误差的放大，能够以极小的额外代价维持良好的基底正交性。

3 FOM 方法

3.1 完全正交化方法 (FOM)

完全正交化方法（Full Orthogonalization Method, FOM）是求解非对称线性方程组最直接的 Krylov 子空间投影方法之一。它忠实地执行了标准的 **Galerkin 投影条件**：要求第 m 步的残量 r_m 必须完全垂直（正交）于当前的搜索空间 $\mathcal{K}_m$。

算法细节与理论推导

在通过 Arnoldi 过程生成了标准正交基矩阵 $V_m = [v_1, v_2, \ldots, v_m]$ 后，我们在仿射空间中寻找的近似解可以表示为：

$$x_m = x_0 + V_m y_m \tag{3.1}$$

其中 $y_m \in \mathbb{R}^m$ 是待求的低维坐标向量。此时，对应的残量可以展开为：

$$r_m = b - Ax_m = r_0 - AV_m y_m \tag{3.2}$$

根据 Galerkin 条件 $r_m \perp \mathcal{K}_m$，在代数上严格等价于 $V_m^T r_m = 0$。将残量表达式代入，我们得到：

$$V_m^T(r_0 - AV_m y_m) = 0 \quad \Longrightarrow \quad V_m^T r_0 = V_m^T A V_m y_m \tag{3.3}$$

由于初始残量 $r_0 = \beta v_1$（其中 $\beta = \|r_0\|_2$），所以 $V_m^T r_0 = \beta V_m^T v_1 = \beta e_1$（$e_1$ 为第一单位向量）。同时，根据 Arnoldi 过程的优美性质 $V_m^T A V_m = H_m$。代入上式，整个高维的残量正交约束，坍缩为一个规模仅为 $m \times m$ 的小型线性方程组：

$$H_m y_m = \beta e_1 \tag{3.4}$$

FOM 的实用标准算法流程如下：

Algorithm 2: 实用的 FOM 方法

给定初值 $x^{(0)}$ 和 (相对) 精度要求 $\varepsilon > 0$
计算初始残量 $r_0 = b - Ax^{(0)}$，及其 2-范数 $\beta = \|r_0\|_2$
若 $\beta == 0$ 则算法收敛退出；否则计算 $v_1 = r_0/\beta$, 生成 Krylov 子空间的第 1 个标准正交基。
for $j = 1, 2, \ldots$ **do**
  $w_j = Av_j$
  for $i = 1, 2, \ldots, j$ **do**
    $h_{i,j} = (w_j, v_i)$
    $w_j = w_j - h_{i,j}v_i$
  end
  $h_{j+1,j} = \|w_j\|_2$
  求解 $j \times j$ 线性方程组：$H_j\tilde{y} = \beta e_1$
  if $h_{j+1,j}|\tilde{y}^{(j)}|/\beta < \varepsilon$ **then**
    // 直接利用标量关系式 $\|r_j\|_2 = h_{j+1,j}|\tilde{y}^{(j)}|$ 进行收敛判断。
  end
  if $h_{j+1,j} == 0$ **then**
    break // Krylov 空间发生完美闭合，已包含精确解，被迫提前终止。
  end
  $v_{j+1} = w_j/h_{j+1,j}$
  // 若尚未收敛，对完全正交化的新方向向量进行归一化，作为扩张后子空间的下一个标准正交基底。
end
计算近似解 $\tilde{x} = x^{(0)} + V_j\tilde{y}$

我们想要做得更好！

尽管 FOM 的 Galerkin 投影条件在代数结构上非常直观，但由于该方法无法保证低维投影矩阵 H_j 始终良态，在特定病态场景下，小方程的求解会变得敏感，从而在残量曲线上引发波动，放大舍入误差、加速 Arnoldi 基向量 V_j 正交性的丧失，导致算法偏离理论方向。

秉持着能打就打，打不过就跑的原则，我们希望能有一种**绕开投影矩阵潜在病态性、方便控制（极小化）残量 2-范数**的改进方案。现在，让我们掌声欢迎接——广义极小残量法 (GMRES)！

4 GMRES 方法

承接上文，为了克服 FOM 在某些非对称问题上可能出现的残量波动，GMRES 选择了 Petrov-Galerkin 条件，令测试空间 $\mathcal{L} = A\mathcal{K}_m$。这在数学上等价于**在 Krylov 子空间中严格极小化残量的 2-范数**。（我猜他就是试出来的，在 $\mathcal{K}_m$ 前面加个 A 试试看，结果发现不错，欸，就能名垂青史了）

4.1 高维极小化向低维最小二乘的转化

假设我们已经通过 Arnoldi 过程生成了正交基矩阵 V_m 及其对应的上 Hessenberg 矩阵 $\bar{H}_m$，满足核心等式：

$$AV_m = V_{m+1}\bar{H}_m \tag{4.1}$$

在 Krylov 子空间中寻找近似解 $x_m = x_0 + V_m y$ 时，其对应的残量为：

$$r_m = b - Ax_m = b - A(x_0 + V_m y) = r_0 - AV_m y \tag{4.2}$$

注意到 $r_0 = \beta v_1 = V_{m+1}(\beta e_1)$（其中 e_1 为 $m+1$ 维空间的第一单位向量），代入 Arnoldi 等式，我们可以将残量重写为：

$$r_m = V_{m+1}(\beta e_1) - V_{m+1}\bar{H}_m y = V_{m+1}(\beta e_1 - \bar{H}_m y) \tag{4.3}$$

由于 V_{m+1} 是一个列向量彼此标准正交的矩阵，它在乘法操作中不会改变向量的 2-范数长度。因此，原方程在 n 维高维空间中的极小化问题，被转化为了一个维度极低的 $(m+1)\times m$ 规模的标准最小二乘问题：

$$\min_{y\in\mathbb{R}^m} \|b - Ax_m\|_2 = \min_{y\in\mathbb{R}^m} \left\|\beta e_1 - \bar{H}_m y\right\|_2 \tag{4.4}$$

4.2 实用的 Givens 旋转

在实际的求解器中，为了求解上述小型的最小二乘问题，我们不会直接硬解法方程（Normal Equations），因为这会使矩阵条件数平方。相反，我们采用 **Givens 旋转 (Givens Rotations)**。

我们只需设计一系列的 Givens 旋转矩阵 $\Omega_1, \Omega_2, \ldots, \Omega_m$，就能逐个消去次对角线上的元素 $h_{i+1,i}$，将其转化为一个上三角矩阵 $\bar{R}_m$。

设 $Q_m = \Omega_m \Omega_{m-1} \ldots \Omega_1$，使得 $Q_m \bar{H}_m = \bar{R}_m = \begin{bmatrix} R_m \\ 0 \end{bmatrix}$。此时，由于正交变换不改变 2-范数，目标函数变为：

$$\left\|\beta e_1 - \bar{H}_m y\right\|_2 = \left\|Q_m(\beta e_1) - Q_m \bar{H}_m y\right\|_2 = \left\|\bar{g}_{m+1} - \begin{bmatrix} R_m \\ 0 \end{bmatrix} y\right\|_2 \tag{4.5}$$

设向量 $\bar{g}_{m+1} = Q_m(\beta e_1)$ 的前 m 个分量为 g_m，最后一个分量为 γ_{m+1}，则有：

$$\|b - Ax_m\|_2^2 = \|g_m - R_m y\|_2^2 + |\gamma_{m+1}|^2 \tag{4.6}$$

要使上式最小，只需令 $R_m y = g_m$ 解出 y（由于 R_m 是上三角矩阵，只需一次快速的回代求解即可），而**极小的残量范数恰好就等于最后一个元素 $|\gamma_{m+1}|$**。

注：**程序无需在每一步迭代时都去计算具体的解 x_m 和物理残量 $b - Ax_m$，仅通过监控 Givens 旋转操作产生的尾部标量 $|\gamma_{m+1}|$，即可实时获知当前的残量是否已达到收敛精度。**

其标准实现流程见 Algorithm 3：

Algorithm 3: 实用的 GMRES 方法

给定初值 $x^{(0)}$ 和 (相对) 精度要求 $\varepsilon > 0$

计算初始残量 $r_0 = b - Ax^{(0)}$，及其 2-范数 $\beta = \|r_0\|_2$

if $\beta == 0$ **then**

  return $\tilde{x} = x^{(0)}$ // 初值即为解

end

$v_1 = r_0/\beta$

令 $\xi = \beta e_1$ // 用于计算和存放右端项被 Givens 旋转后的结果

for $j = 1, 2, \ldots$ **do**

  // 开始迭代，可设置最大迭代步数

  $w_j = Av_j$

  for $i = 1, 2, \ldots, j$ **do**

    // Arnoldi 过程 (MGS)

    $h_{i,j} = (w_j, v_i)$

    $w_j = w_j - h_{i,j}v_i$

  end

  $h_{j+1,j} = \|w_j\|_2$

  // 应用之前算出的 Givens 旋转矩阵 $G_{j-1}, \ldots, G_1$ 到 H 的最新列

  for $i = 1, 2, \ldots, j-1$ **do**

    $$\begin{bmatrix} h_{i,j} \\ h_{i+1,j} \end{bmatrix} = \begin{bmatrix} c_i & s_i \\ -s_i & c_i \end{bmatrix} \begin{bmatrix} h_{i,j} \\ h_{i+1,j} \end{bmatrix}$$

  end

  if $h_{j+1,j} == 0$ **then**

    // Arnoldi 过程提前终止

    set $m = j$ **and break**

  end

  $v_{j+1} = w_j/h_{j+1,j}$

  // 构造当前的 Givens 旋转 G_j (引入分类讨论以防止数值溢出)

  if $|h_{j,j}| > |h_{j+1,j}|$ **then**

    $\tau = h_{j+1,j}/h_{j,j}, \quad c_j = \frac{1}{\sqrt{1+\tau^2}}, \quad s_j = c_j\tau$

  end

  else

    $\tau = h_{j,j}/h_{j+1,j}, \quad s_j = \frac{1}{\sqrt{1+\tau^2}}, \quad c_j = s_j\tau$

  end

  // 应用 G_j 消去次对角线元素

  $h_{j,j} = c_j h_{j,j} + s_j h_{j+1,j}, \quad h_{j+1,j} = 0$

  // 应用 G_j 到右端向量 ξ

  $$\begin{bmatrix} \xi_j \\ \xi_{j+1} \end{bmatrix} = \begin{bmatrix} c_j & s_j \\ -s_j & c_j \end{bmatrix} \begin{bmatrix} \xi_j \\ 0 \end{bmatrix}$$

  if $|\xi_{j+1}|/\beta < \varepsilon$ **then**

    // 检查残量，判断是否收敛

    set $m = j$ **and break**

  end

end

计算 $\tilde{y} = R_m^{-1}\xi(1:m)$，其中 $R_m = H(1:m, 1:m)$，$\xi(m) = \xi(1:m)$

计算近似解 $\tilde{x} = x^{(0)} + V_m\tilde{y}$

- **注 1**：纵观上述实用的 GMRES 与 FOM 算法，其核心运算量几乎完全集中在矩阵与向量的乘积上，即步骤中的 Av_j。因此，开发针对特定稀疏矩阵结构的高效矩阵-向量乘积（SpMV）代码，是提升此类算法性能的关键。
- **注 2**：在某些对正交性要求极高、条件数极其恶劣的特定场合，算法中的 Arnoldi 过程（MGS 步骤）可替换为使用 Householder 变换来实现。这能以稍大一些的计算开销为代价，换取机器精度级别的绝对正交稳定性。

4.3 提前终止了怎么办？

在 Arnoldi 过程中，如果在第 k ($k < n$) 步出现了 $h_{k+1,k} = 0$，GMRES 算法会提前终止，这时算法又该怎么应对呢？别慌，挑战伴随着机遇。在经过探讨和分析后，我们可以自信的说出：这是好事儿啊！

定理 4.1. *设 $A \in \mathbb{R}^{n\times n}$ 为非奇异矩阵，则 GMRES 方法在第 k 步提前终止（即 $h_{k+1,k} = 0$）的充要条件是：此时的近似解即为原方程组的精确解。*

证明：当 $h_{k+1,k} = 0$ 时，$\bar{H}_k$ 的最后一行全为 0。这意味着 Arnoldi 等式 $AV_k = V_{k+1}\bar{H}_k$ 变为了方阵形式：

$$AV_k = V_k H_k \tag{4.7}$$

此时，Krylov 子空间 $\mathcal{K}_k$ 成为了矩阵 A 的不变子空间。

此时的最小二乘问题退化为求解精确的方阵方程组 $H_k\tilde{y} = \beta e_1$。（之前我们得到的是一个 $(m+1)\times m$ 的最小二乘问题，而现在，由于 H_k 是方阵，我们可以对其精确求解），将其解 $\tilde{y}$ 代入真实的残量表达式中，有：

$$\|\tilde{r}\|_2 = \|b - A\tilde{x}\|_2 = \|r_0 - AV_k\tilde{y}\|_2 = \|\beta v_1 - V_k H_k\tilde{y}\|_2 \tag{4.8}$$

提取公共矩阵 V_k 得到：

$$\|\tilde{r}\|_2 = \|V_k(\beta e_1 - H_k\tilde{y})\|_2 = \|V_k(\mathbf{0})\|_2 = 0 \tag{4.9}$$

残量绝对为 0，这说明我们找到了原方程的精确解 $\tilde{x}$，这是好事儿啊！

5 带着 GMRES 到现实世界里遛一遛

依然的，直到将算法打包成真正高效可用的工业级工具，我们还需要干一些脏活儿累活儿。但是别怕，与天斗，其乐无穷！

5.1 GMRES(m) 与收敛停滞

标准 GMRES 要求的的存储与计算量太繁重了！怎么办？

在理论上，如果不考虑浮点舍入误差，标准的 GMRES 算法在精确算术下最多迭代 n 步（矩阵的维度）后，残量必然降为 0，因此它肯定是收敛的，这和 CG（共轭梯度法）类似。

然而，对于大规模的稀疏线性方程组，我们绝不可能真的去迭代 n 步。这是因为：随着迭代步数 m 的增加，为了保持正交性并求解最小二乘问题，算法需要完整地存储前面产生的所有基向量 $v_1, v_2, \ldots, v_m$。

- **存储量**：需要存储 m 个长度为 n 的稠密向量（即矩阵 V_m），内存消耗为 $O(mn)$。当 n 达到百万级别，且 m 逐渐增大时，极其容易引发内存溢出（OOM）。
- **计算量**：在第 j 步的 MGS 正交化过程中，新向量需要与前面所有的 j 个基向量做内积并更新。前 m 步的总计算量（除了稀疏矩阵向量乘法外）呈 $O(m^2n)$ 级数爆炸。当

m 很大时，正交化的时间开销会远远超过矩阵向量乘法本身，使算法失去竞争优势，这有悖于我们的初衷。

向我们走来的是万众瞩目的 GMRES(m) 算法！

为了将运算时间和存储量控制在一个计算机可以接受的范围内，目前的通用做法是采用**重启策略 (Restarting)**。即给定一个固定的最大迭代步数 m（通常远远小于 n，如经验值 $m = 20, 30$ 或 50）：如果 GMRES 迭代到第 m 步后仍未达到精度要求，则计算出当前的近似解 $x^{(m)} \in x^{(0)} + \mathcal{K}_m$，然后将其作为新的迭代初值，清空旧的基向量，重新启动 GMRES 过程。

Algorithm 4: 带重启的 GMRES 方法：GMRES(m)

给定正整数 $m \ll n$，初值 $x^{(0)}$ 和 (相对) 精度要求 $\varepsilon > 0$
计算初始残量 $r_0 = b - Ax^{(0)}$，及其 2-范数 $\beta = \|r_0\|_2$
if $\beta == 0$ **then**
  return $\tilde{x} = x^{(0)}$ // 初值即为解
end
$v_1 = r_0/\beta$
令 $\xi = \beta e_1$
for $j = 1, 2, \ldots, m$ **do**
  执行实用 GMRES 算法中的 Arnoldi 过程、Givens 旋转及更新 ξ
end
计算 $\tilde{y} = R_m^{-1}\xi(1:m)$，其中 $R_m = H(1:m, 1:m)$
计算当前的近似解 $\tilde{x} = x^{(0)} + V_m\tilde{y}$
if $|\xi_{m+1}|/\beta < \varepsilon$ **then**
  stop 并输出结果 $\tilde{x}$
end
令 $x^{(0)} = \tilde{x}$，返回第 2 步重新启动算法

那么古尔丹，代价是什么呢？

加入重启技术虽然能解决内存和计算量的爆炸问题，但也有代价：重启意味着“失忆”——算法在每次重置时，都会丢弃上一个周期辛苦积累出的高维子空间信息。（但是，能否不全部丢完，而是对其先进行加工处理，得到我们需要的重要信息呢？可以好好想一想）这种信息的丢失会导致收敛速度减慢。如果原矩阵 A 不是正定矩阵，或者其特征值分布极其恶劣，算法可能会陷入残量完全无法下降的**停滞 (Stagnation)** 状态。

让我们做个坏人，来举个例子吧：构造一个经典的“最坏情况”原型——**循环移位矩阵 (Cyclic Shift Matrix)**：

假设我们求解 $Ax = b$：

$$A = \begin{bmatrix} 0 & 0 & \cdots & 0 & 1 \\ 1 & 0 & \cdots & 0 & 0 \\ 0 & 1 & \cdots & 0 & 0 \\ \vdots & \vdots & \ddots & \vdots & \vdots \\ 0 & 0 & \cdots & 1 & 0 \end{bmatrix}_{n\times n}, \quad b = \begin{bmatrix} 1 \\ 0 \\ 0 \\ \vdots \\ 0 \end{bmatrix} = e_1 \tag{5.1}$$

空间的演化：由于矩阵的特殊平移结构，每次用 A 左乘基向量：$b = e_1$，$Ab = e_2$，$A^2b = e_3$，$\ldots$ $A^{k-1}b = e_k$ 因此，在第 k 步（假设 $k < n$），Krylov 子空间的基底正是前 k 个标准单位向量：$\mathcal{K}_k = \text{span}\{e_1, e_2, \ldots, e_k\}$。这意味着第 k 步的近似解一定是形如

$x_k = c_1e_1 + c_2e_2 + \cdots + c_ke_k$ 的线性组合。

此时的残量 $r_k = b - Ax_k$：

$$Ax_k = c_1(Ae_1) + c_2(Ae_2) + \cdots + c_k(Ae_k) = c_1e_2 + c_2e_3 + \cdots + c_ke_{k+1} \tag{5.2}$$

$$r_k = e_1 - (c_1e_2 + c_2e_3 + \cdots + c_ke_{k+1}) \tag{5.3}$$

观察残量向量 r_k，它的第一个分量**永远是 1**，后续分量为 $-c_i$。其 2-范数的平方为：

$$\|r_k\|_2^2 = 1^2 + (-c_1)^2 + (-c_2)^2 + \cdots + (-c_k)^2 = 1 + \sum_{i=1}^{k} c_i^2 \tag{5.4}$$

GMRES 的目标是极小化 $\|r_k\|_2$。显然，由于平方项非负，其最小值只能是 1（此时必须令所有 $c_i = 0$）。

结论：在到达第 n 步之前（即 $k \le n-1$），算法所能找到的最优解只能是 $x_k = 0$，**残量永远保持为 1，没有任何下降。**直到第 n 步，空间包含了 e_n，由于 $Ae_n = e_1$，我们终于能去抵消掉 b 中的 e_1，残量才瞬间从 1 跌到 0。

来做个实验吧，构造一个维度为 $N = 50$ 的循环移位矩阵，并分别使用了无重启的标准 GMRES 与带重启的 GMRES(20) 进行数值求解，其真实物理残量的演化曲线如图 5.1 所示。可以看到，GMRES(20) 根本无法收敛，怎么办呢？

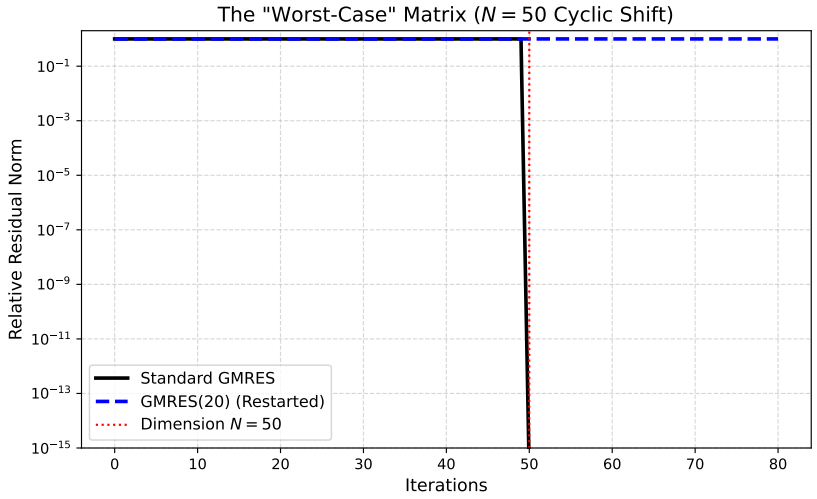

图 5.1: 循环移位矩阵的残量收敛曲线：标准 GMRES 在前 49 步残量卡在 10^0，直到第 50 步瞬间收敛；而 GMRES(20) 由于永远无法看到 50 维的全局信息，陷入了死循环，见不到黎明的曙光。

还记得我们之前提到过的对信息进行加工处理再丢掉的想法吗？实际上，这正是计算数学家们找到的一种既能控制内存开销，又能跨越重启周期保留关键谱信息的方法：**GMRES-DR（特征值剥离重启）技术**，其做法是：在重启清空内存前，计算并提取若干近似特征向量（Ritz vectors），将其保留并扩充到下一轮的初始空间中，从而减轻重启带来的“失忆”效应 [4]。但我们在这里就不过多赘述了，各位有兴趣的可以自行查阅。

6 预处理技术与数值实验验证

为了改善 GMRES 针对具有病态特征值分布的矩阵的算法效果，**预处理技术 (Preconditioning)** 是我们在真实工程中必不可少的工具技巧。同时，为了对比展示不同算法及预

处理的效果，我们设计并进行了数值实验。首先，我们先来介绍预处理方法。

6.1 左预处理 vs. 右预处理，你选哪一个？

在将预处理引入 GMRES 时，等价变形的方式在工程实现上会带来很实际的差别：

- **左预处理 (Left Preconditioning)**：求解 $M^{-1}Ax = M^{-1}b$。
  代价：此时 GMRES 在各步迭代中最小化的不再是原始的物理残量 $\|b - Ax\|_2$，而是预处理后的残量 $\left\|M^{-1}(b - Ax)\right\|_2$。这可能导致算法输出显示残量已经降得很低，但实际的物理误差依然很大，引发误判。
- **右预处理 (Right Preconditioning)**：令 $Ax = (AM^{-1})(Mx) = b$。
  我们先引入中间变量 $y = Mx$，去求解方程组 $(AM^{-1})y = b$。求出 y 后，再通过 $x = M^{-1}y$ 还原出真实解。
  优势：右预处理的绝妙之处在于，算法在寻找极小值时，最小化的依然是**原始残量的 2-范数**：$\left\|b - AM^{-1}y\right\|_2 = \|b - Ax\|_2$。因此，在真实的 GMRES 实现中，右预处理往往是更受青睐的首选方案。

6.2 常见的预处理方法

构造预处理矩阵 M 是一门在“近似精度”和“计算代价”之间找平衡的艺术。如果 $M = A$，那计算 M^{-1} 就等于直接解原方程，本末倒置；如果 $M = I$，那就等于没做预处理。

Jacobi 预处理（对角预处理）：最简单粗暴的方法。直接取矩阵 A 的主对角线元素构成对角矩阵 M。它的求逆极度廉价，且高度支持现代 GPU 并行计算。但对于非对角占优或极其病态的矩阵，其改善效果往往杯水车薪。

不完全 LU 分解（ILU, Incomplete LU Factorization）：这是目前在非对称矩阵求解中**最经典、最通用**的预处理方法。标准的 LU 分解会产生严重的“填充 (Fill-in)”现象，也就是把原本稀疏的矩阵变成稠密矩阵，使得问题丧失优良的稀疏性，这不是我们想要的。因此，ILU 的核心思想是：在做高斯消元时，**强行丢弃 (Drop)** 那些绝对值非常小的元素，强制保持下三角矩阵 $\tilde{L}$ 和上三角矩阵 $\tilde{U}$ 的高度稀疏性。这样得到的 $M = \tilde{L}\tilde{U} \approx A$ 既极大地改善了原矩阵的特征值分布，又使得每次应用预处理时的前推代回求解极其迅速。

6.3 实验设计

我们选用**二维对流占优的对流扩散方程**作为测试模型：

$$-\nu\Delta u + \vec{v} \cdot \nabla u = f \quad \text{in } \Omega \tag{6.1}$$

为了保证实验结果的可核查与可复现性，本节的数值实验参数设置如表 6.1 所示。

表 6.1: 数值实验设置表

参数项	设定取值 / 方法
求解区域 Ω	$[0,1] \times [0,1]$
边界条件	齐次 Dirichlet 边界条件 ($u = 0$)
右端项 f	$f(x,y) = 1$ （全 1 向量对应的物理源项）
空间离散格式	均匀网格，五点中心差分格式
对流场与扩散系数	$\vec{v} = (1,1)$, $\nu = 0.01$
网格规模 N	中等规模 $N = 50$，大规模 $N = 200$
重启截断维度 m	30 （针对带重启的算法）
收敛判定阈值 ε	10^{-8} (依据相对真实物理残量 $\|r_k\|_2 / \|r_0\|_2$)
预处理方式	ILU(0)，采用右预处理框架

由于扩散系数极小而对流场极强，采用中心差分格式离散后，得到的系数矩阵 A 呈现出高非对称性和非正规性。实验分为两个尺度：中等规模（$N = 50$，维度 2500×2500）用于精细观察残量动态；大规模（$N = 200$，维度 40000×40000）用于挑战算法的内存与时间极限。

6.4 预处理到底有啥用？

为了理解预处理究竟有啥用，我们首先在小规模网格（$N = 30$）上提取了原矩阵 A 与经过 ILU(0) 右预处理后矩阵 AM^{-1} 的全谱特征值。

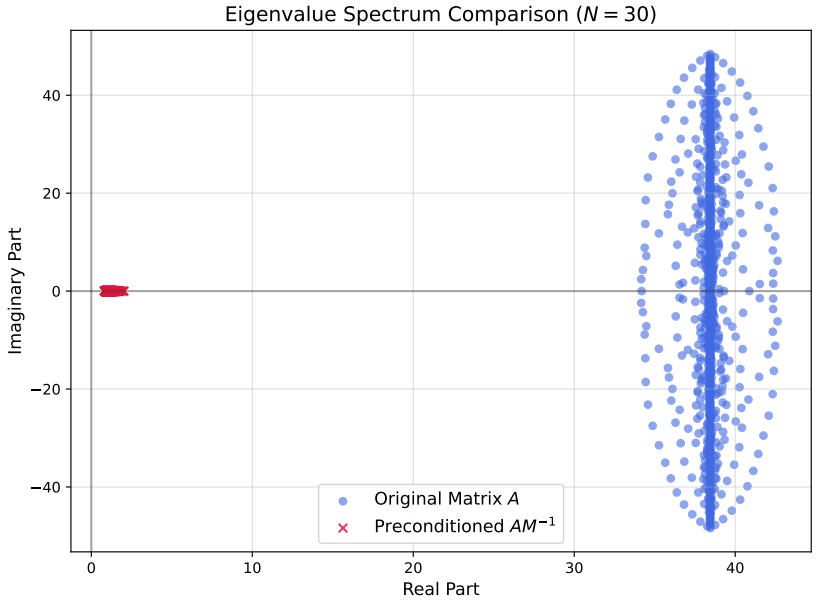

图 6.1: 预处理前后矩阵特征值在复平面上的分布对比

如图 6.1 所示，在这个具体实验中，原矩阵的特征值（蓝色原点）散乱地分布在复平面的右半侧；施加 ILU 预处理后，预处理矩阵的特征值（红色叉号）明显更集中，并更靠近 1 的附近。对于可对角化且非正规性不太强的情形，这样的谱聚集通常有利于 GMRES 构造低阶极小化多项式，从而加快收敛；但也要注意，**对非正规矩阵而言，仅凭特征值分布并不能完全解释收敛行为**，我们这里只是给出一个直观理解。

在 $N = 50$ 的网格上，我们比较 6 种不同的求解策略的算法效果。为了展示真实物理误差，我们在算法代码中并没有使用廉价的递推残量，而是在每一步内部迭代中都强行计算了**真实物理残量** $\|b - Ax_k\|_2$。

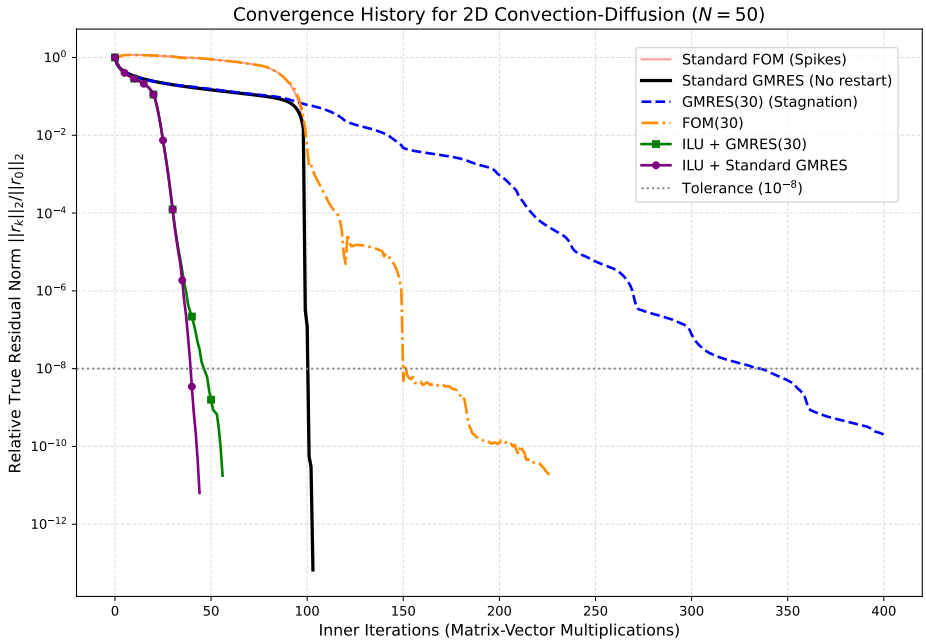

图 6.2: 中等规模（$N = 50$）下 6 种算法的真实残量收敛历史

由图 6.2 可见：

- **Standard FOM (肉红色线)**：它在最开始和 FOM(30) 重合，之后与标准 GMRES 的曲线重合（黑色盖住了红色），说明此时投影矩阵 H_m 在当前较为温和的实验情境下，保持了较好的数值性质。

- **纯 GMRES(30) (蓝线)**：可以看出具有明显的阶段性重启特征，在预热阶段结束后，每当迭代到第 30 步时，残量都会出现明显的震荡和停滞，形成一个个“台阶”，整体收敛速度大幅减慢。

- **FOM(30) (橙色线)**：虽然在最开始与标准 FOM 完全重合，但在之后便类似于 GMRES(30)，也出现了“台阶”式的下降轨迹，额外的还出现了明显尖刺，这正是我们之前提到过的 FOM 可能出现的数值不稳定现象。

- **ILU + GMRES(30) / ILU + Standard GMRES**：施加 ILU 预处理后，无论是带重启还是不带重启的 GMRES，残量都明显更快地下降到 10^{-8} 附近，说明预处理确实显著改善了该离散系统上的迭代效果。

6.5 大规模情形下的表现

在接下来 $N = 200$（$40,000$ 个自由度）的大规模测试中，我们能更直观地从时间上比较算法优劣；结果见图 6.3 与表 6.2。

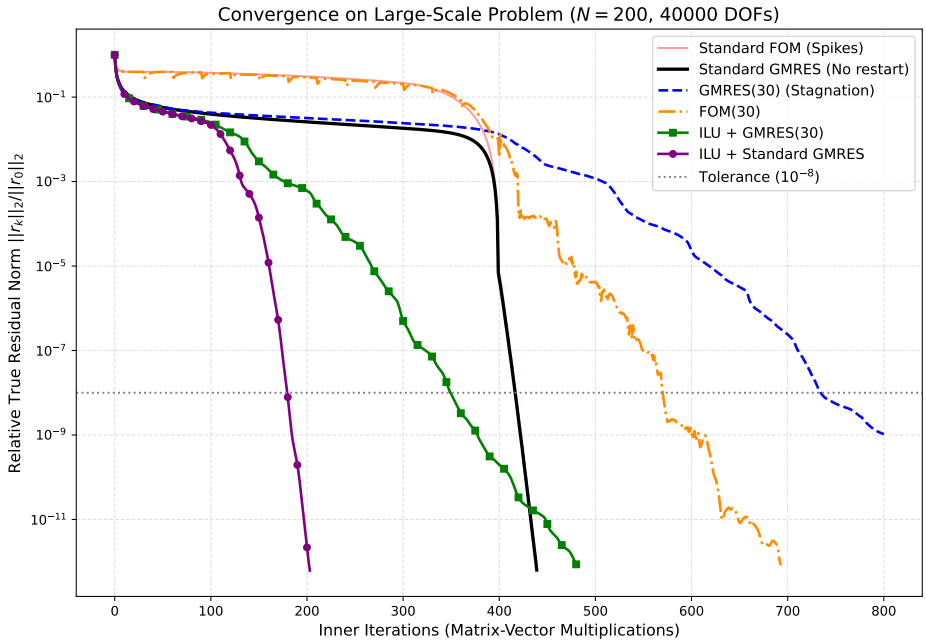

图 6.3: 大规模问题（$N = 200$，40000 自由度）下各算法的残量收敛历史

表 6.2: 大规模测试 (40000×40000) 迭代步数与 Wall-clock 耗时对比

算法名称	总迭代步数	总耗时 (秒)
Standard FOM	439	100.98
Standard GMRES	**439**	**118.22**
FOM(30)	693	11.08
GMRES(30)	800 (未收敛)	14.64
ILU + Standard GMRES	203	25.19 (含 ILU 构造 0.18s)
ILU + GMRES(30)	**481**	**14.07** (含 ILU 构造 0.18s)

观察：在这组实验里，预处理方法的引入显著提升了 GMRES 的收敛效率；而带重启法虽然往往需要更多步数，但由于单步计算与存储开销较小，整体耗时未必更差。这也说明在实际计算中，“迭代步数最少”并不等同于“总耗时最短”。另外的，可以观察到，在当前的大规模问题下，FOM(30) 的数值不稳定现象更为明显，残量曲线中出现了更多的尖刺和震荡，这也验证了我们之前的分析。

7 收敛性分析

GMRES 的极小化过程可以完全转化为一个复平面上的**多项式逼近问题**。设

$$\mathcal{K}_k = \mathrm{span}\{r_0, Ar_0, \ldots, A^{k-1}r_0\}. \tag{7.1}$$

由于 $x_k = x_0 + z_k$（其中 $z_k \in \mathcal{K}_k$），其残量总可以写为

$$r_k = b - Ax_k = r_0 - Az_k = q(A)r_0, \tag{7.2}$$

其中 q 是一个常数项为 1、阶数不超过 k 的多项式，即 $q \in P_k$ 且 $q(0) = 1$。

因为 GMRES 在 Krylov 子空间中最小化残量的 2-范数，所以它天然满足：

$$\|r_k\|_2 = \min_{q\in P_k, q(0)=1} \|q(A)r_0\|_2 \tag{7.3}$$

7.1 核心收敛界

如果矩阵 A 拥有良好的对角化性质，我们可以写出 GMRES 最经典的基本收敛界 [2, 5, 3]：

定理 7.1 (GMRES 的基本收敛界)**.** *设矩阵 $A \in \mathbb{R}^{n\times n}$ 是可对角化的，即存在非奇异矩阵 X 和对角矩阵 $\Lambda = diag(\lambda_1, \ldots, \lambda_n)$ 使得 $A = X\Lambda X^{-1}$。设 x_k 是 GMRES 方法第 k 步的近似解，则其相对残量满足：*

$$\frac{\|r_k\|_2}{\|r_0\|_2} \le \kappa_2(X) \min_{q\in P_k, q(0)=1} \max_{\lambda\in\sigma(A)} |q(\lambda)| \tag{7.4}$$

其中 $\sigma(A)$ 是 A 的特征值集合，$\kappa_2(X) = \|X\|_2 \left\|X^{-1}\right\|_2$ 是特征向量矩阵 X 的谱条件数。

7.2 圆盘定理

定理 7.2 (特征值聚集圆盘的收敛率)**.** *假设可对角化矩阵 A 的特征值全部包含在复平面上一个以 c ($c \neq 0$) 为圆心、R 为半径的闭圆盘 $D(c, R)$ 中，且原点不在圆盘内（即 $R < |c|$）。则 GMRES 的相对残量有如下渐近界：*

$$\frac{\|r_k\|_2}{\|r_0\|_2} \le \kappa_2(X) \left(\frac{R}{|c|}\right)^k \tag{7.5}$$

圆盘收敛界可以帮助我们理解观察到的部分预处理加速现象：

如果预处理后矩阵的特征值更集中地分布在远离原点、靠近 1 的区域，那么包围它们的圆盘半径 R 会变小而圆心 c 仍保持非零，此时收缩因子 $R/|c|$ 也会随之减小。从这个意义上说，谱聚集往往有利于提高 GMRES 的收敛速度。不过，对非正规矩阵仍需保持谨慎：常数因子 $\kappa_2(X)$ 以及更细致的伪谱效应，依然可能对实际收敛造成显著影响。关于这类 Krylov 方法的详细探究，可参考相关讲义材料 [6]。

8 总结

关于 Krylov 子空间，还有很多值得继续探究的内容，也还有许多重要算法本文未及展开（如 Lanczos 过程、BiCGSTAB 方法等）。本文没有追求艰深的理论铺陈，而是选取了一个在处理大规模矩阵计算时的代表方法 GMRES 作为主要介绍对象，从直观代数变换的视角出发，引出了“在 Krylov 子空间中做全局逼近”的核心思想，再落到 Arnoldi 过程、投影条件、重启、预处理与数值实验这些具体环节上。

希望本文能为刚接触计算数学的同学提供一个相对平滑的入口，让读者从一个具体算法出发，感受到现代数值计算中“几何直观、代数结构与工程实现”彼此交织的研究风格。好的思想和直觉是重要且美妙的，然而，脚踏实地，认认真真的利用好我们的数学工具解决真实的工程问题也是计算数学的独到魅力。

参考文献

[1] Saad, Y., & Schultz, M. H. (1986). GMRES: A generalized minimal residual algorithm for solving nonsymmetric linear systems. *SIAM Journal on scientific and statistical computing*, 7(3), 856-869.

[2] Saad, Y. (2003). *Iterative methods for sparse linear systems* (2nd ed.). Society for Industrial and Applied Mathematics.

[3] Trefethen, L. N., & Bau III, D. (1997). *Numerical linear algebra*. Society for Industrial and Applied Mathematics.
[4] Morgan, R. B. (2002). GMRES with deflated restarting. *SIAM Journal on Scientific Computing*, 24(1), 20-37.
[5] Greenbaum, A. (1997). *Iterative methods for solving linear systems*. Society for Industrial and Applied Mathematics.
[6] 潘建瑜. (n.d.). 迭代法与预处理 • 高性能计算：第二讲 *Krylov* 子空间方法 [讲义课件]. 华东师范大学. Retrieved from http://math.ecnu.edu.cn/~jypan

AI 时代的数学研究

——专访九重团队

数学科学学院　　郑登煜　谭皓天

引 言

人工智能正迅速进入数学研究。从文献检索、形式化验证，到提出思路、辅助证明，AI 与数学的关系正在发生深刻变化。近期，中国科学技术大学九重团队围绕 AI4Math 开展探索，并研发了面向数学研究的多智能体系统 Eureka。

九重团队核心成员包括傅孝明副教授、翟晓雅副研究员、许斌教授和孙天阳同学。傅孝明副教授研究领域为计算机图形学与计算机辅助设计，主要从事几何处理、优化、建模与制造等方向研究，已在 SIGGRAPH、SIGGRAPH Asia、ACM Transactions on Graphics 等发表论文 28 篇。翟晓雅副研究员的研究方向覆盖结构优化设计与材料设计，聚焦多物理场、多功能微结构的设计与优化，并探索材料世界与具身智能之间的深度联系，入选中国工业与应用数学学会青年人才托举工程项目、安徽省青年拔尖人才青年学者计划。许斌教授是中国科学院吴文俊数学重点实验室成员，研究方向涉及微分几何、黎曼曲面相关几何结构及其与可积系统的交叉，主持国家自然科学基金青年基金和面上项目，在 Advances in Mathematics、Mathematische Annalen 等期刊发表论文 30 余篇。孙天阳同学是数学科学学院 2023 级研究生，曾获 2024 年国家奖学金，目前主要从事 AI4Math 相关研究。

我们很荣幸邀请到九重团队四位核心成员，就 Eureka 的缘起与研发过程、AI 如何真正参与数学研究、人机协同科研的未来，以及 AI 时代数学专业学生应如何学习和成长等问题展开了一次深入交流。

1 什么是 Eureka？

Q1 九重团队是在怎样的背景下开始关注 AI 辅助数学研究的？启动 Eureka 项目的直接契机是什么？

孙天阳

团队最初关注 AI4Math，与后来决定开发 Eureka 的思路并不完全相同。最开始，我们关注的是形式化语言 Lean。年初时，AI coding agent 的能力不断提升，我判断 AI 已经能够较好地编写 Lean 代码，而过去人工把自然语言证明转成形式化语言很费劲。于是我向三位老师提出，可以重新尝试这件事，团队也在校内组织了 Lean 学习讨论班。

讨论班开展约一个月后，国内外陆续出现 AI 解决研究级数学问题的进展，例如北大董彬老师团队使用智能体解决了安德森猜想等工作。我们由此判断，AI 的能力可能已经接近研究级数学的门槛。团队因此调整方向：暂时不把重点放在自动定理证明上，而是先开发一个使用自然语言开展数学研究的系统。

许斌

我较早就关注 Lean 和大模型。2023 年，我就开始用 GPT 帮助学生润色论文。当时信息学院的周熠老师和数院的黄文院长都预测说未来会有新的科研范式。到了 2024 年，我推荐学生参加形式化数学活动，但当时自然语言数学转写为 Lean 几乎完全依靠人工，一行论证往往需要很长时间，因此觉得时机尚不成熟。到今年春节后，底座模型的能力出现明显变化。我亲自测试时发现，它已经能对博士论文级别的前沿遗留问题提出有帮助的建议，虽然还不能完全解决问题，但进步已经足够显著。

我此前主要研究黎曼曲面及其与多个纯数学分支的交叉，并不只局限于狭义的几何。过去我也尝试用超算和数值计算从大量数据中寻找一些问题里的规律。此次加入项目，一方面是因为长期关注 AI 在数学中的潜力，另一方面也因为与团队老师和孙天阳一直保持密切合作。现在 AI 已经能大规模辅助编写 Lean，这使过去成本极高的工作重新变得可行。

傅孝明

我们一直在思考，面对这一轮技术冲击，团队怎样才能做出真正有影响力的工作。最初我们创建的 Lean 讨论班推进得比较平缓，也影响了原有科研项目的节奏。经过分析，我们认为不能停留在学习和讨论层面，需要真正做出系统。早期我们对多智能体科研系统的内部机制并不熟悉，团队构建和研发组织都投入了很大精力。对我而言，直接契机就是希望抓住科研范式变化的窗口，做一项更具影响力的基础设施型工作。

翟晓雅

春节前后，AI 给我的冲击非常大。我用一两天搭建了一些系统，与它讨论博士阶段遗留的小问题，和它进行探讨也让我很有收获。我还尝试让 AI 生成大规模材料，有一次几分钟就生成了数百页内容。这种效率给我的冲击非常直接。开学时我就在组里提出，未来的课题组应该成为“智能实验室”，我认为这个“智能”就体现在我们怎样用 AI 赋能科研。

从数学学院的角度看，当时北京大学有董彬老师团队、中国科学院有高小山老师团队，中国科大也需要建设自己的基础设施平台，服务学院和更广泛的科研需求。我认为 Eureka 已经迈出了这一步。

Q2 Eureka 主要希望解决什么问题？它如何参与数学研究，流程和系统特点是什么？

傅孝明

Eureka 是一个典型的多智能体系统。通俗地说，就是让一组具有不同分工的智能体相互配合，共同完成数学研究任务。有的智能体负责澄清问题、调研论文和文献，有的负责提出研究思路，有的负责延伸、论证具体路线，还有智能体负责审查和反馈。它们形成一个 closed loop，在迭代中提高研究过程和结果的可靠性。研究结束后，系统还可以导出成果，保留中间产物，支持后续撰写论文或继续研究。

完整流程大致分为三部分。第一是立项：用户以自然语言描述问题，系统检查表述是否准确、问题是否已有研究，并通过文献调研与用户反复确认真正要解决的问题。第二是求解：系统提出若干思路，逐条论证、证明并接受审查反馈，构成循环。第三是结果沉淀：保存最终结果或其中有价值的中间内容。三个阶段都强调人机协同和人的控制。

孙天阳

我们最初想把它做成全自动科研系统，但实践表明，人类专家的经验、提示方式和方向判断非常重要，因此后来转向高度支持人类参与的人机协同系统，并尽量降低专家的使用门

槛。

Eureka 进行研究有一个很关键的过程是进行文献调研，这主要利用大模型的语义理解能力：系统根据题目生成检索关键词，搜索并尝试下载相关文献；如果文献无法下载，会提示用户协助。对于年代久远的扫描版 PDF，系统会进行深度处理，尽量还原可读文本。每篇文献都会形成精炼摘要，说明与研究问题的相关性和可用内容，作为后续智能体选择精读文献的索引，以控制时间和 token 成本。研究方向发生变化或者有新的研究成果出现时，系统还可以动态抓取新文献。系统也支持辅助阅读以及将德语、法语等文献翻译成英语。用户反馈显示，文献调研经常能找到研究者此前没有注意到、但很有价值的材料。

在人机交互方面，研究流程的每个环节都允许人类介入。用户可以提供模糊思路，让系统将其细化；也可以给出方向，由系统生成若干路线，再选择最有希望的一条执行。结果产生后，用户可以标记疑点，要求系统重点审查，也可以随时导出中间成果，与其他工具配合。

许斌

早期测试给我们的一个重要教训是：仅仅让系统自动运行很多轮，未必比专家给出精准提示词更有效。我曾把以前一位博士的博士论文中的一个猜想交给系统自动运行，生成了大量内容但没有解决问题；后来提出猜想的研究者使用 ChatGPT 用几轮准确提示就获得了很优美的证明。当时我就跟孙天阳说人机交互太重要了。底座模型容易一根筋，沿单一路线一直走下去，人机交互和专家提示非常关键。团队后来针对这一点完善了系统。

Q3 如何看待自然语言与形式化语言 Lean 的关系？

孙天阳

我认为自然语言语料更加充分，因此当前模型在自然语言推理和数学证明方面更强，适合提出、展开和交流研究；Lean 等形式化系统则有希望在验证证明正确性方面发挥重要作用。

许斌

随着 AI 生成数学证明的能力迅速增长，验证和消化这些证明会成为新的问题。当前 Lean 的不少领域仍缺少底层语料和库，但我相信 AI 能够在短时间内解决这个问题，形式化库也应更多由 AI 构建和审查，避免把大量机械工作重新交给人类。团队近期已尝试用形式化方法核验系统得到的成果。

不过，形式化验证并不是终点。即使一个结果通过 Lean 验证，如果人类无法理解、传播并将它纳入共同的数学知识体系，它仍未真正成为数学文化的一部分。我举个可能不太恰当的例子，望月新一提出的解决 ABC 猜想的理论，据我了解，由于其内容极为深奥，目前能够完全理解和验证的人仍然极少，因此学习和传播的门槛较高。从这个角度来看，我个人觉得望月新一理论的实际影响或许在一定程度上受到了限制。现在基座模型的能力也在增长，我觉得 Lean 更像一个过渡阶段。目前比较理想的流程是：自然语言提出和发展研究，形式化系统进行可靠性验证，再由人类与 AI 共同整理为可理解、可接受的数学知识。

Q4 Eureka 研发过程中遇到的主要困难和挑战是什么？

翟晓雅、傅孝明、孙天阳

最初的困难首先是人员不足。项目开始时主要由孙天阳一人推进，随后团队从其他项目协调成员，并通过校内活动、宣讲和选拔逐步吸引学生，才搭建起基础开发团队。

第二个困难是技术路线。团队此前没有搭建过此类多智能体科研系统，只能从模拟人的

研究思维出发，把证明过程建模为图或树结构，通过持续试错迭代。初版由约七名同学集中开发一周完成，虽然能处理竞赛级并达到 IMO 金牌水平，但在研究级测试中效果很不理想，后来又推倒重来。

这一过程中最重要的经验，是不要用过度复杂的人工规则限制大模型。早期方案对模型干预过多，反而压制了模型自身能力；把系统结构简化、适当“放权”后，效果出现明显改善。随着底座模型继续增强，怎样减少不必要的人为限制，同时保留关键的人机控制，是团队仍会持续优化的问题。

2 Eureka 能做什么？

Q5 Eureka 适用于哪些学科和领域？目前有哪些代表性成果？

傅孝明

由于当前系统主要使用自然语言而不是限定在某套形式化体系内，理论上各个数学方向都可以使用。团队的目标也不局限于数学：只要任务涉及理论推导或论证，例如理论物理、力学、计算机科学等，都可能成为应用场景。团队希望 Eureka 的数学推导能力进一步成为其他学科开展理论研究的基础。

孙天阳

目前较有代表性的进展，是系统解决了一个源自密码学的、已有四十多年历史的问题。这个问题是这个领域很受关注的一个问题。该结果已经过人类专家核验，我们团队目前正在合作撰写文章。除此之外，系统还在概率论、PDE、代数几何等领域产生了一些阶段性成果。由于不同结果需要相应领域专家检查，团队会在核验后通过公众号等渠道逐项介绍。欢迎大家关注我们团队的公众号“九重 JIUCHONG”。

Q6 应当如何理解 AI 在研究成果中的实际贡献？怎样界定 AI 辅助与 AI 自主研究？

许斌

这个问题我想前段时间发布并得到国际数学联盟支持的《人工智能与数学莱顿宣言》里面已经做出了阐述，大概意思就是说，AI 不作为论文作者署名，人类研究者承担全部责任，同时应适当披露使用了哪些 AI 工具。可以概括为“署名归人，责任也归人”。

但不署名并不意味着 AI 没有实质贡献。我觉得我们人类作为碳基生物要保持谦卑，要向硅基生物学习。AI 可能给出人类暂时看不懂但确有道理的思路，研究者需要保持谦逊，花时间理解其中的价值。实际成果常常来自人机反复互动，而不是简单地把猜想、证明思路和工具切割为完全属于某一方。无论 AI 参与程度多高，最终的判断、核验和责任仍应由人承担。

Q7 团队对 Eureka 下一阶段的发展有哪些计划？未来有没有可能在交叉领域开展应用？

翟晓雅

我相信 Eureka 能够在交叉领域发挥作用。团队目前正在与系统合作开展材料力学相关的理论证明，希望在后续形成阶段性成果。我们的长期期待，是让 Eureka 成为多学科共享的基础设施，不仅服务数学家，也服务力学、物理、化学以及结构材料等交叉领域的研究者。

Q8 从长期看，团队希望把 Eureka 发展成怎样的平台？

傅孝明

长期方向主要有两条。第一，继续为数学教师和学生提供科研服务，尤其通过充分的人机交互设计，让数学研究者能够真正把系统融入自己的工作。第二，从数学向外拓展，服务于其他学科以及交叉学科，使 Eureka 成为其他使用数学推导与论证的学科所需要的科研基础设施。

目前系统除服务中国科大外，也向安徽大学、合肥工业大学等兄弟院校提供使用机会，已有百余名用户，外部用户也产生了不少结果。项目并非依托一个大型专项启动，早期主要依靠团队自有项目支持和同学们的投入。受算力和经费限制，开放范围仍然有限，但团队希望未来服务更多研究者，推动数学本身的发展，以及数学与其他学科的交叉。

3 对 AI 与数学研究的看法

Q9 如何看待 AI for Math 的发展前景？它目前处于怎样的阶段？

孙天阳、傅孝明

虽然目前我们隔一两个月就能听说 AI 解决了一个大的问题，比如雅可比猜想之类的，但是从团队目前的测试来看，大语言模型和多智能体系统整体仍更擅长相对较小、边界较清楚的问题，例如补足大型证明中的某一步、处理已有论文遗留的小猜想，或改进研究者已得到但并非最优的界。研究级重大成果开始零星出现，但还不能据此准确预测三到四年后的发展速度。

许斌

我觉得 AI4Math 的发展速度在很大程度上取决于底座模型。底座模型近来的数学能力提升，与产业投入和商业竞争密切相关；如果资源持续投入，能力可能继续快速增长，但如果投入减少也可能在某一阶段出现停滞。因此，对于未来的前景有很多偶然因素，是不好预测的。

翟晓雅

我认为 AI4Math 的意义不只在数学内部。在我看来 AI4Math 是通往 AGI（通用人工智能）的一个重要的基石。这就好比为什么人从一年级要开始就要学数学，从幼儿园开始就要学加减。数学是许多学科的理论基础，当 AI4Math 进一步成熟后，有望扩展到算法、材料、生命科学、力学等更广泛的 AI for Science 场景。

Q10 未来较成熟的人机协同科研场景会是什么样？人类专家有哪些作用难以替代？

翟晓雅

现阶段，顶尖专家仍会在问题选择、研究方向、证明思路和结果验证中扮演重要角色，他们的介入能够显著放大 AI 的能力。未来具体模式难以预测，因为模型公司的研究重点、所邀请专家的领域以及算力资源，都可能影响 AI 更擅长哪些学科。

傅孝明

AI 已经改变了研究者可选择的问题范围。过去因为缺少某类专业知识、软件能力或硬

件开发经验而不敢尝试的任务，现在可以在 AI 帮助下迅速做出可用原型。例如我们最近在做一些包含大量约束规则的运筹问题，AI 可以帮助检查规则冲突和逻辑矛盾，大幅降低人工阅读成本。在 AI 的帮助下，研究者可以跨入原来不熟悉的方向，去解决很多原来感兴趣但没有解决的问题。

Q11 AI 未来能否主动提出问题、创造新的学科，并形成数学审美或科研品味？

许斌

AI 并非只能回答人类提出的问题。当前系统通常等待人类指令，更多是产品形态和安全设计造成的，并不等于 AI 没有提出问题的潜力。未来 AI 可能提出新问题、创造新工具，甚至形成新的数学分支；真正困难的是，人类能否理解、评价并承认这些机器产生的新结构。最近马骁老师有一篇推文很火，里面有一个观点叫“抽卡数学”，“抽卡数学”可以让 AI 在研究者不熟悉的领域自由探索，虽然单次成功率较低，但有机会意外产出有价值的结果；而由人类提供明确思路和指令时，AI 的科研成功率会显著更高。

翟晓雅

关于“品味”，近期已经有研究尝试把数学审美品味量化，并训练 AI 学习这种判断。如果 AI 只是模仿已有选择，未必能称为真正的品味；如果它能够综合广泛知识，持续提出独特且有价值的路线，就可能表现出某种科研审美。Eureka 的用户已经反馈，系统会给出非常独特、甚至有些“奇异”的证明思路。这些跨领域、新奇而有效的联系，可以看作形成科研品味的早期迹象，但尚不能据此断言 AI 已具备成熟、稳定的数学审美。

Q12 如果 AI 产生数学知识的速度远超人类，数学家应当怎样跟上？

许斌

即使没有 AI，人类也早已无法跟上全部数学的发展；AI 出现后更不可能做到。在没有 AI 的时候就有这么一个说法：庞加莱是最后一个数学全才。所以我们没必要跟上数学的发展，享受和硅基生物一起做数学的乐趣就行了。与其追求掌握机器生成的一切，不如关注真正重要的问题。像哥德巴赫猜想这类共同关心的问题一旦取得进展，自然会吸引大家集中理解和核验。

孙天阳

我反而觉得，在 AI 的帮助下也可能让新的“全才型”研究者重新出现。AI 是知识广博且有耐心的老师，可以全天候帮助人学习陌生领域。未来可能出现同时开展数学、物理、生物、化学、计算机乃至软硬件研究的人，也可能出现不局限于单一学科的科研系统。关键不在于读完所有结果，而在于借助 AI 建立更广的理解能力和更好的筛选机制。

Q13 如何看待部分数学研究者对 AI 的谨慎和质疑？

傅孝明、许斌、翟晓雅

我觉得这个问题也许可以“过一两年再看”。对于那些坚持传统方式、暂时不愿使用 AI 的研究者，我其实很尊重，他们当然有自己的选择。但从现在的发展趋势来看，我不太相信数学研究者能够长期完全拒绝 AI。

AI 首先已经是一个非常有用的学习工具。特别是到了博士阶段，很多时候需要快速进入一个陌生领域，遇到一些基础问题又不一定方便随时请教别人，这时 AI 可以非常耐心地解释，也不会因为问题简单而让你产生心理负担。从这个角度说，它可以是一个很好的老师、

朋友和协作者。

类似的变化其实在编程领域已经发生了。过去大家习惯自己逐行写代码，现在越来越多学生会大量借助 AI 完成代码工作。ChatGPT 刚出现时，一些高校曾经限制学生使用它完成作业，但几年之后，整体趋势已经逐渐转向鼓励学生学习如何更好地使用 AI。数学研究很可能也会经历类似的过程。

当然，真正想做 AI for Math，也并不意味着“把问题扔给 AI，自己什么都不用想”。恰恰相反，这要求研究者有很强的耐心、理解能力和判断能力。因为 AI 给出的结果是否可靠、哪些思路值得继续推进，最终仍然需要研究者自己判断。随着基础模型能力快速提升，我认为未来 AI 会越来越深地进入数学研究流程，而关键问题也会逐渐从“要不要用 AI”转变为“怎样把 AI 用好”。

Q14 对“AI 只是模仿和组合已有知识，无法进行真正原创研究”的观点，如何回应？

翟晓雅

AI 很擅长把不同领域的知识联系起来，用一个领域的方法解决另一个领域的问题，这本身就是很强的研究能力。它是否已经能够稳定地产生真正向外拓展的新知识，目前还缺少足够明确、广受认可的例子，因此不宜过早下结论。但跨领域迁移、组合并形成有效的新解法，并不能简单地视为没有原创价值。

访谈参与人员合影留念。左起：郑芳、郑登煜、翟晓雅、傅孝明、许斌、孙天阳、谭皓天。

4 作为学生如何应对 AI 时代

Q15 对数学专业低年级本科生有哪些建议？基础课程和 AI 工具应如何配合？

孙天阳

基础课仍然要认真学习。微积分、线性代数、代数和分析等课程不仅传授知识，也塑造逻辑能力和思考方式。真正与 AI 合作时，使用者必须能判断回答质量、决定何时干预和向哪个方向引导；如果对输出完全看不懂，就很难共同完成高质量工作。

AI 不应代替学生亲自完成推导、证明和思考，但可以帮助澄清概念、提供不同层次的解释。例如，过去遇到一个需要更高阶语言才能解释的概念，学生可能要先系统学习另一门课程；现在可以先与 AI 反复讨论，获得更贴近当前困惑的解释，从而加深理解。每个人也应逐步摸索适合自己的 AI 学习工作流。

傅孝明

低年级学生不只可以更早做科研，也可以更大胆地做自己真正想做的事情：开发网页、制作游戏、参加社团项目或探索跨学科问题。AI 降低了实现想法的门槛，因此学生不必完全受传统按部就班路径的束缚，应更开放地拥抱新工具。

从这个意义上说，AI 一方面带来了某种“能力平权”，让更多人能够实现过去门槛很高的想法；但这种平权以主动行动为前提。对于真正愿意做事的人，AI 会显著放大其能力，而缺乏主动性的人与前者之间的差距反而可能进一步扩大。

Q16 对已经开始科研的高年级本科生和研究生有哪些建议？

许斌

已经接受两三年传统“古法数学”训练的学生拥有宝贵基础。进入研究阶段后，可以更大胆地做真正感兴趣的问题，边做边学，把 AI 当作老师和合作伙伴。陌生知识可以通过反复追问和投入时间逐步掌握。此外仍应找到合适导师，获得经验、方向和研究判断方面的指导。

学生还需要耐心、接受挫折，并以谦逊态度与 AI 合作。AI 在知识广度上超过单个人并不值得沮丧，AI 本来就比每个人都要聪明，所以关键是学习怎样利用它。把作业和思考全部交给 AI 是最坏的用法；教育形式可能改变，但思维方式、做事方式和人的全面成长仍需要真实的教学与指导。

傅孝明

高年级学生和研究生更应该主动拥抱工具。在我们的团队实践中，部分大一、大二学生已经能承担重要工作，关键不是年级，而是是否愿意做事、是否有热情和信心。在 AI 时代，这种主动性带来的差距会比过去更明显。

教育的核心不只是知识传授，而是帮助学生形成思维方式、做事方式以及独立判断的能力。与此同时，传统的课程模式也可能需要随之调整。未来教育的价值或许会更多体现在小班讨论、问题导向、导师式指导，以及人与人之间真实的交流和引导上。

翟晓雅

对于计算和应用方向，过去的门槛往往是不会使用软件、不会实现想法；AI 正在快速降低这些障碍。研究者的重心应上移到对领域的理解、问题定义和科研品味：判断什么问题

值得做、什么问题可能产生影响。数学专业学生也不必只瞄准数学本身，可以把数学训练形成的知识和逻辑能力带到其他学科，开展真正的交叉研究。

Q17 希望进入 AI4Math 的学生，应重点学习和积累哪些知识与能力？

许斌

AI4Math 更像一个所有数学研究者都可能使用的领域，而不是边界清晰的新专业。若侧重使用 AI 研究数学，扎实的数学基础仍不可缺少，否则无法理解和判断结果；若侧重开发科研工具，则需要熟悉相关工具并真正愿意动手，但两条路径之间并没有绝对界限。

孙天阳

最近有一句比较自嘲的话，“如果一个东西没来得及学，过一个月就不用学了”。具体技术和范式变化很快，例如当前工作可概括为 harness engineering，即调控多个智能体更好地协作，但相关理论和方法也在不断出现、淘汰。因此，很难列出一套学完后才能入门的固定课程。我们团队更看重三类能力：第一，从第一性原理出发想清楚问题和系统逻辑；第二，快速接受和学习新事物，把最新工具融入工作流程；第三，有热情、肯投入并持续行动。

傅孝明

AI 显著降低了进入陌生领域的难度。只要具备基本逻辑和判断，就可以先让工具完成原型，再分析和改进。学生不要把自己限制在“只擅长某件事”的边界内，基础数学、应用数学以及不同学院之间的界限会越来越模糊，跨学科能力将变得更加重要。团队中也有原本学习基础数学的学生，后来参与机械臂、硬件和控制相关工作。过去这类跨越往往意味着先补很长一段工程背景，但现在可以借助 AI 先搭建、先实现，再在过程中补足知识。

不仅是 AI4Math 领域，现在在 AI 的帮助下，很多困难都可以跨过去。科大的同学我相信都有参与科研的能力，关键是是否有足够的热情与行动力。我们团队里已经有低年级本科生承担重要工作。例如，一位大二学生在真正投入项目后，很快成长为团队主力。在 AI 时代，年级和既有背景的重要性正在下降，主动性、学习速度和执行力反而更加关键。

5 参与机会与寄语

Q18 团队是否会为本科生和研究生提供参与项目、合作或交流学习的机会？

傅孝明、孙天阳

团队欢迎本科生和研究生参与。目前成员覆盖大一至大四，本科生也是系统开发的重要力量。团队会先讨论想法，再由同学负责功能开发、新模块或新架构的实现，完成后共同检查和迭代；低年级本科生同样可以承担关键任务。团队也有定期讨论和组会，并欢迎感兴趣的同学进一步了解、参与或旁听交流。

Q19 对关注 AI4Math、希望参与未来数学研究的青年学生有哪些期待？

傅孝明

第一，积极拥抱时代和新工具；第二，在 AI 帮助下循序渐进地向更大的问题推进，不要一开始就因挑战过大而失去信心；第三，把数学基础向交叉领域扩展，因为交叉会带来更多机会。对新生而言，也应尽早看到考试和单一路径之外的广阔世界，建立多元化的发展选择。

我们正处在一个变化极快的时代。正所谓，“历史的车轮滚滚向前”、“百年未有之大变局”，这两句话非常贴切。这既是一个充满变化和不确定性的时代，也是一个充满机会的时代。也许再过二十年回头看，最近这一两年会被认为是某种新时代真正开始的节点。

许斌

学生需要多看外部世界，关注国家发展、真实需求和未来就业，不能把自己限制在象牙塔中。传统路径正在变化，青年人应脚踏实地地考虑自己的长期发展，主动了解实用领域和社会需求。是否继续做纯数学可以依据个人热爱决定，但应保持开放，不把保研、读研或发表论文当作唯一目标。

翟晓雅

尽快建立更广的全局视野，并尽早找到真正热爱的方向。大学教育不仅是学习书本知识，更重要的是形成学习的逻辑；要把这种逻辑迁移到其他领域，使它支撑更长久的工作和生活。同时积极拥抱变化，持续培养学习新事物的能力。

孙天阳

除了学习和科研，也要重视身体锻炼、保持健康。技术进步越快，越需要良好的身体状态支持长期工作。希望同学们在拥抱新工具、积极行动的同时，也保持可持续的生活和科研节奏。

Fitch Cheney's Five-Card Trick: Combinatorial Insights and Generalization

刘飞鹏

Abstract

Fitch Cheney's Five-Card Trick is a classic magic trick rooted in combinatorial mathematics, which demonstrates the ingenious application of the pigeonhole principle, modular arithmetic, and permutation encoding. This paper first elaborates on the core strategy of the original five-card trick, explaining how a magician and their assistant can communicate the identity of a hidden card through the ordered display of four cards from a standard 52-card deck. Further, we generalize the problem to a deck of n labeled cards where a participant selects d cards, and derive the upper bound $n = d! + d - 1$ for the maximum size of the deck that allows the trick to succeed. We then prove the attainability of this upper bound using the Birkhoff–von Neumann Theorem on doubly stochastic matrices, complemented by Hall's Marriage Theorem. This work reveals the deep combinatorial structure behind the seemingly simple magic trick and showcases the universality of combinatorial principles in solving practical encoding and communication problems.

1 Introduction

Fitch Cheney's Five-Card Trick is a captivating magic performance that relies not on sleight of hand, but on rigorous combinatorial reasoning. In the classic version, a participant randomly draws five cards from a standard 52-card deck (excluding jokers). An assistant returns one card to the participant and reveals the remaining four cards to the magician in a specific order; the magician then accurately identifies the hidden card. The trick's elegance lies in the deliberate design of the hidden card and the ordered display of the four revealed cards—a communication system built on basic combinatorial tools.

While the trick appears as a simple brain teaser, its underlying mathematical framework is generalizable to arbitrary numbers of selected cards and deck sizes. This paper first unpacks the workable strategy for the original five-card trick, step-by-step explaining the use of the pigeonhole principle, modular arithmetic, and permutation encoding. We then pose the core generalized question: for a deck of n distinct cards, if a participant selects d cards and the assistant reveals $d - 1$ in an ordered sequence, what is the maximum n for which the magician can always determine the hidden card? We derive the upper bound for n via combinatorial counting arguments and prove that this bound is always attainable using the Birkhoff‐von Neumann Theorem, a key result in linear algebra and combinatorics. Finally, we discuss the implications of this generalization and note practical extensions for larger decks.

This paper is based entirely on the exposition in Kleber's article [1]. In particular, the presentation of the Fitch Cheney five-card trick, the proof via Hall's Marriage Theorem and the

作者信息: 2022 级数学科学学院，邮箱：liu1826405101@mail.ustc.edu.cn

稿件信息: 本稿件于 2 月 27 日来稿。稿件编辑：朱一方，包麒新

Birkhoff–von Neumann Theorem, the extension to the 124-card version, and the construction given in the appendix are all adapted from [1]. Our aim is to provide a systematic exposition of these ideas rather than to present new mathematical results. Detailed proofs of Hall's Marriage Theorem and the Birkhoff–von Neumann Theorem can be found in standard textbooks on combinatorics, such as Brualdi's *Introductory Combinatorics* [2].

2 The Original Five-Card Trick: A Combinatorial Strategy

The success of the original trick hinges on three core combinatorial ideas: the pigeonhole principle, modular arithmetic modulo 13 (for card ranks), and permutation encoding of three cards (for conveying a numerical value). We first define the set of cards: a standard deck has four suits (spades ♠, hearts ♡, clubs ♣, diamonds ♢) and 13 ranks (1 = Ace to 13 = King), with a total order imposed on all cards for permutation purposes: spades > hearts > clubs > diamonds by suit, and rank order for the same suit.

2.1 Step 1: Fix the Suit of the Hidden Card (Pigeonhole Principle)

A participant selects five cards, and a standard deck has four suits. By the pigeonhole principle, at least two of the five cards must share the same suit. The assistant uses this fact to fix the suit of the hidden card: one of the two same-suit cards is placed as the first revealed card, and the other is chosen as the hidden card. This immediately communicates the suit of the hidden card to the magician—an essential first step.

2.2 Step 2: Resolve the Rank Ambiguity with Modular Arithmetic

The first revealed card gives the suit, but there are 12 remaining possible ranks for the hidden card (excluding the rank of the first card). The three remaining revealed cards can only be permuted in 3! = 6 ways, which initially seems insufficient to encode 12 values. The critical solution is choosing which of the two same-suit cards to hide (rather than hiding a fixed one), paired with modular arithmetic modulo 13.

We formalize this with a key lemma:

Lemma 2.1. For any distinct integers $a, b \in \{1, 2, \ldots, 13\}$, there exists a unique integer $c \in \{1, 2, \ldots, 6\}$ such that either

$$a + c \equiv b \pmod{13}$$

or

$$b + c \equiv a \pmod{13}.$$

Proof. Arrange the numbers $1, 2, \ldots, 13$ equally spaced on a circle in cyclic order. Since $a \neq b$, the two points labeled a and b divide the circle into two arcs. Let the lengths of these two arcs be d and $13 - d$, where $1 \leq d \leq 12$.

Since the sum is 13, the smallest one of the two arc lengths is at most 6;

If the arc from a to b has length at most 6, let c be its length. Then

$$a + c \equiv b \pmod{13}.$$

Otherwise, the arc from b to a has length at most 6. Let c be its length. Then

$$b + c \equiv a \pmod{13}.$$

Done. □

This lemma guarantees that for the two same-suit cards (ranks a and b), the assistant is able to find one base card (x) to place first, hide the other card (y), and find a $c \in \{1, ..., 6\}$ such that $x + c \equiv y \pmod{13}$. Then the assistant place the base card (x) first and hide the other card (y) which the magician will guess. The value x is visible to the magician, c is the only information the magician needs to compute the rank of the hidden card—now the problem reduces to encoding c using the three middle cards.

2.3 Step 3: Encode c via Permutation of Three Cards

With the total order on all cards defined, the remaining three revealed cards have a unique relative order, which the assistant maps to the value c using a fixed code (Table 1). The magician decodes the permutation to get c, then computes $a + c \pmod{13}$ to find the rank of the hidden card—combining this with the suit from the first card gives the full identity of the hidden card.

表 1.1: Permutation Code for Three Cards

Relative Order	Code c
Small, Middle, Large	1
Small, Large, Middle	2
Middle, Small, Large	3
Middle, Large, Small	4
Large, Small, Middle	5
Large, Middle, Small	6

2.4 Example Application

Suppose the four revealed cards are 7♠ , Q♡, 8♣, 3♢ in order.

1. Suit: The first card is a spade, so the hidden card is a spade.
2. Permutation Decoding: The middle three cards (Q♡, 8♣, 3♢) follow the order Large, Middle, Small, which maps to $c = 6$.
3. Rank Calculation: $7 + 6 = 13 \pmod{13}$, so the rank is 13 (King).

The hidden card is therefore the King of spades (K♠)—a perfect illustration of the strategy.

3 Generalization of the Trick: Combinatorial Bounding

We now generalize the original problem to a deck of n distinct labeled cards (1 to n) with the following setup:

1. A participant selects d cards from the deck.
2. The assistant hides one card and reveals the remaining $d-1$ in a linear order (a permutation of the $d-1$ cards).
3. The magician infers the hidden card from the ordered sequence of $d-1$ cards.

The core question is: What is the maximum value of n for which a valid strategy always exists? We first derive an upper bound for n via combinatorial counting, then prove this bound is attainable (tight) using the Birkhoff–von Neumann Theorem.

3.1 Upper Bound Derivation

We define two key combinatorial quantities for the problem:

1. Number of possible hands: A participant selecting d cards from n has $\binom{n}{d}$ distinct hands (unordered sets).
2. Number of possible messages: The assistant reveals $d-1$ ordered cards (a permutation),

so the number of distinct messages is the number of ordered $d-1$-tuples from n cards: $n \times (n-1) \times \cdots \times (n-d+2) = \frac{n!}{(n-d+1)!}$.

A successful strategy assigns to each d-card hand a compatible ordered $d-1$-tuples. This assignment must be injective; otherwise the same displayed tuple would correspond to two different hidden cards, and the magician could not determine the hidden card uniquely. This gives the inequality:

$$\frac{n!}{(n-d+1)!} \geq \binom{n}{d}$$

Rearranging gives the upper bound for n:

$$n \leq d! + d - 1$$

For the original five-card trick ($d = 5$), this upper bound is $5! + 5 - 1 = 120 + 4 = 124$—a striking result: the trick is not limited to a 52-card deck, but can be extended to a deck of 124 cards with a valid strategy!

3.2 Attainability of the Upper Bound

The upper bound $n = d! + d - 1$ is always attainable, meaning there exists a valid strategy for the trick for this maximum deck size. We prove this using the Birkhoff–von Neumann Theorem (a key result on doubly stochastic matrices), with Hall's Marriage Theorem as a foundational tool for the proof of the Birkhoff–von Neumann Theorem.

To prove that the upper bound $n = d! + d - 1$ is attainable, our goal is to construct a valid encoding strategy for the generalized card trick. This can be viewed as a matching problem on a bipartite graph. One part of the graph consists of all possible hands (unordered d-card sets), while the other part consists of all possible ordered messages (ordered sequences of the remaining $d-1$ displayed cards). An edge connects a hand to a message whenever the message can be produced from that hand.

A valid strategy is precisely a one-to-one assignment that associates each hand with a compatible message, while ensuring that every message is used exactly once. In graph-theoretic terms, this is exactly a perfect matching in the bipartite graph. Equivalently, if we represent the bipartite graph by its incidence matrix X, then a perfect matching corresponds to a permutation matrix supported on the support of X: each row and each column contains exactly one selected entry equal to 1, and every selected entry lies in the support of X. Therefore, proving the existence of a valid strategy is equivalent to proving the existence of such a permutation matrix. That is why we use Birkhoff–von Neumann Theorem here.

Preliminaries: Doubly Stochastic Matrices and the Birkhoff–von Neumann Theorem

A doubly stochastic matrix (bistochastic matrix) is an $m \times m$ square matrix $X = (x_{ij})$ of non-negative real numbers where every row and every column sums to 1:

$$\sum_{i=1}^{m} x_{ij} = 1 \quad \forall j, \quad \sum_{j=1}^{m} x_{ij} = 1 \quad \forall i.$$

The Birkhoff–von Neumann Theorem states:

Theorem 3.1. The set of $m \times m$ doubly stochastic matrices is the convex hull of the set of $m \times m$ permutation matrices.

In other words, any doubly stochastic matrix X can be written as a convex combination of permutation matrices:

$$X = \theta_1 P_1 + \theta_2 P_2 + \cdots + \theta_k P_k,$$

where $\theta_i \geq 0$, $\sum_{i=1}^{k} \theta_i = 1$, and each P_i is a permutation matrix (a binary matrix with exactly one 1 in each row and column).

A proof of this theorem relies on Hall's Marriage Theorem: for a bipartite graph with partitions A and B, a perfect matching exists if and only if for every subset $S \subseteq A$, the number of neighbors of S is at least $|S|$. Hall's Marriage Theorem is so basic in combinatorics so we omit the proof here. See [2] for a complete proof. For a doubly stochastic matrix, we construct a bipartite graph of rows and columns (an edge exists if $x_{ij} \neq 0$)—Hall's condition is satisfied, guaranteeing a permutation matrix with non-zeros only where X has non-zeros. Induction then completes the proof (see section 3.4 for full details).

Proof of Attainability

We set $n = d! + d - 1$ (the upper bound) and construct a 0–1 matrix X for the problem:

- Rows: Indexed by the $\binom{n}{d}$ distinct hands (unordered d-card sets).
- Columns: Indexed by the $\frac{n!}{(n-d+1)!}$ distinct messages (ordered $d-1$-card sequences).
- Entries: $x_{ij} = 1$ if the $d-1$ cards of message j are all contained in hand i; otherwise $x_{ij} = 0$.

For $n = d! + d - 1$, the matrix X is square since

$$\binom{n}{d} = \frac{n!}{(n-d+1)!},$$

and every row and every column contains exactly $d!$ ones. Indeed, each hand corresponds to exactly $d!$ compatible messages, while each message is compatible with exactly $d!$ hands.

Now define

$$Y = \frac{1}{d!} X.$$

Then Y is a doubly stochastic matrix: all entries are nonnegative, and every row and column sums to 1.

By the Birkhoff–von Neumann Theorem,

$$Y = \sum_{k} \lambda_k P_k,$$

where $\lambda_k > 0$, $\sum_k \lambda_k = 1$, and each P_k is a permutation matrix.

Suppose that $Y_{ij} = 0$. If $(P_k)_{ij} = 1$ for some permutation matrix with positive coefficient λ_k, then

$$Y_{ij} = \sum_{k} \lambda_k (P_k)_{ij} \geq \lambda_k > 0,$$

which contradicts the assumption that $Y_{ij} = 0$. Therefore,

$$(P_k)_{ij} = 0$$

for every permutation matrix with positive coefficient λ_k. Hence every permutation matrix appearing in the decomposition is supported on the support of Y, and therefore also on the support of X.

In conclusion, there exists a permutation matrix P supported on the support of X. Such a permutation matrix defines a perfect matching between the set of hands and the set of compatible ordered messages: every hand is assigned a unique compatible message, and every message is assigned to a unique hand. This bijection is precisely the encoding strategy required for the generalized card trick, enabling the magician to recover the hidden card uniquely from the displayed message.

Therefore, the upper bound $n = d! + d - 1$ is attainable for every d. In particular, for the original five-card trick ($d = 5$), a valid strategy exists for a deck of 124 cards.

3.3 Existence of the Permutation Matrix P

To find the permutation matrix P supported on the non-zeros of X, we construct a bipartite graph $G = (A, B, E)$ where:

- $A = \{1, 2, ..., m\}$ (rows of X), $B = \{1, 2, ..., m\}$ (columns of X).
- $E = \{(i, j) \mid X_{ij} \neq 0\}$ (edges connect rows to columns with non-zero entries).

We verify Hall's Condition: for every subset $S \subseteq A$, let $N(S) \subseteq B$ be the set of neighbors of S; then $|N(S)| \geq |S|$.

Proof of Hall's Condition:

- For all $i \in S$, $\sum_{j \in N(S)} X_{ij} = 1$ (since all non-zeros of row i are in $N(S)$, and X is doubly stochastic). Thus:
$$|S| = \sum_{i \in S} \sum_{j \in N(S)} X_{ij} = \sum_{j \in N(S)} \sum_{i \in S} X_{ij}.$$
- For all $j \in N(S)$, $\sum_{i=1}^{m} X_{ij} = 1$, so $\sum_{i \in S} X_{ij} \leq 1$. Thus:
$$\sum_{j \in N(S)} \sum_{i \in S} X_{ij} \leq \sum_{j \in N(S)} 1 = |N(S)|.$$

Combining the two inequalities gives $|S| \leq |N(S)|$, so Hall's Condition is satisfied. A perfect matching exists in G, which defines a permutation matrix P supported on the non-zeros of X. This completes the proof of the Birkhoff–von Neumann Theorem.

Remark 3.2. To establish the attainability of the upper bound $n = d! + d - 1$, it is in fact sufficient to prove the existence of a permutation matrix supported on the support of X. The Birkhoff–von Neumann Theorem yields the stronger conclusion that every doubly stochastic matrix can be expressed as a convex combination of permutation matrices. We include its proof here for completeness and because it provides a natural theoretical framework for the attainability argument.

3.4 Proof of Birkhoff–von Neumann

Let X be an $m \times m$ doubly stochastic matrix. If there exists a permutation matrix P supported on the support of X, then the theorem holds. We prove this claim by induction.

1. Base Case: If X is a permutation matrix, then the result is immediate, since
$$X = 1 \cdot X.$$
2. Inductive Step: Assume that X is not a permutation matrix, and let
$$\lambda = \min\{X_{ij} \mid X_{ij} > 0\}$$
be the smallest positive entry of X. Let P be a permutation matrix supported on the support of X.The existence of P has been proved in the previous subseciton.
Since X is not a permutation matrix, we have $\lambda < 1$. Indeed, if $\lambda = 1$, then every positive entry of X equals 1. As every row and every column of a doubly stochastic matrix sums to 1, each row and each column would contain exactly one entry equal to 1, implying that X itself is a permutation matrix, a contradiction. Hence $1 - \lambda > 0$, so the normalization by $\frac{1}{1-\lambda}$ is well defined.
Define
$$X' = X - \lambda P.$$
   - Every entry of X' is nonnegative, since λ is the smallest positive entry of X and the support of P is contained in the support of X.

- Every row and every column of X' sums to $1 - \lambda$, since both X and P have row and column sums equal to 1.
- X' has at least one more zero entry than X, because an entry satisfying $X_{ij} = \lambda$ becomes zero after subtracting λP.

Therefore,

$$X'' = \frac{1}{1-\lambda} X'$$

is a doubly stochastic matrix with fewer nonzero entries than X. By the inductive hypothesis, X'' is a convex combination of permutation matrices. Consequently,

$$X = \lambda P + (1 - \lambda) X''$$

is also a convex combination of permutation matrices.

4 Notes and Extensions

We conclude with two key notes on the generalization and practical extensions of the trick:

4.1 Smaller Decks: Trivial Strategy Extension

For any deck size $n_1 < n_0 = d! + d - 1$, a valid strategy always exists. The set of hands for an n_1-card deck is a subset of the hands for an n_0-card deck, so the bijection (permutation matrix) for the n_0-card deck restricts to a valid bijection for the n_1-card deck. This means the strategy for the maximum deck size works for all smaller decks—including the standard 52-card deck for $d = 5$.

4.2 Practical Strategies for Larger Decks

The proof of attainability is non-constructive (it guarantees a strategy exists but does not explicitly construct it). For $d = 5$ (124-card deck), the 0-1 matrix X has 225, 150, 024 rows and columns—far too large for explicit construction by hand and imposible for a couple to perform. However, constructive strategies exist for 124-card deck, which extend the original five-card trick's strategy (pigeonhole principle + modular arithmetic + permutation encoding) to higher dimensions. The strategy is introduced in the appendix.

5 Conclusion

Fitch Cheney's Five-Card Trick is a beautiful demonstration of how basic combinatorial principles—the pigeonhole principle, modular arithmetic, and permutation encoding—can solve a seemingly intractable communication problem. By generalizing the trick to arbitrary d (selected cards) and n (deck size), we derived the tight upper bound $n = d! + d - 1$ for the maximum deck size, and proved this bound is attainable using the Birkhoff–von Neumann Theorem (with Hall's Marriage Theorem as a key tool).

This work reveals the universality of combinatorial mathematics in magic and practical problems alike: what appears as a simple magic trick is a concrete instantiation of deep combinatorial and linear algebraic ideas. For the original five-card trick, the generalization shows the trick's potential to scale to a 124-card deck—an astonishing result that highlights the power of mathematical reasoning to transform our understanding of simple systems. Future work could focus on explicit constructive strategies for larger decks (e.g., $d = 5$, $n = 124$) and extending the trick to non-card-based systems (e.g., number sets or finite sets) and the number of different strategies.

6 Appendix:Constructive Strategy for the d!+d-1-Card Deck

We now present the explicit constructive strategy for the maximum deck size $n = d! + d - 1$, with a focus on the original case $d = 5$ (the 124-card deck) for concreteness. The strategy relies on a bijection between permutations and integers via the factorial number system, which we first establish as a foundational tool.

We begin with a key construction for permutation encoding: for any positive integer n, there exists a one-to-one correspondence between the $n!$ permutations of an n-element set and the integers $0, 1, \ldots, n! - 1$. This correspondence is built on the factorial number system, where every integer $N \in \{0, 1, \ldots, (n+1)! - 1\}$ can be uniquely expressed as:

$$N = a_1 \cdot 1! + a_2 \cdot 2! + \cdots + a_n \cdot n!$$

for integers a_i satisfying $0 \le a_i \le i$ for all i.

For a permutation π of length n, define a_i as the number of elements to the right of the $(n-i)$-th element of π that are strictly smaller than this element. The function

$$f(\pi) = a_1 \cdot 1! + a_2 \cdot 2! + \cdots + a_{n-1} \cdot (n-1)!$$

establishes the desired bijection: it maps each permutation of length n to a unique integer in $0, 1, \ldots, n! - 1$, and every integer in this range is the image of exactly one permutation. See the following examples.

Example 6.1. Let $\pi = 53241$. We compute

$$a_1 = 1, \qquad a_2 = 1, \qquad a_3 = 2, \qquad a_4 = 4.$$

Hence

$$\begin{aligned} f(\pi) &= 1 \cdot 1! + 1 \cdot 2! + 2 \cdot 3! + 4 \cdot 4! \\ &= 1 + 2 + 12 + 96 \\ &= 111. \end{aligned}$$

Thus the permutation 53241 is encoded as the integer 111.

Example 6.2. Suppose $n = 5$ and we wish to find a permutation π such that

$$f(\pi) = 58.$$

Express 58 in factorial representation:

$$58 = 2 \cdot 4! + 1 \cdot 3! + 2 \cdot 2! + 0 \cdot 1!.$$

Hence

$$(a_1, a_2, a_3, a_4) = (0, 2, 1, 2).$$

The corresponding permutation is[1]

$$\pi = 42513.$$

Indeed,

$$\begin{aligned} f(42513) &= 0 \cdot 1! + 2 \cdot 2! + 1 \cdot 3! + 2 \cdot 4! \\ &= 0 + 4 + 6 + 48 \\ &= 58. \end{aligned}$$

[1] How to construct the permutation when all a_i is given? We leave this question to the reader.

We now apply this tool to the case $d = 5$ (the 124-card deck), where we label the cards in the deck with the integers $0, 1, \ldots, 123$ (a total order on the deck). Let a participant select a hand of five cards, and order these cards in strictly increasing order as $c_0 < c_1 < c_2 < c_3 < c_4$. The assistant selects c_i to be the hidden card, where the index i is determined by the congruence

$$i \equiv c_0 + c_1 + c_2 + c_3 + c_4 \pmod 5.$$

We justify this choice and decode the hidden card as follows: let s denote the sum of the four revealed cards modulo 5. The hidden card c_i satisfies

$$c_i \equiv -s + i \pmod 5.$$

After removing the four revealed cards, the remaining 120 cards are relabeled as

$$0, 1, \ldots, 119$$

according to their original order in the full deck; that is, the relative order of the remaining cards is preserved, and they are assigned consecutive labels starting from 0. Let c_i' denote the new label of the hidden card.

Since exactly i of the revealed cards have labels smaller than c_i, the relabeling shifts the label of c_i downward by i. Hence

$$c_i' = c_i - i.$$

Substituting the congruence

$$c_i \equiv -s + i \pmod 5$$

gives

$$c_i' \equiv (c_i - i) \equiv -s \pmod 5.$$

This congruence restricts the hidden card to exactly $24 = 4!$ possible candidates in the reduced deck—precisely the number of permutations of the four revealed cards. The assistant then orders the four revealed cards into a permutation that encodes an integer $p \in \{0, 1, \ldots, 23\}$ via the function $f(\pi)$ defined above. The magician decodes this permutation to get p, which uniquely identifies the hidden card among the 24 candidates.

This constructive strategy generalizes directly to any integer $d \geq 2$ for the maximum deck size $n = d! + d - 1$. For a hand of d cards ordered as $c_0 < c_1 < \cdots < c_{d-1}$, the assistant hides c_i where $i \equiv \sum_{k=0}^{d-1} c_k \pmod d$. The $d - 1$ revealed cards sum to $s \pmod d$, restricting the hidden card to $(d - 1)!$ candidates in the reduced deck, and the permutation of the $d - 1$ revealed cards encodes an integer in $0, 1, \ldots, (d - 1)! - 1$ to uniquely determine the hidden card.

Reference

[1] M. Kleber, *The Best Card Trick*, The Mathematical Intelligencer, 24(1):9–11, 2002.
[2] R. A. Brualdi, *Introductory Combinatorics*, 5th ed., Pearson, 2010.

Research on the Erdős Matching Conjecture and Focal-free uniform hypergraphs

叶钉

Abstract

In this paper, we study a generalized matching problem in extremal set theory. We introduce the notion of $(k_1, \overline{k}_2)$-disjoint families, which are simultaneously k_1-disjoint (any k_1 sets have empty intersection) and $\overline{k}_2$-disjoint (any k_2 sets have complements with empty intersection). Let $m(n, k, t; k_1, \overline{k}_2)$ denote the maximum size of a k-uniform family on $[n]$ containing no $(k_1, \overline{k}_2)$-disjoint subfamily of size t.

In Section 2, except for a general upper bound given in Theorem 2.1, all remaining results are original contributions of the author. We provide a constructive lower bound for this generalized matching number and establish its connection with the classical matching number. In particular, we prove that under suitable parameter conditions, the generalized matching number coincides with the classical matching number, yielding an exact formula. Using the shifting method, we show that when $t \equiv 1 \pmod{s}$ and n is sufficiently large,

$$m(n, k, t; s+1) = \binom{n}{k} - \binom{n - \lceil t/s \rceil + 1}{k}.$$

Furthermore, by combining our results with recent advances on the Erdős Matching Conjecture, we obtain exact results in a new range of parameters.

Additionally, this paper introduces the closely related notions of (r, s)-focal hypergraphs and focal-free families, and shows that the generalized matching number plays a key role in determining the asymptotic Turán number and code capacity in these problems.

1 Introduction and Definitions

Extremal set theory studies the maximum possible size of a set family satisfying certain combinatorial constraints. A classical problem in this area is the Erdős matching conjecture, which asks for the maximum size of a k-uniform family $\mathcal{F} \subseteq \binom{[n]}{k}$ that does not contain s pairwise disjoint edges. This corresponds to forbidding an *s-matching* in the hypergraph.

In this paper, we investigate a natural generalization of this problem. Rather than just forbidding s completely disjoint sets, we consider families that avoid more complex intersection patterns. Specifically, we say a collection of sets is $(k_1, \overline{k}_2)$-*disjoint* if it is simultaneously k_1-disjoint (no k_1 sets have common intersection) and $\overline{k}_2$-disjoint (no k_2 sets have complements with common intersection). This framework generalizes the classical matching problem while capturing more intricate combinatorial structures.

Let $m(n, k, t; k_1, \overline{k}_2)$ denote the maximum size of a k-uniform family on $[n]$ containing no $(k_1, \overline{k}_2)$-disjoint collection of size t. When $k_1 = 2$ and $k_2 = t$, this reduces to the classical matching number. Our work establishes bounds on this generalized matching number and explores its

作者信息: 2022 级数学科学学院，邮箱：lgye@mail.ustc.edu.cn

稿件信息: 本稿件于 2 月 28 日来稿。稿件编辑：朱一方，包麒新

connections to the original Erdős matching problem, providing both constructive lower bounds and structural results that extend classical extremal set theory.

Definition 1.1. Given integers n, k, k_1, k_2, t, we say a collection $A_1, A_2, \ldots, A_t$ of subsets of $[n]$ is **k-disjoint** if for each k-subset $\mathcal{B} \in \binom{[t]}{k}$, we have $\bigcap_{i\in\mathcal{B}} A_i = \emptyset$. We say this collection is **$\overline{k}$-disjoint** if for each k-subset $\mathcal{B} \in \binom{[t]}{k}$, we have $\bigcap_{i\in\mathcal{B}}([n]\backslash A_i) = \emptyset$.

We say a collection $A_1, A_2, \ldots, A_t$ of repeatable subsets of $[n]$ is **$(k_1, \overline{k}_2)$-disjoint** if it is k_1-disjoint and $\overline{k}_2$-disjoint.

Definition 1.2. For integers n, k, k_1, k_2, t, we define $m(n, k, t; k_1, \overline{k}_2)$ to be the maximum size of a family $\mathcal{F} \subseteq \binom{[n]}{k}$ such that $\mathcal{F}$ contains no $(k_1, \overline{k}_2)$-disjoint collection of size t.

These definitions generalize the classical concept of disjoint families and are central to the extremal problems we investigate in this work.

An alternative interpretation is as follows: if $A_1, A_2, \ldots, A_t$ is $(k_1, \overline{k}_2)$-disjoint, then for every point i,$t - k_2 + 1 \le \#\{A : i \in A, A \in (A_1, A_2, \ldots, A_t)\} \le k_1 - 1$,otherwise,it is easy to find $\mathcal{B}_1 \in \binom{[t]}{k_1}$ let $\bigcap_{i\in\mathcal{B}_1} A_i \neq \emptyset$ or $\mathcal{B}_2 \in \binom{[t]}{k_2}$ let $\bigcap_{i\in\mathcal{B}_2}([n]\backslash A_i) \neq \emptyset$.

2 Main result

This paper establishes several new bounds and exact formulas for $m(n, k, t; k_1, \overline{k}_2)$. Our principal contributions are threefold. First, we give a general upper bound . Second, we provide constructive lower bounds through explicit combinatorial constructions. Finally, and most significantly, we bridge the generalized matching number with the classical matching number, obtaining exact results in a new range of parameters by leveraging recent advances on the Erdős Matching Conjecture.

Theorem 2.1. [2] Let n, k, t, s_1, s_2 be positive integers with $\{t \ge s_1 + 1, s_1 n \ge tk\}$ or $\{t \ge s_2 + 1, s_2 n \ge t(n-k)\}$. Set $X = \min\{\lfloor \frac{n}{\lceil k/s_1 \rceil} \rfloor, \lfloor \frac{n}{\lceil (n-k)/s_2 \rceil} \rfloor\}$. Then

$$m(n, k, t; s_1 + 1, \overline{s_2 + 1}) \le \frac{1}{n}\binom{n}{k}\left((t-1)\left\lfloor \frac{n}{X} \right\rfloor + X - 1\right).$$

This theorem provides a general upper bound under specific density conditions. In the following sections, we will focus on deriving matching or near-matching lower bounds through explicit constructions.

We define $m(n, k, t; k_1)$ to be the maximum size of a family $\mathcal{F} \subseteq \binom{[n]}{k}$ such that $\mathcal{F}$ contains no k_1-disjoint collection of size t. We will show that

$$m(n, k, t; s_1 + 1, \overline{s_2 + 1}) \ge \max\{m(n, k, t; s_1 + 1), m(n, n-k, t; s_2 + 1)\}.$$

Indeed, for any family $\mathcal{F} \subseteq \binom{[n]}{k}$ without (s_1+1)-disjoint collection of size t, clearly $\mathcal{F}$ contains no $(s_1+1, \overline{s_2+1})$-disjoint collection of size t. This implies that $m(n, k, t; s_1+1, \overline{s_2+1}) \ge m(n, k, t; s_1+1)$. Similarly, for any family $\mathcal{F} \subseteq \binom{[n]}{k}$ without $\overline{s_2+1}$-disjoint collection of size t, $\mathcal{F}$ contains no $(s_1 + 1, \overline{s_2 + 1})$-disjoint collection of size t. On the other hand, $\mathcal{F}^c = \{[n]\backslash F : F \in \mathcal{F}\} \subseteq \binom{[n]}{n-k}$ contains no $(s_2 + 1)$-disjoint collection of size t with $|\mathcal{F}^c| = |\mathcal{F}|$, which implies that $m(n, k, t; s_1 + 1, \overline{s_2 + 1}) \ge m(n, n-k, t; s_2 + 1)$.

Now we can reduce lower bounding $m(n, k, t; s_1 + 1, \overline{s_2 + 1})$ to lower bounding a simpler number $m(n, k, t; s_1 + 1)$ (or equivalently $m(n, n-k, t; s_2 + 1)$). We will give a lower bound of $m(n, k, t; s_1 + 1)$ below.

Lemma 2.1. Let n, k, t, s be positive integers with $t \geq s+1$. Then

$$m(n,k,t;s+1) \geq \binom{n}{k} - \binom{n-\lceil t/s \rceil + 1}{k} + t - (\lceil t/s \rceil - 1)s - 1.$$

Proof. Take a subset $S \subseteq [n]$ with $|S| = \lceil \frac{t}{s} \rceil - 1$ and a family $\mathcal{F} \subseteq \binom{[n]}{k}$ such that at most $t-(\lceil t/s \rceil -1)s-1$ edges in $\mathcal{F}$ do not intersect with S. We claim that $\mathcal{F}$ contains no $(s+1)$-disjoint collection of size t. Otherwise, suppose there are $(s+1)$-disjoint $F_1, F_2, \ldots, F_t$ in $\mathcal{F}$. There are at least $(\lceil t/s \rceil -1)s+1$ F_i contains at least one element of S. Since $|S|s = (\lceil \frac{t}{s} \rceil -1)s < (\lceil t/s \rceil -1)s+1$, by Pigeonhole Principle, there exist $s+1$ many F_i's intersecting at some element of S, contradicted to the $(s+1)$-disjoint property. The claim is true. Therefore,

$$m(n,k,t;s+1) \geq \max|\mathcal{F}| = \binom{n}{k} - \binom{n-\lceil t/s \rceil + 1}{k} + t - (\lceil t/s \rceil - 1)s - 1.$$

□

Theorem 2.2. Let n, k, t, s_1, s_2 be positive integers with $t \geq \max\{s_1+1, s_2+1\}$. Let

$$m_1 = \binom{n}{k} - \binom{n-\lceil t/s_1 \rceil + 1}{k} + t - (\lceil t/s_1 \rceil - 1)s_1 - 1$$

$$m_2 = \binom{n}{k} - \binom{n-\lceil t/s_2 \rceil + 1}{n-k} + t - (\lceil t/s_2 \rceil - 1)s_2 - 1$$

Then

$$m(n,k,t;s_1+1,\overline{s_2+1}) \geq \max\{m_1, m_2\}.$$

Proof. The result follows directly by combining the lower bounds established in Lemma 2.1 with the inequality $m(n,k,t;s_1+1,s_2+1) \geq \max\{m(n,k,t;s_1+1), m(n,n-k,t;s_2+1)\}$.

□

A significant part of our analysis involves establishing conditions under which the generalized matching number $m(n,k,t;s+1)$ coincides with the classical matching number. The following result provides such an exact formula in a certain range of parameters.

Theorem 2.3. there exist absolute constant s_0 t_0,such that

$$m(n,k,t;s+1) = \binom{n}{k} - \binom{n-\lceil t/s \rceil + 1}{k}$$

holds if $n \geq (\lceil t/s \rceil - 1)(\frac{5}{3}k - \frac{2}{3})$,$t \equiv 1 \pmod{s}$,$\lceil t/s \rceil \geq \lceil t_0/s_0 \rceil$,$0 < s \leq k$.

Theorem 2.4. [1] there exist absolute constant s_0,such that

$$m(n,k,s) = \binom{n}{k} - \binom{n-s+1}{k}$$

holds if $n \geq (s-1)(\frac{5}{3}k - \frac{2}{3})$ and $s \geq s_0$.

Definition 2.1. For integers $1 \leq i < j \leq n$ and a family $\mathcal{F}$ define the (i,j)-shift S_{ij} as follows

$$S_{ij}(F) = \begin{cases} (F-\{j\})\cup\{i\} & if \quad i \notin F, j \in F, (F-\{j\})\cup\{i\} \notin F \\ F & otherwise \end{cases};$$

$$S_{ij}(\mathcal{F}) = \{S_{ij}(F) : F \in \mathcal{F}\}$$

It is not hard to see that if we keep on shifting then finally we end up with a *shifted* family $\mathcal{G}$,i.e. $S_{ij}(\mathcal{G}) = \mathcal{G}$ for all $1 \le i < j \le n$.If the family $\mathcal{F} \subset \binom{[n]}{k}$,there is another explanation for shifted.Let $(a_1, \ldots, a_k)$ stand for a k-set with $a_1 < \cdots < a_k$,and we say that $(a_1, \ldots, a_k) \prec (b_1, \ldots, b_k)$ if $a_i \le b_i$ for all $i \in [k]$ and two k-sets are distinct.The family $\mathcal{F} \subset \binom{[n]}{k}$ is called *shifted* if $G \prec F \in \mathcal{F}$ can implies $G \in F$.

Lemma 2.2. In the study of generalized matching number, we can assume that $\mathcal{F}$ is shifted, and this assumption will not affect the result.

Proof. We will prove that if $S_{ij}(\mathcal{F})$ has an $(s+1)$-disjoint collection of size λ then $\mathcal{F}$ also has. Assume that $\mathcal{A} \subseteq S_{ij}(\mathcal{F})$ is an $(s+1)$-disjoint collection of size λ. We can classify these edges into four categories:

$$\mathcal{A}_1 = \{A \in \mathcal{A} : i, j \in A\}, \quad \mathcal{A}_2 = \{A \in \mathcal{A} : i \in A, j \notin A\},$$

$$\mathcal{A}_3 = \{A \in \mathcal{A} : i \notin A, j \in A\}, \quad \mathcal{A}_4 = \{A \in \mathcal{A} : i, j \notin A\}.$$

Since the $(s+1)$-disjoint property, we have $|\mathcal{A}_1| + |\mathcal{A}_2| \le s$ and $|\mathcal{A}_1| + |\mathcal{A}_3| \le s$. We first partition $\mathcal{A}_2$ into $\mathcal{A}_{21}$ and $\mathcal{A}_{22}$, such that

$$\mathcal{A}_{21} = \{A \in \mathcal{A}_2 : A \in \mathcal{F}\}, \quad \mathcal{A}_{22} = \{A \in \mathcal{A}_2 : A \notin \mathcal{F}\}.$$

By the definition of (i,j)-shift, $\mathcal{A}_1, \mathcal{A}_{21}, \mathcal{A}_3, \mathcal{A}_4 \subseteq \mathcal{F}$ and $S_{ij}^{-1}(\mathcal{A}_{22}) = \{(A - \{i\}) \cup \{j\} : A \in \mathcal{A}_{22}\} \subseteq \mathcal{F}$, and $\{(A - \{j\}) \cup \{i\} : A \in \mathcal{A}_3\} \subseteq \mathcal{F}$. We also partition $\mathcal{A}_3$ into $\mathcal{A}_{31}$ and $\mathcal{A}_{32}$ in the following way: if $|\mathcal{A}_3| \le |\mathcal{A}_{21}|$ then let $\mathcal{A}_{31} = \mathcal{A}_3$ and $\mathcal{A}_{32} = \emptyset$; if $|\mathcal{A}_3| > |\mathcal{A}_{21}|$ then let $\mathcal{A}'_3 = \{A \in \mathcal{A}_3 : (A - \{j\}) \cup \{i\} \in \mathcal{A}_{21}\}$ and $\mathcal{A}_{31} = \mathcal{A}'_3 \sqcup \mathcal{A}''_3$, where $\mathcal{A}''_3$ is an arbitrary subset of $\mathcal{A}_3 \setminus \mathcal{A}'_3$ satisfying $|\mathcal{A}'_3| + |\mathcal{A}''_3| = |\mathcal{A}_{31}| = |\mathcal{A}_{21}|$.

Now, set $\mathcal{A}'_{32} = \{(A - \{j\}) \cup \{i\} : A \in \mathcal{A}_{32}\}$ and define a subset $\mathcal{B}$ of $\mathcal{F}$ as follows:

$$\mathcal{B} = \mathcal{A}_1 \sqcup (\mathcal{A}_{21} \sqcup \mathcal{A}'_{32}) \sqcup (\mathcal{A}_{31} \sqcup S_{ij}^{-1}(\mathcal{A}_{22})) \sqcup \mathcal{A}_4.$$

It is not hard to see that $\mathcal{B}$ is an $(s+1)$-disjoint collection of size λ. Indeed,

$$\#\{B : i \in B, B \in \mathcal{B}\} = |\mathcal{A}_1| + |\mathcal{A}_{21}| + |\mathcal{A}'_{32}| \le \max\{|\mathcal{A}_1| + |\mathcal{A}_2|, |\mathcal{A}_1| + |\mathcal{A}_3|\} \le s,$$

and

$$\#\{B : j \in B, B \in \mathcal{B}\} = |\mathcal{A}_1| + |\mathcal{A}_{31}| + |S_{ij}^{-1}(\mathcal{A}_{22})| \le |\mathcal{A}_1| + |\mathcal{A}_2| \le s.$$

Points other than i and j remain unchanged under the (i,j)-shift, so for every point i, $\#\{B : i \in B, B \in \mathcal{B}\} \le s$. □

Lemma 2.3. For any fixed $\lceil t/s \rceil$, if there is a $\lceil t/s \rceil$-matching in a k-uniform shifted hypergraph $\mathcal{F}$,then a $s+1$-disjoint collection of size t can be found in $\mathcal{F}$,when $t \equiv 1 \pmod{s}$,$0 < s \le k$.

Proof. Let $a = \lceil t/s \rceil$,then $t = (a-1)s + 1$.The a-matching in $\mathcal{F}$ note as $\mathcal{F}_m = (F_1, \ldots, F_a)$.Let hypergraph $\mathcal{F}'(\mathcal{F}_m) = \{F : \mathcal{F}_m$ contains at least one edge G,such that $F \prec G\}$,it is easy to get that $\mathcal{F}' \subset \mathcal{F}$(because $\mathcal{F}$ is shifted).

Claim 1. After a finite number of applications of $\{S_{ij}\}$,$\mathcal{F}_m$ can be transformed into a matching on $[ak]$.

Proof. Define m as the smallest number that not appear in $\mathcal{F}_m$,and M as the largest number that does appear in $\mathcal{F}_m$.If $m > M$ then the claim is proven.If not,take the edge A containing M, and then replace A in $\mathcal{F}_m$ with $S_{mM}(A)$.In this process, since m increases and M decreases, we can repeat it iteratively. After a finite number of steps, we will have $m > M$. □

Claim 2. Let $i < j$ and $A \in \binom{[n]}{k}$, then $S_{ij}(A) \prec A$.

Proof. Suppose $S_{ij}(A) \neq A$. Then by definition, $i \notin A$, $j \in A$, and $S_{ij}(A) = (A \setminus \{j\}) \cup \{i\} \notin \mathcal{F}$.We compare A and B in the order $\prec$. Write $A = \{a_1 < a_2 < \cdots < a_s < j \cdots < a_k\}$, $S_{ij}(A) = \{a_1 < a_2 < \cdots < a_t < i < a_{t+1} \cdots < a_s < a_{s+2} \cdots < a_k\}$.By comparing A and $S_{ij}(A)$ term by term and using the facts that $i < a_{t+1}$ and $a_i < a_{i+1}$, we obtain $S_{ij}(A) \prec A$. □

By Claim 1 and Claim 2,there is a matching $\mathcal{F}_{ak}$ in $\mathcal{F}'$ covering $[ak]$.Since $\mathcal{F}'(\mathcal{F}_{ak}) \subset \mathcal{F}'(\mathcal{F}_m)$, making it the most difficult to find $s+1$-disjoint collection of size t,we refer to $\mathcal{F}'(\mathcal{F}_{ak})$ as $\mathcal{F}'$ and now work in $\mathcal{F}'$.

If in $\mathcal{F}'$, besides $\mathcal{F}_{ak}$, we can also find $s-1$ disjoint matching of size $a-1$,then take these matchings and $\mathcal{F}_{ak}$ form t-collection,so the collection is $s+1$-disjoint(because the occurrence count of each point is less than $s+1$).Then we start to count the number of $a-1$-matching.

To find the first matching $\mathcal{F}_{ak,1}$ of size $a-1$, we observe the k-th elements $x_{1,k}, \ldots, x_{a,k}$ in $\mathcal{F}_{ak}$. Without loss of generality let $x_{1,k} < \cdots < x_{a,k}$, then we construct the matching $\mathcal{F}_{ak,1} = \{F_{2,1}, F_{3,1}, \ldots, F_{a,1}\}$, where $F_{i,1} = (F_i - \{x_{i,k}\}) \cup \{x_{i-1,k}\} \prec F_i$ for $2 \leq i \leq a$. Similarly, we observe the $(k-1)$-th elements $x_{1,k-1}, \ldots, x_{a,k-1}$ in $\mathcal{F}_{ak}$ to find the second matching $\mathcal{F}_{ak,2}$. It is not hard to see that $\mathcal{F}_{ak}, \mathcal{F}_{ak,1}, \mathcal{F}_{ak,2}$ are disjoint and we are able to find more disjoint $(a-1)$-matchings. By $k \geq s$ we finally get $s-1$ disjoint $(a-1)$-matchings $\mathcal{F}_{ak,1}, \mathcal{F}_{ak,2}, \ldots, \mathcal{F}_{ak,s-1}$(Because when $k=2$, it is possible that only one match can be selected, so the condition is $s \leq k$ rather than $k+1$). The proof is complete. □

*Proof of Theorem 2.3:*Theorem 2.4 states that if uniform hypergraph $\mathcal{F}$ contains $\binom{n}{k} - \binom{n-\lceil t/s \rceil + 1}{k} + 1$ edges,then there is a $\lceil t/s \rceil$-matching in $\mathcal{F}$.Then, Lemma 2.2 and Lemma 2.3 explain a $s+1$-disjoint collection of size t can be found in $\mathcal{F}$ together.Finally,since $m(n,k,t;s+1) \geq \binom{n}{k} - \binom{n-\lceil t/s \rceil + 1}{k}$(Lemma 2.1),so $m(n,k,t;s+1) = \binom{n}{k} - \binom{n-\lceil t/s \rceil + 1}{k}$. □

The preceding proof highlights that Theorem 2.4 (a classical matching result) provides the threshold, while Lemma 2.3 serves as the crucial bridge connecting the existence of a matching to the existence of an $(s+1)$-disjoint collection of size t. Consequently, any sufficient condition for the existence of a large matching can be translated into a corresponding result for generalized matchings via Lemma 2.3.

What is particularly noteworthy is that this theorem provides the unique construction for the case of equality in the inequality. This translation of the equality condition to our setting is valid because the existence of another graph $\mathcal{F}'$ without $s+1$-disjoint collection of size t would imply that $\mathcal{F}'$ also lacks $\lceil t/s \rceil$-matching, thereby contradicting the original theorem.

3 Generalized Focal Families

Next, a research topic in extremal graph theory that is closely related to the concepts studied in this paper will be introduced, in order to illustrate the significance of this study. (All the content in this chapter represents the research achievements of other authors.)

3.1 Background

Extremal problems concerning set systems without certain forbidden configurations are central in combinatorics and have applications in coding theory and computer science. In particular, the study of frameproof and focal-free hypergraphs has attracted considerable attention. Alon and Holzman [3] introduced the notion of r-focal hypergraphs and studied the corresponding

Turán number $ex_k(n, \mathcal{F}_r)$. In this work, we generalize their notion to (r, s)-focal hypergraphs and codes, and determine the asymptotic Turán number and code capacity in several regimes.

3.2 Definitions

Definition 3.1. A family of r sets (not necessarily distinct) $A_0, A_1, \ldots, A_{r-1} \subseteq 2^{[n]}$ with $A_0 \neq A_j$ for any $j \in [r-1]$ is called an (r, s)-*focal hypergraph* with focus A_0 if for every $x \in A_0$,

$$|\{i \in [r-1] : x \in A_i\}| \geq s.$$

A hypergraph $\mathcal{F} \subseteq 2^{[n]}$ is (r, s)-*focal-free* if it contains no (r, s)-focal hypergraph as a subhypergraph.

Definition 3.2. For integers $r \geq 3$, $1 \leq s \leq r-2$, and $k \geq 2$, define

$$ex_k(n, \mathcal{G}_{s,r}) = \max\left\{|\mathcal{F}| : \mathcal{F} \subseteq \binom{[n]}{k} \text{ is } (r, s)\text{-focal-free}\right\}.$$

Definition 3.3. Fix integers q, n, s, r with $n > r \geq 3$ and $1 \leq s \leq r-2$. A family $\boldsymbol{x}^{(0)}, \boldsymbol{x}^{(1)}, \ldots, \boldsymbol{x}^{(r-1)}$ of r vectors (not necessarily distinct) in $[q]^n$, with $\boldsymbol{x}^{(0)} \neq \boldsymbol{x}^{(i)}$ for each $i \in [r-1]$, is called an (r, s)-*focal family* with focus $\boldsymbol{x}^{(0)}$ if for every coordinate $i \in [n]$, at least s of the $r-1$ entries $x_i^{(1)}, \ldots, x_i^{(r-1)}$ equal $x_i^{(0)}$.

Let

$$g_{r,s}^q(n) = \max\{|C| : C \subset [q]^n \text{ contains no } (r, s)\text{-focal family of size } r\}.$$

3.3 Main Theorem

The following theorem gives an asymptotically optimal result for the Turán number of (r, s)-focal-free hypergraphs.The bound of Turán number is closely related to matching number, which also serves as the starting point of our study on generalization matching number in this paper.

Theorem 3.1. [2] Let $r \geq 3$, $1 \leq s \leq r-2$, and $k \geq 2$ be fixed integers. Then

$$\lim_{n\to\infty} \frac{ex_k(n, \mathcal{G}_{s,r})}{\binom{n}{\lceil \frac{sk}{r-1} \rceil}} = \frac{1}{\binom{k}{\lceil \frac{sk}{r-1} \rceil} - m\left(k, \lceil \frac{sk}{r-1} \rceil, \lambda; s+1, \overline{r-s}\right)},$$

where $\lambda \in [r-1]$ satisfies $\lambda \equiv sk \pmod{r-1}$, and $m(k, t, \lambda; s+1, \overline{r-s})$ is a generalized Erdős matching number.

Theorem 3.2. [2] For any fixed integers n, r and s satisfying $n, r \geq 3$ and $1 \leq s \leq r-2$, we have

$$\lim_{q\to\infty} \frac{g_{r,s}^q(n)}{q^{\lceil \frac{sn}{r-1} \rceil}} = \frac{1}{1 - m\left(n, \lceil \frac{sn}{r-1} \rceil, t; s+1, \overline{r-s}\right) / \binom{n}{\lceil \frac{sn}{r-1} \rceil}},$$

where $t \in [r-1]$ satisfies $t \equiv sn \pmod{r-1}$.

This result extends previous work on r-cover-free and r-focal-free hypergraphs, and provides a unified asymptotic formula for the generalized focal-free setting.

Reference

[1] Peter Frankl and Andrey Kupavskii. The erdős matching conjecture and concentration inequalities. *Journal of Combinatorial Theory, Series B*, 157:366–400, 2022.

[2] Xinqi Huang, Chong Shangguan, Xiande Zhang, and Yuhao Zhao. Focal-free uniform hypergraphs and codes, 2024.

[3] Alon Noga and Holzman Ron. Near-sunflowers and focal families. *Israel Journal of Mathematics*, 256(Pt.1):21–33, 2023.

笔墨文篇

稻花香里说丰年，听取蛙声一片。

——《西江月·夜行黄沙道中》

庐山小姑娘

史红霞

庐山有句名言：“不到三叠泉，枉为庐山客”。我们便是被这句话催上茫茫征途的。漫长的山路，不是热嘎嘎的沙砾，就是寒碜碜的石栈。才走了十来华里，我们这一行立志要当“庐山客”的人已个个唏嘘起来。渐渐地，那飘散的白云和绿荫间的纱雾，那满山遍野摇曳的杜鹃和色彩斑驳的野蕨，再也不能勾起我游目骋怀的雅趣了。哦，三叠泉！你真能赐给我们什么？还是我们真能从你那儿获取什么？

将近午错时分，我们终于来到五老峰下的一座不知名的小山。从三五错落有致的凉棚里，地嗖地窜出一个十三四岁的小姑娘，两手轻盈地一摆，甜津津地招呼道：“吃馄饨喝凉茶噢——”一转身，蹦回她的凉棚里。抹桌、摆碗、斟茶，眨眼间就摆布停当。我们正巴望着歇脚，赶紧占了位。正喝着茶，小姑娘用疑虑的眼光打量着我们：“你们也去三叠泉？”“是呀！不去怎么来五老峰？”“还有多少路？该走了一半了吧？”小姑娘乐呵呵地笑了：“你们呀最好留在这里，不然回不来！”

原来，我们只走了五分之一的路程，前面还有好几座山。可小姑娘的“惊人之语”，已经把我们“逼上梁山”。我们当中年纪最大的一位代表大家吐心声：“宁可回不来，也要见见三叠泉！”小姑娘又笑了，拿出一瓶四特酒和十来个五香蛋，俏皮地说：“算你们运气好，那就多吃点儿，多歇会儿，等会我给你们带路。”五老峰下的价格，比起牯岭又高出二成，小姑娘这话或是一种生意经吧！她怎么会为我们带路呢？然而，这并不妨碍我们开怀饱啖一顿，谁能挡得住四特酒的诱惑呢？

我真想留在这五老峰下。因为我自知大病初愈，怕牵累别人。可看着几位鬓角染霜的旅友同伴，又愧得难于启齿。正矛盾着，却见一位大嫂挑着一对粥桶走进凉棚。小姑娘叫一声“妈——”，接过粥桶往肩头轻轻一搁，竟催着我们上路了。

腰鼓似的粥桶亮油油、红彤彤的，小姑娘悠然担着它，如桃花篮似的大步走在我们前面。这时，我才细细打量着她：湖绿色的花布衫，显得短窄了些，蓝湛湛的裤子卷起两道高高的脚筒边；细丝丝的乌发并没有精心梳理，却是亮油油的，仿佛沐着五老峰的山云水雾似的。她给我们带路？挑这两桶粥？她究竟去干什么？一个个疑问冲向我心头，我便赶上前去和她拉呱。这一来我首先注意到她那眼睛，那非常特别的眼波儿。我敢说这是一眼泉水，吸足了山坞水涯间的灵秀之气。不然她怎么不待你多问，就回答了你心头的所有疑问。

原来每天午后，凉棚的生意就淡了，小姑娘照例是挑两桶粥，送到前面的山头去，当然罗，翻一座山，粥价会涨二成。那些下午从三叠泉返回的人，非买这粥喝才解乏。每年，她和妈妈苦忙一个暑假，足够全家一年的零花和小姑娘自己的学费呢！跟着这个挑粥桶的庐山小姑娘，我们踏着一层层石栈道，上了又下，下了又上。有时候，她会哼上一支不知名的山歌；有时候，她会催促我们：“跑呀！我挑着桶和你们比试，莫拉下来！”她总是快活地笑着唱着，始终走在前面。我惊奇地发现，我们一行中，再也听不见唏嘘叹息声。我更惊奇地感到，我的身体里也滋长出一种踏遍青山的力量。我猛然想起戈尔泰老人的诗句：“一个孩子的力量，就是生长的力量。”去三叠泉，该不就是为了获取生命的力量吧！

似乎换了一个方向。小姑娘搁下粥桶，抹去额角的汗水，轻轻对我们说：“好啦，不送你们了，沿着这条山路，再翻过前面那座山，就到了。”她又对我神秘地一笑：“现在你只好前进不好后退了，再退就冤了。”我也问道：“你陪我们多翻了两座山吧？”没料到小姑娘竟朗声大笑，指着路边的粥桶反问：“那你们可愿再买碗粥吃，我只收一倍的钱？”

作者信息: 史红霞，生于 1988 年，陕西西安人，毕业于北京大学中文系、文学硕士，陕西作协会员，2008 年始发作品，曾在《人民日报》《文汇报》《羊城晚报》《陕西日报》《诗刊》《人民文学》《草堂》《知音》《延河》等报刊发表散文、诗歌作品多篇。

稿件信息: 本稿件于 3 月 25 日来稿。稿件编辑：刘浩东

我们每人又喝了一碗粥——这并非一种感谢，而是确实需要“加热”。沿着她用扁担指的山路，开始了最后的跋涉。不知谁带了头，我们引亢高歌，歌声在峭壁上发出阵阵回声。这时候，我觉得我们这一行人都变成了孩子。来到观瀑亭，我们终于听到了那巨大的轰鸣声，我们欢呼雀跃，手做喇叭喊道：“三叠泉，您好！”谁也没有说要休息，我们便勇敢地走下那陡峭的一千级石梯。

啊，三叠泉，你为我们的到来欢呼起来，激动人心的鼓啸声越来越响……

春色如茶

杨炳阳

与朋友聊茶，说起汤色，竟用春色比喻，许是因我喜欢绿茶被水浸泡后，清清淡淡、绿意盈盈吧。无论龙井、云雾、碧螺春，还是银针、玉芽、毛尖，林林总总的茶，哪一款都能给人一种很特别的感觉，仿佛春花般纯美香甜，仿佛春风般清寒凛冽，仿佛春雨般梦幻怡人，品茶时的心态就如同走进了浓浓的春色一般。

有人说，想当一个文化人就得先学会喝茶。对或不对倒也不着急辩驳，无非是个人的修行。若能走很远的路汲来一壶山泉，再慢慢烧开，冲洗茶叶，泡出茶汤，然后一闻、二品、三回味，慢条斯理地喝完一壶茶，想那悠然的时光便会生出好些禅意，再烦郁的心境也都自然而然地恬淡了。这时候，若有一本泛黄的书卷拿在手上，该是多么的贴切啊。

春天的到来，恰是泡一壶好茶，急是急不来的，节气上早已立了春，可天气还是阴阴冷冷的，让人离不开暖气、棉衣，也不想出门，窝在家里做冬眠状。直到有一天，突然听到了滚滚的雷声，见到了张扬而下的暴雨，才知道春天已经大张旗鼓地来了。此刻，放眼看去才突然发现，外面的世界已经颜色大变，原本枯槁焦黄的山体已经呈现出一副艳丽的春光图来，桃花、梨花、油菜花争相斗艳，红色、黄色、白色谁都想独霸天下。可是，春天本来就该五彩缤纷啊，若只有桃花的红，或者梨花的白，又怎么能丰富我们的视野，又怎么能让我们诗兴大发呢？若真是让各种鲜花竞争一回，又有谁敢占尽春光？就好像那茶，纵然一口下去，有些微苦，但稍稍缓和些之后，就会觉得舌尖上漾起了一丝丝甜意，且慢慢扩散，细细品来只觉得层次丰富、滋味无穷。连茶的味道都不敢单一，这轻盈的春天又怎么敢让某种物件一枝独秀。苦后回甘，苦中有甘，这便是人们常说的禅茶一味了吧。而春色，既然经历了电闪雷鸣后的阵痛，催生出了这样一场盛大的花事，又怎么能让这些花儿分出尊卑呢，这春天的颜色总是不嫌多，只要丰富就好。

拿出品茶时的格调，闻一闻泥土的芬芳、菜花的馥郁。这时候，就应该换上踏青的衣服，走进大自然，品一品这清新的春意。看，那金灿灿的油菜花已经打造出一座座金山；桃花借来了云霞的颜色飞出几朵红晕；而梨花定然是念着“梅须逊雪三分白，雪却输梅一段香”的诗句，渴望引起文人的注意；水面上疏影横斜的是刚绽了绿芽的垂柳，空气中满满的都是春的气息。情与景，相互交融，那茶也就泡透了，春色之妙宛如一盅茶，其实茶也醉人。

看够了春日美景，再深深地吸一口气，伸个懒腰，顿时觉得心旷神怡，又恰恰契合了喝茶后那般神清气爽的心境了。

作者信息：杨炳阳，生于 1958 年，山东潍坊人，毕业于山东大学中文系，曾在《人民日报》《人民文学》《诗刊》《大众日报》《文汇报》《知音》《星星诗刊》《青岛文学》等报刊发表散文、诗歌、小说作品多篇。

稿件信息：本稿件于 2 月 15 日来稿。稿件编辑：柯力成

致谢

《蛙鸣》自复刊以来，历经诸多困难与挑战。历届编委在实践中不断积累经验，也为我们留下了宝贵的启示与教益。在科大数院各位老师、校友和同学的共同支持与努力下，第 68 期《蛙鸣》终于得以与大家见面。

在此，《蛙鸣》编辑部全体成员衷心感谢各位投稿人的踊跃来稿，感谢第十二届数院学生会同学参与排版设计与宣传工作，感谢各位编委和审稿人的积极参与与辛勤付出（排名不分先后）：叶钉、倪嘉晖、张玉诚、柯力成、舒屹扬、罗云杰、朱一方、包麒新、张汇泽、冯玉山、郑登煜、刘浩东、朱葛瑄、邓博文。感谢他们在繁忙的学习与科研之余抽出时间，以严谨、专业的态度完成审稿工作。

编辑部衷心感谢中国科学技术大学数学科学学院对第 68 期《蛙鸣》编辑、筹备工作的全方位支持。特别感谢郑芳老师、邵锡惠老师对本期《蛙鸣》的悉心关怀与指导；感谢章俊彦老师对创办本期《蛙鸣》的热情支持与鼓励。

最后，感谢每一位读者对本期《蛙鸣》的关注与阅读。期待与各位下期再见！

第 68 期《蛙鸣》编辑部

2026 年 7 月 26 日

《蛙鸣》第 69 期征稿启事

现在，我们正式为《蛙鸣》第 69 期征稿！

创刊宗旨

《蛙鸣》是中国科大数院的学生杂志。1981 年 6 月 20 日，首期《蛙鸣》由 78 级数学系的同学们自写、自编、自刻、自印而成。四十余年来，《蛙鸣》一直是一个完全由学生主导，共同探讨、自由交流数学的开放平台，让同学们可以互相交流彼此的思想和发现。所以，我们欢迎各位科大的校友和同学们踊跃投稿！同时，我们也欢迎外校师生投稿，增进交流！

投稿栏目

(1) **蛙鸣记忆** 记录属于你的科大故事，叙述你与科大和数学的点点滴滴。
(2) **初阳** 以小论文形式研究一个无需太高深的数学知识就足够理解和欣赏的问题，或对具有一定深度的数学内容进行深入浅出的科普。欢迎大一大二同学来稿！
(3) **星辰** 分享你所喜爱或崇敬的数学工作者的故事、演讲与采访等，或让你印象深刻的讲座、座谈会与研讨会等的记录，或由你所撰写、翻译的数学科普与数学历史等。
(4) **蛙声一片** 以小论文形式记录你对数学更深入的学习或研究，可以撰写关于一个前沿方向或经典问题与相关成果的综述，可以研究一个具有一定深度与背景的数学问题，也可以记录你对数学课程的进阶内容的学习与思考。
(5) **笔墨诗篇** 分享你的原创文学作品，体裁不限。

投稿步骤

请将稿件发送到数院学生会官方邮箱：`mathsu01@ustc.edu.cn`
(1) 邮件标题：蛙鸣 _ 投稿栏目 _ 文章标题 _ 作者。
(2) 邮件正文：作者信息、联系方式（邮箱、QQ 或微信等）。
(3) 邮件附件：稿件 PDF（请隐去作者信息，以便盲审）。确定录用后请发送稿件 tex 源码。

文章要求

(1) 含有较多公式的文章请使用 LaTeX 编写，推荐使用《蛙鸣》官网模板。
(2) 数学类文章可以使用中文或英文撰写，要求语言朴实流畅，无明显语病。
(3) 文章摘要：请在正文前简要介绍本篇文章用到的想法、思路、主要内容等概要信息。
(4) 非原创内容请注明参考文献（尽可能详细到章节）。
(5) 其他投稿相关问题可以发送邮件至 `mathsu01@ustc.edu.cn` 咨询。

更多资讯请关注数院学生会官方 QQ（2061453364）与微信公众号（中国科大数学科学学院学生会）了解。

感谢大家对蛙鸣的支持！

欢迎大家踊跃来稿！

数院学生会 QQ 号

数院学生会微信公众号

蛙鸣第68期